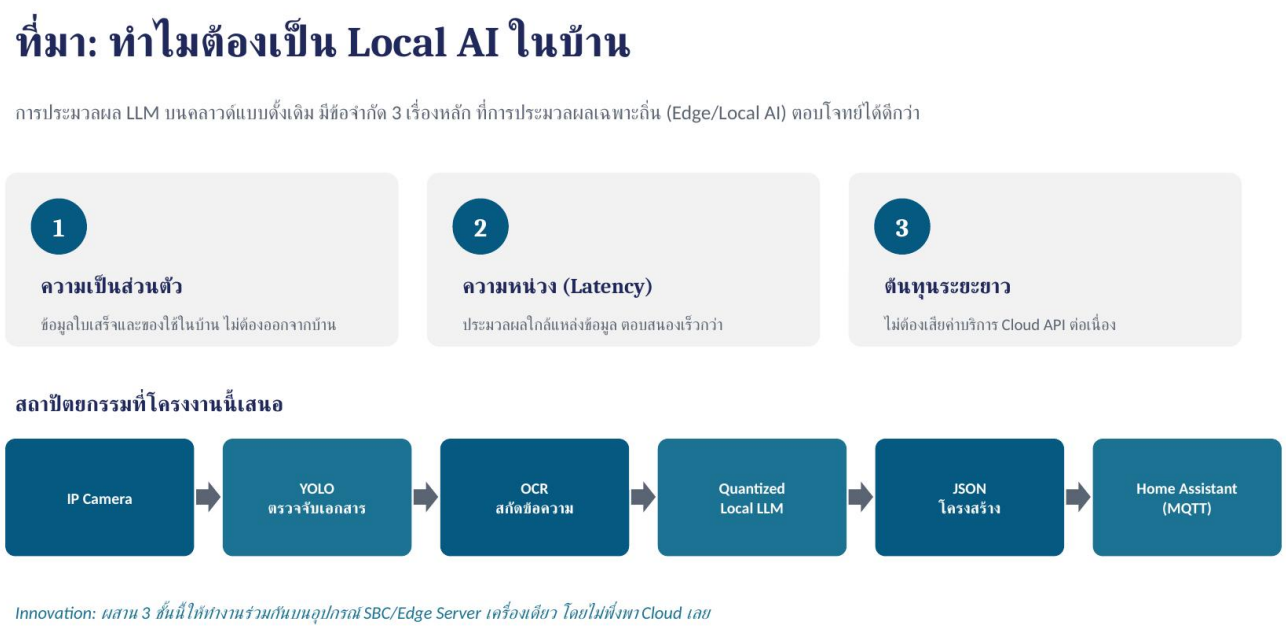


สคริปต์นำเสนอ — สไลด์ที 1

สวัสดีครับ วันนี้ผมจะนำเสนอหัวข้อ “การพัฒนาระบบประสาทส่วนกลางอัจฉริยะในทีพักอาศัย เพือสกัดและวิเคราะห์ข้อมูลห่วงโซ่อุปทานในครัวเรือน
ด้วยปัญญาประดิษฐ์ประมวลผลเฉพาะถีน”
ซึงเป็นส่วนหนึงของการทบทวนวรรณกรรมประกอบวิทยานิพนธ์ โดยมีอาจารย์ ผศ.บุญทรัพย์ ไวคำ เป็นอาจารย์ทีปรึกษาครับ



สคริปต์นำเสนอ — สไลด์ที่ 2

เริ่มจากที่มาของโครงงานก่อนครับ ทุกวันนี้การประมวลผล LLM
บนคลาวด์แบบดั้งเดิมมีข้อจำกัดอยู่สามเรื่องหลัก คือความเป็นส่วนตัวของข้อมูล
ความหน่วงในการตอบสนอง และต้นทุนการใช้งานระยะยาว การประมวลผลแบบเฉพาะถิ่นหรือ
Local AI จึงตอบโจทย์กว่า
โครงงานวิทยานิพนธ์ของผมจึงออกแบบสถาปัตยกรรมที่เชื่อมโยงตั้งแต่กล้อง IP Camera
ตรวจจับเอกสารด้วย YOLO สกัดข้อความด้วย OCR ประมวลผลด้วย Quantized Local LLM
ให้ได้โครงสร้าง JSON แล้วส่งต่อเข้าสู่ระบบบ้านอัจฉริยะผ่าน MQTT
เพื่อพยากรณ์อัตราการสิ้นเปลืองสินค้าในครัวเรือนครับ

วัตถุประสงค์และขอบเขตการศึกษา



1. ทบทวน–สังเคราะห์งานวิจัยด้าน on-device LLM inference ครอบคลุม 3 มิติของกรอบ Performance Trade-off
2. เปรียบเทียบด้วย Synthesis Matrix ระบุจุดร่วม จุดขัดแย้ง และ Research Gap
3. กำหนดสถาปัตยกรรมเชิงแนวคิด (Conceptual Architecture) สำหรับพัฒนาต้นแบบ
4. วางแผนดำเนินงาน (Roadmap) สำหรับขั้นตอนถัดไปของวิทยานิพนธ์

ขอบเขต: จำกัดที่การทบทวนวรรณกรรมและสังเคราะห์องค์ความรู้เท่านั้น — ยังไม่รวมการทดลองหรือพัฒนาระบบจริง

สคริปต์นำเสนอ — สไลด์ที่ 3

รายงานฉบับนี้มีวัตถุประสงค์สี่ข้อ คือทบทวนงานวิจัยที่เกี่ยวข้องกับ on-device LLM inference ครอบคลุมสามมิติของกรอบ Performance Trade-off เปรียบเทียบด้วย Synthesis Matrix เพื่อหาจุดร่วม จุดขัดแย้ง และช่องว่างทางความรู้ กำหนดสถาปัตยกรรมเชิงแนวคิด และวางแผนการดำเนินงานขั้นต่อไป โดยขอบเขตจำกัดอยู่ที่การทบทวนบทความวิจัย 12 ฉบับที่ผ่านการตรวจสอบในฐานข้อมูล Scopus เท่านั้น ยังไม่รวมการทดลองจริงครับ

กระบวนการคัดกรองบทความวิจัย

คัดกรองแบบ Funnel จากบทความตั้งต้น จนเหลือชุดที่ตรงกรอบ Performance Trade-off ของโครงงานโดยตรง



แยกกลุ่มเฉพาะบทความที่ตรงกรอบ Performance Trade-off ของโครงงานนี้โดยตรง: P1–P4, P6, P10 (quantization/hardware) · P8–P9 (structured decoding) · P7, P11–P12 (downstream IoT) · P5 (cross-disciplinary motivation)

สคริปต์นำเสนอ — สไลด์ที 4

กระบวนการคัดกรองบทความ เริมจากบทความทีเกียวข้องทังหมด 57 ฉบับ ผ่านเกณฑ์ Scopus เบืองต้นเหลือ 37 ฉบับ ยืนยันสถานะแล้ว 35 ฉบับ และคัดเฉพาะทีตรงกรอบ Performance Trade-off ของโครงงานโดยตรง จนเหลือ 12 ฉบับทีนำมาใช้ในรายงานฉบับนี แบ่งเป็นกลุ่ม quantization/hardware หกฉบับ กลุ่ม structured decoding สองฉบับ
กลุ่มบ้านอัจฉริยะสามฉบับ และอีกหนึงฉบับทีใช้เป็นหลักฐานสนับสนุนข้ามศาสตร์ครับ



สคริปต์นำเสนอ — สไลด์ที 5

จากการทบทวน พบว่างานวิจัยแบ่งออกเป็นสามมิติชัดเจนครับ มิติแรกคือ quantization กับ hardware trade-off พบว่ายิงบีบอัดแบบจำลองมากขึ้น ยิงประหยัดพลังงาน แต่ความแม่นยำจะลดลงในงานที่ต้องการความละเอียดสูง มีการทดสอบตั้งแต่ Raspberry Pi ไปจนถึง NVIDIA H100 มิติที่สองคือ grammar-constrained decoding หรือการบังคับโครงสร้างผลลัพธ์ให้เป็น JSON ตาม schema ซึ่งงาน SGLang เร่ง throughput ได้ถึง 6.4 เท่า แต่ยังทดสอบบนฮาร์ดแวร์ระดับ data center เท่านั้น และมิติที่สามคือบริบทบ้านอัจฉริยะและ IoT ปลายน้ำ ตั้งแต่ตัวแทน LLM ควบคุมอุปกรณ์ แบบจำลองพยากรณ์ Adaptive Holt-Winters ไปจนถึง ESP32 Gateway ที่เชื่อมต่อผ่าน MQTT ครับ

จุดที่เห็นตรงกัน vs จุดที่ขัดแย้งกัน

จุดร่วม (Consensus)

ทุกงานวิจัยเห็นตรงกันว่า **NPU + Quantization** จำเป็นต่อการรัน AI ภายใต้ทรัพยากรจำกัด

งานกลุ่ม Fully-local (Husom, Yin, Oloko-Oba) มุ่งลดพึ่งพา Cloud ให้เหลือน้อยที่สุด

งานชั้นปลายน้ำ (Rivkin, Sawalha, Serepas) ออกแบบให้เบา (lightweight) ไม่พึ่งทรัพยากรกลาง

จุดที่ขัดแย้ง/ต่างกัน

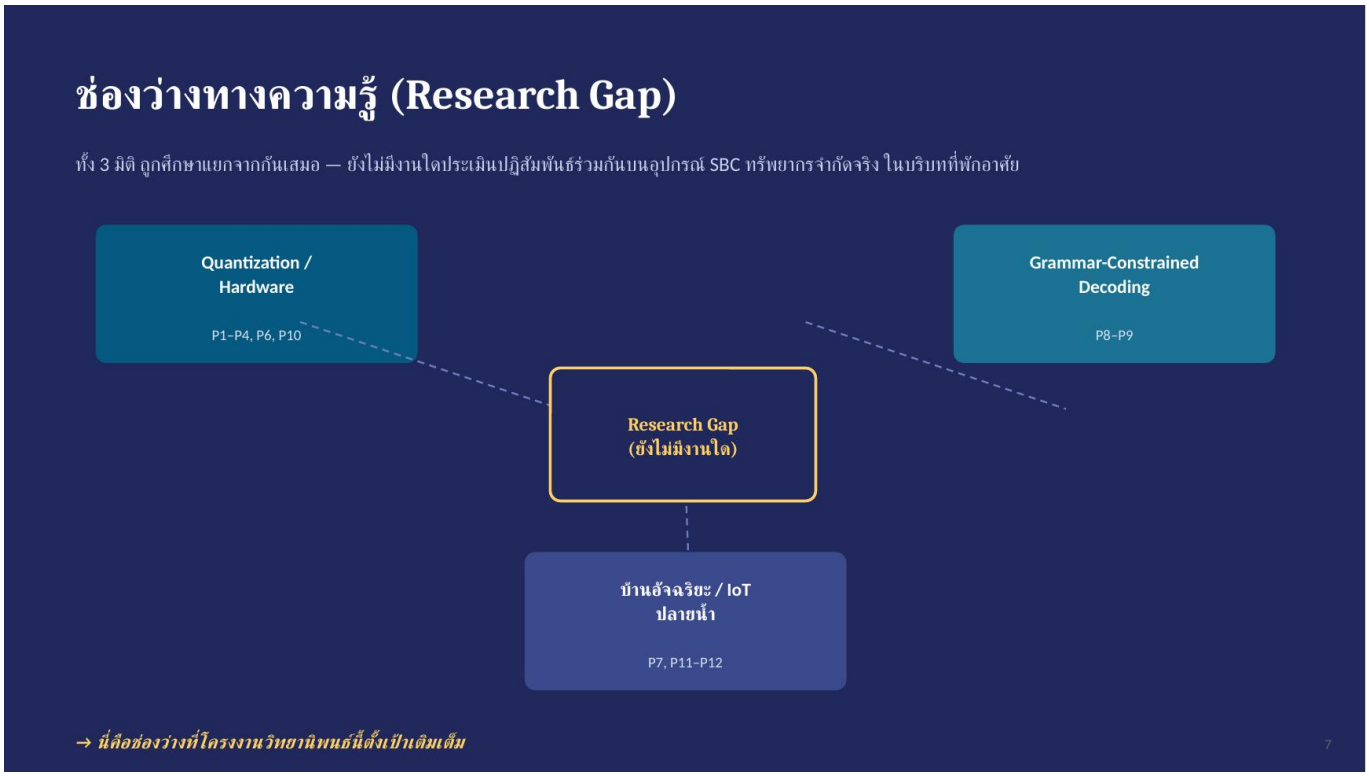
ระดับฮาร์ดแวร์ต่างกันมาก: Raspberry Pi 4 (RAM 4GB) ↔ NVIDIA H100

ระดับการพึ่งพา Cloud: บางงาน Hybrid (Cai et al.) บางงาน Fully-local

ผลลัพธ์จากฮาร์ดแวร์แรงสูง อาจถ่ายโอนมาใช้กับ Edge Server ขนาดเล็กในบ้านไม่ได้โดยตรง

สคริปต์นำเสนอ — สไลด์ที่ 6

เมื่อเปรียบเทียบกันแล้ว งานวิจัยทั้งหมดเห็นตรงกันว่า NPU และ Quantization จำเป็นต่อการรัน AI ภายใต้ทรัพยากรจำกัด และต่างมุ่งลดการพึ่งพา Cloud ให้เหลือน้อยที่สุด
แต่สิ่งที่ต่างกันคือระดับฮาร์ดแวร์ที่ใช้ทดสอบ ตั้งแต่ Raspberry Pi ไปจนถึง NVIDIA H100 ซึ่งต้นทุนต่างกันมาก รวมถึงระดับการพึ่งพา Cloud ที่บางงานยังเป็นแบบ Hybrid อยู่ ทำให้ผลการทดลองจากฮาร์ดแวร์ระดับสูง อาจไม่สามารถถ่ายโอนมาใช้กับ Edge Server ขนาดเล็กในบ้านได้โดยตรงครับ



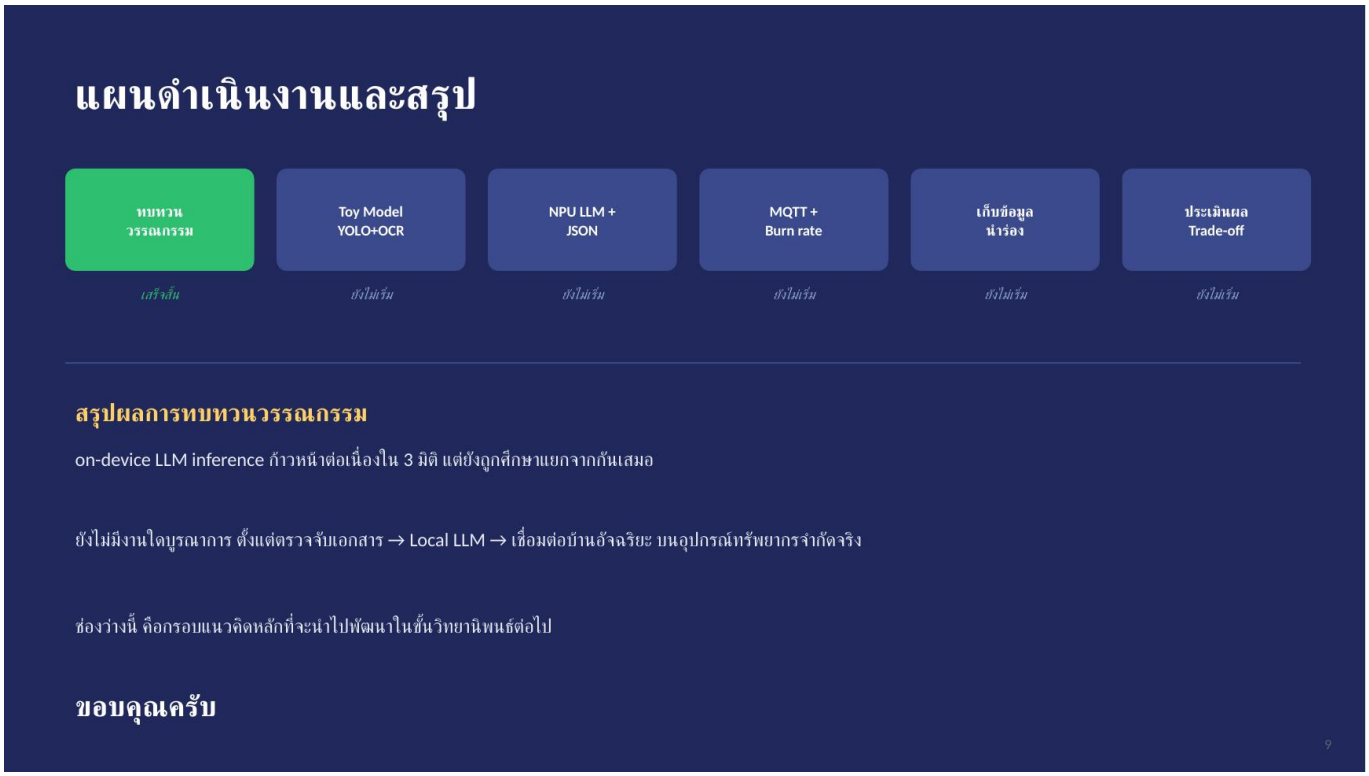
สคริปต์นำเสนอ — สไลด์ที 7

จากการสังเคราะห์ทั้งหมดนี้ เราพบช่องว่างทางความรู้ที่สำคัญครับ นั่นคือทั้งสามมิติ — quantization, structured decoding และบริบทบ้านอัจฉริยะ — ถูกศึกษาแยกจากกันมาโดยตลอด ยังไม่มีงานวิจัยฉบับใดเลยที่ประเมินปฏิสัมพันธ์ร่วมกันของทั้งสามมิตินี้ บนอุปกรณ์ single-board computer ที่มีทรัพยากรจำกัดจริง ในบริบทของที่พักอาศัย ช่องว่างนี้เองที่เป็นโอกาส และเป็นเป้าหมายหลักที่โครงงานวิทยานิพนธ์ของผมจะเข้าไปเติมเต็มครับ



สคริปต์นำเสนอ — สไลด์ที 8

จากช่องว่างดังกล่าว ผมจึงกำหนดสถาปัตยกรรมเชิงแนวคิดเป็นสามชั้นครับ
ชั้นแรกคือชั้นตรวจจับและสกัดข้อมูล ใช้กล้อง IP Camera ร่วมกับ YOLO และ OCR
ชั้นที่สองคือชั้นประมวลผลด้วย NPU-centric Local LLM ที่ผ่านการบีบอัดและควบคุมด้วย grammar-constrained decoding เพื่อให้ได้ JSON ที่ถูกต้อง
และชั้นที่สามคือชั้นประยุกต์ใช้งานปลายน้ำ ที่เชื่อมต่อ Home Assistant ผ่าน MQTT และพยากรณ์ burn rate ด้วย Adaptive Holt-Winters จุดที่ต่างจากงานวิจัยเดิมคือ ทั้งสามชั้นนี้จะทำงานประสานกันบนฮาร์ดแวร์เครื่องเดียว โดยไม่พึ่งพา Cloud เลยครับ



สคริปต์นำเสนอ — สไลด์ที 9

สำหรับแผนดำเนินงานต่อไป ตอนนี้อยู่ในระยะที 1 คือทบทวนวรรณกรรมเสร็จสิ้นแล้ว ขั้นต่อไปจะเป็นการพัฒนาต้นแบบ เชื่อมต่อระบบ และเก็บข้อมูลนำร่อง สรุปคือ งานวิจัยที่ผ่านมายังแยกศึกษาสามมิตินี้ออกจากกัน และช่องว่างนี้เองครับ ที่จะเป็นกรอบแนวคิดหลักในการพัฒนาวิทยานิพนธ์ของผมต่อไป ขอบคุณครับ