ชื่อ-นามสกุล: ณัชพล เพ็งพล **รหัสนักศึกษา:** 673380267-4

Sec: 1

ใบงานกิจกรรม

Fast-Track Research Skills

ส่วนที่ 1: Google Hack & Academic Search

1. หัวข้อที่เลือกศึกษา:

การประยุกต์ใช้ปัญญาประดิษฐ์แบบ Local/Edge AI บนหน่วยประมวลผลเฉพาะทาง NPU (Neural Processing Unit) ร่วมกับแบบจำลองภาษาขนาดเล็กชนิด Quantized (อาทิ Llama-3, Phi-3, Gemma ซึ่งดำเนินการผ่านซอฟต์แวร์ Ollama และไลบรารี llama.cpp) เพื่อการประมวลผลข้อมูลแบบ On-device ทั้งหมดภายในเครื่อง โดยหัวข้อดังกล่าวเป็นองค์ประกอบหลักด้านปัญญาประดิษฐ์ (Core AI Engine) ของโครงงานวิทยานิพนธ์ เรื่อง “การพัฒนาระบบประสาทส่วนกลางอัจฉริยะในที่พักอาศัยเพื่อสกัดและวิเคราะห์ข้อมูลห่วงโซ่อุปทานในครัวเรือนด้วยปัญญาประดิษฐ์ประมวลผลเฉพาะถิ่น”

2. คำสำคัญ (Keywords) ที่ใช้ในการสืบค้น:

Local AI, Edge AI, On-device AI, NPU (Neural Processing Unit), AI Accelerator, Quantized LLM, Small Language Model (SLM), Ollama, llama.cpp, Edge Computing

3. เทคนิคการสืบค้นที่ใช้ในการดำเนินการ:

1) การใช้เครื่องหมายอัญประกาศ (" ") เพื่อกำหนดให้ระบบค้นหาผลลัพธ์ที่ตรงตามวลีทั้งหมด อาทิ "edge AI" และ "NPU inference"

2) การใช้คำสั่ง site: เพื่อจำกัดขอบเขตการสืบค้นเฉพาะแหล่งข้อมูลทางวิชาการที่น่าเชื่อถือ อาทิ site:ieeexplore.ieee.org, site:dl.acm.org และ site:mdpi.com

3) การใช้คำสั่ง filetype:pdf เพื่อสืบค้นและเข้าถึงไฟล์บทความวิจัยฉบับเต็มโดยตรง

4) การใช้ตัวดำเนินการ OR เพื่อรวมคำค้นที่มีความหมายใกล้เคียงกัน อาทิ ("quantized LLM" OR "small language model") AND NPU

5) การใช้ระบบ Documents Search ของฐานข้อมูล Scopus ผ่านเว็บไซต์สำนักหอสมุด มหาวิทยาลัยขอนแก่น (library.kku.ac.th/36678/) โดยกำหนดเงื่อนไขปีพิมพ์ระหว่าง ค.ศ. 2023-2026 และสาขาวิชา (Subject Area) เป็น Computer Science เพื่อยืนยันสถานะการจัดทำดัชนีในฐานข้อมูล Scopus ของแหล่งข้อมูลแต่ละรายการ

4. ชื่อบทความ / แหล่งข้อมูลที่ค้นพบ:

ชื่อบทความ	URL / DOI	CRAAP Score
Edge-LLM: A Collaborative Framework for Large Language Model Serving in Edge Computing	doi.org/10.1109/ICWS62655.2024.00099	25 / 25
Sustainable LLM Inference for Edge AI: Evaluating Quantized LLMs for Energy Efficiency, Output Accuracy, and Inference Latency	doi.org/10.1145/3767742	25 / 25
Hybe: GPU-NPU Hybrid System for Efficient LLM Inference with Million-Token Context Window	doi.org/10.1145/3695053.3731051	24 / 25
ShadowNPU: System and Algorithm Co-design for NPU-Centric On-Device LLM Inference	doi.org/10.1145/3745756.3809205	24 / 25
From Biosignals to Bedside: A Review of Real-Time Edge Machine Learning for Wearable Health Monitoring	doi.org/10.3390/bioengineering13050559	24 / 25

5. ความเห็นของอาจารย์ที่ปรึกษาโครงงาน

_____

_____

ลายเซ็น. . . . . .

. . . . . .

ส่วนที่ 2: วัดความน่าเชื่อถือด้วย CRAAP Test

(เกณฑ์: หากได้ต่ำกว่า 15 คะแนน แนะนำให้เปลี่ยนแหล่งข้อมูลใหม่ทันที)

คำสั่ง: จากแหล่งข้อมูลที่ค้นพบในส่วนที่ 1 ให้ประเมินคะแนนความน่าเชื่อถือเบื้องต้น (เต็ม 5 คะแนนใน แต่ละ

หัวข้อ) พร้อมระบุเหตุผลสั้นๆ

C - Currency (ความทันสมัย / ความเป็นปัจจุบัน): สำหรับหัวข้อนั้นๆ ข้อมูลเก่าเกินไปหรือยัง? (เช่น สาย ไอที/

การแพทย์ ข้อมูลไม่ควรเกิน 3-5 ปี แต่ถ้าสายประวัติศาสตร์ ข้อมูลเก่าอาจจะใช้ได้) ลิงก์ต่างๆ ในเว็บยังกด ใช้งาน

ได้ไหม?

R - Relevance (ความเกี่ยวข้อง / ความสำคัญต่อเนื้อหา) : เนื้อหาในเว็บนี้ตรงกับหัวข้อรายงานของเรา จริงๆ

ไหม? กลุ่มเป้าหมายของบทความนี้คือใคร?

A - Authority (ความเชี่ยวชาญของแหล่งที่มา) : ใครเป็นคนเขียน? ใครเป็นสำนักพิมพ์หรือผู้จัดทำ? เขามี คุณวุฒิหรือความเชี่ยวชาญในเรื่องนี้ไหม? บนหน้าเว็บมีข้อมูลติดต่อหรือระบุตัวตนชัดเจนรึเปล่า? URL ลงท้ายด้วย

อะไร (เช่น .ac.th, .go.th จะมีความน่าเชื่อถือ)

A - Accuracy (ความถูกต้อง / มีหลักฐานรองรับ) : ข้อมูลมาจากไหน? มีหลักฐานหรือการอ้างอิง (Citations/References) รองรับไหม? ภาษาที่ใช้ดูเป็นทางการ ไม่มีคำสะกดผิดเต็มไปหมด หรือใช้ อารมณ์ตัดสิน?

P - Purpose (วัตถุประสงค์ในการเผยแพร่) : จุดประสงค์ของบทความนี้คืออะไร? เพื่อให้ความรู้ทางวิชาการ

ขายของ โฆษณาชวนเชื่อ (Propaganda) หรือความบันเทิง? ผู้เขียนมีความลำเอียงหรือไม่?

ชื่อบทความที่ 1: Edge-LLM: A Collaborative Framework for Large Language Model Serving in Edge Computing

แหล่งตีพิมพ์: 2024 IEEE International Conference on Web Services (ICWS) (2024), DOI: doi.org/10.1109/ICWS62655.2024.00099

เกณฑ์ประเมิน (CRAAP)	**คะแนน (1-5)**	**เหตุผลสนับสนุน / สิ่งที่ตรวจพบ**
C - Currency(ความใหม่/อัปเดต)	5	บทความเผยแพร่ในปี ค.ศ. 2024 ถือว่ามีความทันสมัย เนื่องจากอยู่ในกรอบเวลาที่ยอมรับได้ของสาขาวิชาคอมพิวเตอร์ (ไม่เกิน 3-5 ปี) และสามารถเข้าถึงได้จริงผ่านฐานข้อมูล IEEE Xplore โดยใช้หมายเลข DOI
R - Relevance(ความเกี่ยวข้องกับหัวข้อ)	5	เนื้อหามีความสอดคล้องโดยตรงกับหัวข้อโครงงาน กล่าวคือ เป็นการนำเสนอแนวทางการประมวลผลแบบจำลองภาษาขนาดใหญ่ (LLM) ในลักษณะ Collaborative บน Edge Server ซึ่งเป็นองค์ประกอบหลักของสถาปัตยกรรม Edge Server ร่วมกับ Quantized Local LLM ที่ได้ออกแบบไว้ในโครงงาน
A - Authority(ความเชี่ยวชาญของผู้แต่ง/เว็บ)	5	ตีพิมพ์ในการประชุมวิชาการ IEEE International Conference on Web Services (ICWS) ซึ่งจัดโดยสถาบัน IEEE และผ่านกระบวนการประเมินโดยผู้ทรงคุณวุฒิ (Peer Review) อย่างครบถ้วน
A - Accuracy(ความถูกต้อง/มีอ้างอิงไหม)	5	มีหมายเลข DOI ยืนยันจากฐานข้อมูล IEEE Xplore ผ่านการตรวจสอบสถานะการจัดทำดัชนีในฐานข้อมูล Scopus แล้ว (Confirmed) และมีจำนวนการอ้างอิง (Citation) รวม 62 ครั้ง อีกทั้งมีรายการอ้างอิงท้ายบทความครบถ้วน ([x] มี)
P - Purpose(วัตถุประสงค์ของบทความ)	5	จัดทำขึ้นเพื่อวัตถุประสงค์ทางวิชาการ โดยนำเสนอผลการวิจัยเชิงระบบ (System-oriented Research) มิได้มีเจตนาเพื่อการค้าแต่อย่างใด

สรุปผล: บทความนี้ได้คะแนนรวม 25 / 25 คะแนน

ชื่อบทความที่ 2: Sustainable LLM Inference for Edge AI: Evaluating Quantized LLMs for Energy Efficiency, Output Accuracy, and Inference Latency
แหล่งตีพิมพ์: ACM Transactions on Internet of Things (2025), DOI: doi.org/10.1145/3767742

เกณฑ์ประเมิน (CRAAP)	**คะแนน (1-5)**	**เหตุผลสนับสนุน / สิ่งที่ตรวจพบ**
C - Currency(ความใหม่/อัปเดต)	5	บทความเผยแพร่ในปี ค.ศ. 2025 ถือว่ามีความทันสมัยเป็นอย่างยิ่งและอยู่ในกรอบเวลาที่ยอมรับได้ของสาขาวิชาคอมพิวเตอร์
R - Relevance(ความเกี่ยวข้องกับหัวข้อ)	5	มีความสอดคล้องโดยตรงกับการประเมินแบบจำลอง Quantized LLM ในมิติของประสิทธิภาพเชิงพลังงาน (Energy Efficiency) และความหน่วง (Latency) ซึ่งเป็นตัวชี้วัดสำคัญของ Local LLM ในสถาปัตยกรรมของโครงงาน
A - Authority(ความเชี่ยวชาญของผู้แต่ง/เว็บ)	5	ตีพิมพ์ในวารสาร ACM Transactions on Internet of Things ซึ่งเป็นวารสารในเครือ ACM (Association for Computing Machinery) ที่ผ่านกระบวนการประเมินโดยผู้ทรงคุณวุฒิ
A - Accuracy(ความถูกต้อง/มีอ้างอิงไหม)	5	มีหมายเลข DOI ยืนยัน ผ่านการตรวจสอบสถานะการจัดทำดัชนีในฐานข้อมูล Scopus แล้ว (Confirmed) และมีจำนวนการอ้างอิงรวม 58 ครั้งแม้เพิ่งได้รับการตีพิมพ์ไม่นาน อีกทั้งมีรายการอ้างอิงท้ายบทความครบถ้วน ([x] มี)
P - Purpose(วัตถุประสงค์ของบทความ)	5	จัดทำขึ้นเพื่อวัตถุประสงค์ทางวิชาการ ในลักษณะของงานประเมินผลเชิงทดลอง (Evaluation Study) มิได้มีเจตนาทางการค้าแต่อย่างใด

สรุปผล: บทความนี้ได้คะแนนรวม 25 / 25 คะแนน

ชื่อบทความที่ 3: Hybe: GPU-NPU Hybrid System for Efficient LLM Inference with Million-Token Context Window

แหล่งตีพิมพ์: International Symposium on Computer Architecture (ISCA) (2025), DOI: doi.org/10.1145/3695053.3731051

เกณฑ์ประเมิน (CRAAP)	**คะแนน (1-5)**	**เหตุผลสนับสนุน / สิ่งที่ตรวจพบ**
C - Currency(ความใหม่/อัปเดต)	5	บทความเผยแพร่ในปี ค.ศ. 2025 ถือว่ามีความทันสมัยเป็นอย่างยิ่ง
R - Relevance(ความเกี่ยวข้องกับหัวข้อ)	5	มีความสอดคล้องกับสถาปัตยกรรมแบบผสมผสาน GPU-NPU (Hybrid GPU-NPU) ซึ่งเกี่ยวข้องโดยตรงกับการพิจารณาเลือกใช้ฮาร์ดแวร์เร่งความเร็ว (NPU) ในสถาปัตยกรรม Edge Server ของโครงงาน
A - Authority(ความเชี่ยวชาญของผู้แต่ง/เว็บ)	5	ตีพิมพ์ในการประชุมวิชาการ ISCA (International Symposium on Computer Architecture) ซึ่งเป็นการประชุมระดับแนวหน้า (Top-tier) ของสาขาวิชาสถาปัตยกรรมคอมพิวเตอร์ จัดร่วมโดยสถาบัน ACM และ IEEE
A - Accuracy(ความถูกต้อง/มีอ้างอิงไหม)	4	มีหมายเลข DOI ยืนยัน ผ่านการตรวจสอบสถานะการจัดทำดัชนีในฐานข้อมูล Scopus แล้ว (Confirmed) และมีรายการอ้างอิงท้ายบทความครบถ้วน ([x] มี) อย่างไรก็ตาม จำนวนการอ้างอิง (Citation) ยังอยู่ในระดับต่ำ (9 ครั้ง) เนื่องจากเป็นบทความที่เพิ่งได้รับการตีพิมพ์
P - Purpose(วัตถุประสงค์ของบทความ)	5	จัดทำขึ้นเพื่อวัตถุประสงค์ทางวิชาการ โดยนำเสนอสถาปัตยกรรมระบบใหม่พร้อมผลการทดลองสนับสนุน

สรุปผล: บทความนี้ได้คะแนนรวม 24 / 25 คะแนน

ชื่อบทความที่ 4: ShadowNPU: System and Algorithm Co-design for NPU-Centric On-Device LLM Inference

แหล่งตีพิมพ์: ACM SIGMOBILE International Conference on Mobile Systems, Applications, and Services (MobiSys) (2026), DOI: doi.org/10.1145/3745756.3809205

เกณฑ์ประเมิน (CRAAP)	คะแนน (1-5)	เหตุผลสนับสนุน / สิ่งที่ตรวจพบ
C - Currency(ความใหม่/อัปเดต)	5	บทความเผยแพร่ในปี ค.ศ. 2026 (ปรับแก้จากข้อมูลเดิมที่ระบุปี ค.ศ. 2025) ถือเป็นแหล่งข้อมูลที่มีความทันสมัยที่สุดในกลุ่มที่คัดเลือกมา
R - Relevance(ความเกี่ยวข้องกับหัวข้อ)	5	มีความสอดคล้องกับหัวข้อโครงงานในระดับสูงสุด เนื่องจากเป็นผลงานการออกแบบระบบประมวลผลแบบจำลองภาษาบนอุปกรณ์ (On-device LLM Inference) ที่ยึด NPU เป็นศูนย์กลาง ซึ่งตรงกับแก่นของสถาปัตยกรรม NPU ร่วมกับ Quantized Local LLM ของโครงงานโดยตรง
A - Authority(ความเชี่ยวชาญของผู้แต่ง/เว็บ)	5	ตีพิมพ์ในการประชุมวิชาการ ACM MobiSys (SIGMOBILE) ซึ่งเป็นการประชุมชั้นนำด้านระบบเคลื่อนที่ (Mobile Systems) ในเครือ ACM
A - Accuracy(ความถูกต้อง/มีอ้างอิงไหม)	4	มีหมายเลข DOI ยืนยัน ผ่านการตรวจสอบสถานะการจัดทำดัชนีในฐานข้อมูล Scopus แล้ว (Confirmed) โดยได้ปรับแก้ปีที่ตีพิมพ์จาก ค.ศ. 2025 เป็น ค.ศ. 2026 เรียบร้อยแล้ว และมีรายการอ้างอิงท้ายบทความครบถ้วน ([x] มี) อย่างไรก็ตาม จำนวนการอ้างอิงยังอยู่ในระดับต่ำ (4 ครั้ง) เนื่องจากเพิ่งได้รับการตีพิมพ์
P - Purpose(วัตถุประสงค์ของบทความ)	5	จัดทำขึ้นเพื่อวัตถุประสงค์ทางวิชาการ โดยนำเสนอการออกแบบร่วมระหว่างระบบและขั้นตอนวิธี (System–Algorithm Co-design) พร้อมผลการทดลองเชิงเทคนิค

สรุปผล: บทความนี้ได้คะแนนรวม 24 / 25 คะแนน

ชื่อบทความที่ 5: From Biosignals to Bedside: A Review of Real-Time Edge Machine Learning for Wearable Health Monitoring
แหล่งตีพิมพ์: Bioengineering (MDPI) (2026), DOI: doi.org/10.3390/bioengineering13050559

เกณฑ์ประเมิน (CRAAP)	คะแนน (1-5)	เหตุผลสนับสนุน / สิ่งที่ตรวจพบ
C - Currency(ความใหม่/อัปเดต)	5	บทความเผยแพร่ในปี ค.ศ. 2026 ถือว่ามีความทันสมัยเป็นอย่างยิ่ง
R - Relevance(ความ	4	มีความเกี่ยวข้องในเชิงอ้อมแต่มีนัยสำคัญ โดยได้คัดเลือกบทความ

เกณฑ์ประเมิน (CRAAP)	คะแนน (1-5)	เหตุผลสนับสนุน / สิ่งที่ตรวจพบ
เกี่ยวข้องกับหัวข้อ)		ฉบับนี้เป็นแหล่งข้อมูลข้ามศาสตร์ (Cross-disciplinary) นอกสาขาวิชาคอมพิวเตอร์ ตามเกณฑ์ที่อาจารย์ที่ปรึกษากำหนด เพื่อแสดงให้เห็นถึงการประยุกต์ใช้ Edge Machine Learning ในบริบททางการแพทย์และสุขภาพ (Wearable Monitoring) ซึ่งใช้หลักการประมวลผลแบบ Real-time On-device Inference เช่นเดียวกับโครงงาน
A - Authority(ความเชี่ยวชาญของผู้แต่ง/เว็บ)	5	ตีพิมพ์ในวารสาร Bioengineering ของสำนักพิมพ์ MDPI ซึ่งได้รับการจัดทำดัชนีในฐานข้อมูล Scopus และผ่านกระบวนการประเมินโดยผู้ทรงคุณวุฒิในสาขาวิศวกรรมชีวการแพทย์
A - Accuracy(ความถูกต้อง/มีอ้างอิงไหม)	5	มีหมายเลข DOI ยืนยัน ผ่านการตรวจสอบสถานะการจัดทำดัชนีในฐานข้อมูล Scopus แล้ว (Confirmed) และมีรายการอ้างอิงท้ายบทความครบถ้วน ([x] มี) โดยเป็นบทความปริทัศน์ (Review Article) ที่รวบรวมและสังเคราะห์งานวิจัยจำนวนมาก
P - Purpose(วัตถุประสงค์ของบทความ)	5	จัดทำขึ้นเพื่อวัตถุประสงค์ทางวิชาการ ในลักษณะบทความปริทัศน์ (Review Article) ที่ตีพิมพ์ในวารสารวิชาการ มิได้มีเจตนาทางการค้าแต่อย่างใด

สรุปผล: บทความนี้ได้คะแนนรวม 24 / 25 คะแนน