การเสนอเค้าโครงโครงงานคอมพิวเตอร์

ภาควิชาวิทยาการคอมพิวเตอร์ คณะวิทยาศาสตร์ มหาวิทยาลัยขอนแก่น

นายณัชพล เพ็งพล รหัสนักศึกษา 673380267-4

นายธนบดี เริ่มรักสกุล รหัสนักศึกษา 673380270-5

นักศึกษาระดับปริญญาตรี หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์

อาจารย์ที่ปรึกษาโครงงาน ผศ.บุญทรัพย์ ไวคำ

1 ชื่อหัวข้อโครงงาน

ภาษาไทย การพัฒนาระบบประสาทส่วนกลางอัจฉริยะในที่พักอาศัยเพื่อสกัดและวิเคราะห์ข้อมูลห่วงโซ่อุปทานในครัวเรือนด้วยปัญญาประดิษฐ์ประมวลผลเฉพาะถิ่น

ภาษาอังกฤษ DEVELOPMENT OF A LOCALIZED RESIDENTIAL INTELLIGENCE ENGINE FOR HOUSEHOLD SUPPLY-CHAIN ANALYTICS USING EDGE COMPUTING AND HOME NETWORK INFRASTRUCTURE

2 หลักการและเหตุผล

โครงงานเสนอระบบประสาทส่วนกลางอัจฉริยะในที่พักอาศัยที่รับข้อมูลจากประสาทสัมผัสดิจิทัลหลายชนิด หรือ e-Senses แล้วแปลงเป็นข้อมูลที่ตรวจสอบและใช้วิเคราะห์ได้ e-Eye รับภาพเอกสารซื้อสินค้า e-Nose อาจรับข้อมูลก๊าซหรือกลิ่น และ e-Skin อาจรับน้ำหนักหรือแรงสัมผัส ระยะแรกเลือก e-Eye เพื่อทำการทดลองที่มีข้อมูลจริง ส่วนโหนดอื่นยังเป็นส่วนขยายในกรอบระบบ ไม่ใช่ผลทดลองที่สำเร็จแล้ว [12]

ข้อมูลซื้อสินค้าในครัวเรือนอยู่ในใบเสร็จที่มีรูปแบบ ภาษา และคุณภาพภาพถ่ายต่างกัน การแปลงภาพเป็นรายการสินค้าแบบมีโครงสร้างต้องผ่านการตรวจจับเอกสาร การรู้จำข้อความ และการสกัดฟิลด์ ความผิดพลาดของขั้นต้นอาจส่งต่อถึงผล JSON และการวิเคราะห์ปลายน้ำ จึงต้องวัดทั้งความแม่นยำและทรัพยากรที่ใช้ในแต่ละขั้น

รายงานทบทวนวรรณกรรม 32 หน้าของโครงงานสังเคราะห์บทความวิจัย 12 ฉบับในสามมิติ คือ quantization และฮาร์ดแวร์ การสร้างผลลัพธ์แบบมีโครงสร้าง และบริบทบ้านอัจฉริยะ/IoT งานที่ทบทวนให้แนวทางวัด trade-off แต่ยังไม่ตอบโดยตรงว่าขั้นตอนเหล่านี้ทำงานร่วมกันได้ดีเพียงใดกับใบซื้อสินค้าจริงภาษาไทย/อังกฤษภายใต้ทรัพยากรจำกัด ช่องว่างนี้กล่าวเฉพาะชุดวรรณกรรมที่ทบทวน ไม่ใช่ข้อสรุปว่าไม่มีงานอื่นศึกษาเรื่องเดียวกัน [1–3, 12]

ผลนำร่องล่าสุดรับภาพ 124 ไฟล์ เหลือภาพไม่ซ้ำระดับไฟล์ 113 ภาพ และคัดภาพผู้สมัครใบซื้อสินค้ามีรายการ 59 ภาพ โมเดล YOLOv8n บน PC ได้ mAP@0.5 เท่ากับ 0.928 ในภาพตรวจ 10 ภาพจากชุดแรก และ 0.237 ในภาพส่งเพิ่ม 6 ภาพซึ่งกันไว้ทดสอบโมเดลเดิมโดยไม่ฝึกเพิ่ม ภาพชุดหลังต่างฉากด้วย จึงยังแยกสาเหตุของคะแนนที่ต่างกันไม่ได้ ต้องเพิ่มภาพและตรวจกรอบอ้างอิงก่อนสรุปประสิทธิภาพของระบบ [4]

3 วัตถุประสงค์ของโครงงาน

- ออกแบบกรอบสถาปัตยกรรม e-Senses และกระบวนการสามชั้น ได้แก่ การรับรู้และสกัดข้อมูล การประมวลผลเฉพาะถิ่น และการใช้งานในระบบบ้านอัจฉริยะ โดยใช้ e-Eye เป็นกรณีศึกษาระยะแรก
- พัฒนาต้นแบบแปลงภาพใบซื้อสินค้าเป็นข้อมูล JSON ที่ตรวจสอบย้อนหลังได้ และวัดความผิดพลาดของการตรวจจับ OCR และการสกัดข้อมูลทั้งรายชั้นและปลายทาง
- เปรียบเทียบผลของโมเดลขนาดเล็ก ระดับ quantization และการบังคับรูปแบบ JSON ต่อความถูกต้อง เวลา และหน่วยความจำภายใต้ทรัพยากรจำกัด โดยเริ่มบน PC และตรวจการส่งออกโมเดลสำหรับ RK3588
- ออกแบบการส่งข้อมูลที่ผ่านการตรวจแล้วสู่ระบบบ้านอัจฉริยะ และกำหนดข้อมูลเพิ่มเติมที่จำเป็นต่อการประเมินปริมาณคงเหลือหรืออัตราการใช้สินค้า ก่อนทดลองบนอุปกรณ์จริงเมื่อมีความพร้อม

4 ทฤษฎีและผลงานวิจัยที่เกี่ยวข้อง

4.1 การประมวลผลเฉพาะถิ่นและ trade-off

การลด precision ของโมเดลช่วยลดภาระทรัพยากร แต่ต้องประเมินความแม่นยำร่วมกับเวลาและพลังงาน ไม่อาจเลือกจากขนาดไฟล์เพียงอย่างเดียว Husom และคณะศึกษาการอนุมาน quantized LLM บนอุปกรณ์ edge ขณะที่ Giedra และคณะเสนอการประเมินหลายตัวชี้วัดบนระบบที่มีทรัพยากรจำกัด [1, 2] งาน ShadowNPU ศึกษาการแบ่งงานระหว่างหน่วยประมวลผลบนอุปกรณ์ [17] ในโครงงานนี้การเปรียบเทียบจะยึดงานสกัดใบซื้อสินค้าไทย/อังกฤษแทน benchmark ทั่วไป

4.2 การสร้างผลลัพธ์แบบมีโครงสร้าง

SGLang ศึกษาการเร่งการทำงานของโปรแกรมภาษาแบบมีโครงสร้าง [3] และ llama.cpp รองรับ grammar/JSON schema บางส่วน [5] โครงงานจะเปรียบเทียบการสร้าง JSON แบบเปิดกับแบบบังคับ schema โดยวัดทั้งความถูกต้องของโครงสร้างและค่าฟิลด์ เพราะ JSON ที่ parse ได้ยังอาจมีรายการสินค้าหรือราคาไม่ตรงหลักฐาน

4.3 การเชื่อมระบบบ้านอัจฉริยะและข้อมูลปลายน้ำ

รายงาน Assignment 4 สังเคราะห์งานบ้านอัจฉริยะสามแนวทาง: ตัวแทน LLM สำหรับควบคุมบ้าน [14], การพยากรณ์ข้อมูล IoT แบบอนุกรมเวลา [15] และเกตเวย์ ESP32 สำหรับการเชื่อมต่อ [16] โครงงานนี้จะส่งเฉพาะข้อมูลรายการซื้อที่ผ่านการตรวจแล้วผ่าน MQTT และแยกข้อมูลการซื้อเข้าออกจากข้อมูลปริมาณคงเหลือ เพราะใบเสร็จเพียงอย่างเดียวไม่บอกอัตราการใช้จริง [12]

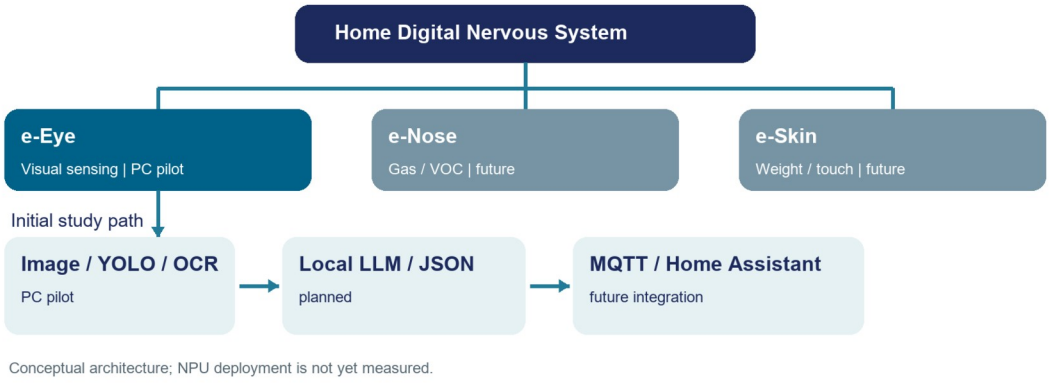
4.4 การตรวจจับเอกสารและเครื่องมือส่งออก

mAP@0.5 ใช้วัดการตรวจจับที่เกณฑ์ IoU 0.5 ส่วน mAP@0.5:0.95 ใช้หลายเกณฑ์ [6] สำหรับภาษาไทย Tesseract มีข้อมูลภาษา tha และ EasyOCR รองรับ th ร่วมกับ en [7, 8] Rockchip แยก RKNN Toolkit2 สำหรับการแปลง/ทดสอบโมเดลภาพและ RKLLM สำหรับการแปลง/รันโมเดลภาษา จึงต้องตรวจความเข้ากันได้ของแต่ละส่วนแยกกัน [9, 10]

5 วิธีดำเนินการวิจัย

5.1 สถาปัตยกรรมรวมและผลนำร่องที่มีแล้ว

ภาพที่ 1 แสดง e-Senses ของบ้านและเส้นทางศึกษาระยะแรก ชั้นรับรู้ใช้ e-Eye รับภาพใบซื้อสินค้า ตรวจกรอบเอกสารด้วย YOLO และอ่านด้วย OCR ชั้นประมวลผลจะใช้โมเดลภาษาขนาดเล็กสกัด JSON พร้อมตรวจ schema และความสมเหตุสมผล ก่อนส่งต่อชั้นประยุกต์ใช้ผ่าน MQTT/Home Assistant เมื่อข้อมูลพร้อม ส่วน e-Nose และ e-Skin ยังเป็นโหนดแนวคิดสำหรับระยะต่อเนื่อง [12]



ภาพที่ **1** กรอบสถาปัตยกรรม e-Senses และเส้นทางศึกษา e-Eye ระยะแรก (ออกแบบโดยผู้วิจัย)

ปัจจุบันฝึก YOLOv8n ด้วย PC CPU และตรวจ OCR แบบ spot-check เท่านั้น RKNN Toolkit2 บน PC แปลง ONNX เป็น RKNN เป้าหมาย RK3588 แบบไม่ quantize และรัน inference ได้หนึ่งภาพ ยังไม่มีการประเมิน JSON/LLM แบบมีเฉลย

ตรวจซ้ำหรือการวัดบนบอร์ด การตรวจเพิ่มพบว่าภาพส่งเพิ่มทั้ง 6 ใบมีตัวหนังสือหมุนข้าง เมื่อลองหมุนภาพและกรอบเฉลยให้ตรงโดยไม่ฝึกเพิ่ม mAP@0.5 ของ 6 ภาพเปลี่ยนจาก 0.237 เป็น 0.714 อีกด้านหนึ่งการหมุน 7 ภาพที่อ่านตรงในชุดแรกไป 90 องศาทำให้คะแนนเปลี่ยนจาก 0.995 เป็น 0.492 ผลแบบจับคู่นี้ชี้ความไวต่อการหมุนเฉพาะชุดเล็ก ยังไม่พิสูจน์สาเหตุเดียวของคะแนนต่างระหว่างชุด [4, 9]

ตารางที่ **1** ผลนำร่องและขอบเขตการตีความ

รายการ	ผล ณ **17 ต.ค. 2569**	ข้อจำกัด
ข้อมูล	124 ไฟล์ / 113 ไม่ซ้ำ / 59 ผู้สมัคร	ภาพไม่เท่ากับธุรกรรมอิสระ
YOLOv8n PC	38 ฝึก / 10 ตรวจ; mAP@0.5 0.928	ฉากเดิมคล้ายกัน; label รอตรวจซ้ำ
ชุดต่างฉาก	6 ภาพ; mAP@0.5 0.237	กลุ่มเล็ก; ยังไม่ใช่ final test
EasyOCR	3 ภาพ; spot-check วันที่/ยอด 4/6	ตรวจคนรอบเดียว; ไม่ใช่ CER
RKNN PC	ONNX → RKNN → PC inference สำเร็จ	ไม่ใช่ benchmark NPU จริง

5.2 ชุดข้อมูลและเฉลยอ้างอิง

ใช้เฉพาะใบซื้อสินค้าที่มองเห็นรายการสินค้า จำนวน และราคาเป็นชุดหลัก เอกสารชำระเงินหรือใบค่าหอเก็บเป็นชุดเสริมหรือทดสอบชนิดเอกสาร ไม่ปะปนกับคะแนนสกัดรายการสินค้า 59 ภาพปัจจุบันเป็นผู้สมัคร; จะรวมภาพที่ถ่ายซ้ำและเอกสารคู่เป็นกลุ่มธุรกรรมก่อนแบ่งชุดฝึก/ตรวจ/ทดสอบ เพื่อไม่ให้ข้อมูลใกล้ซ้ำข้ามชุด เป้าหมายระยะถัดไปคือเพิ่มความหลากหลายของร้าน ฉาก แสง มุม และอุปกรณ์ถ่าย และขยายเป็นอย่างน้อย 100 ธุรกรรมอิสระหากการเก็บข้อมูลและเวลาทำได้

การตรวจชื่อสินค้าเบื้องต้นในภาพผู้สมัคร 59 ภาพพบว่า ถอดชื่อครบครั้งแรก 12 ภาพ อ่านได้บางส่วนแต่ยังไม่ครบ 45 ภาพ และอีก 2 ภาพไม่มีบรรทัดชื่อสินค้า ตัวเลขอักษรจากส่วนที่อ่านได้ยังใช้แทนสัดส่วนภาษาของทั้งชุดไม่ได้ และยังไม่มีผู้ตรวจซ้ำ

เฉลยแต่ละภาพจะประกอบด้วยกรอบเอกสาร ข้อความอ้างอิง และ JSON schema คงที่: transaction_date, merchant, items[{name, quantity, unit, unit_price, line_total}], grand_total, currency และช่องสถานะอ่านไม่ออก กำหนด null สำหรับข้อมูลไม่ปรากฏ ไม่เดาจากบริบท จะให้ผู้วิจัยสองคนตรวจเฉลยแยกกันแล้วแก้ข้อขัดแย้งร่วมกัน พร้อมบันทึก version, กลุ่มธุรกรรม และเหตุผลการตัดภาพออก การวัดมุมเอียงละเอียดต้อง

กำหนดแนวอ้างอิงของกระดาษหรือบรรทัด ส่วนสัดส่วนตัวอักษรไทย/อังกฤษจะนับจากข้อความเฉลยที่ตรวจแล้ว ไม่ใช้ OCR ดิบเป็นค่าจริง

5.3 การทดลองและตัวชี้วัด

การตรวจจับใช้กรอบ receipt_region หนึ่งบริเวณต่อภาพเท่าที่นิยามอนุญาต รายงาน mAP@0.5, mAP@0.5:0.95, precision, recall และสัดส่วนกรอบคะแนนสูงสุดที่ IoU≥0.5 แยกฉากเดิมกับฉากใหม่ พร้อมรายงานจำนวนภาพและช่วงความไม่แน่นอนเมื่อขนาดชุดทดสอบเหมาะสม การตรวจ OCR เปรียบเทียบอย่างน้อย EasyOCR กับ Tesseract บนภาพและการ crop เดียวกัน ใช้ CER หลังประกาศกฎ normalize Unicode/ช่องว่าง และวัดความถูกต้องวันที่ ยอดรวม และบรรทัดสินค้าแยกจาก CER [6–8]

การสกัด JSON ใช้ข้อความ OCR เดียวกันในแต่ละเงื่อนไข และใช้ข้อความเฉลยแทน OCR อีกชุดหนึ่งเพื่อแยกความผิดพลาดต้นทาง เปรียบเทียบอย่างน้อยสองโมเดลขนาดเล็กที่ตรวจสิทธิและความเข้ากันได้แล้ว × สองระดับ quantization × เปิด/ปิด constrained decoding ภายใต้ prompt, schema, seed และขีดจำกัดโทเคนเดียวกัน ตัวชี้วัดหลักคือ parse rate, schema-valid rate, exact-match รายฟิลด์, ความคลาดเคลื่อนจำนวนเงิน และความครบของรายการสินค้า ตัวชี้วัดทรัพยากรคือเวลา end-to-end, เวลาแต่ละขั้น, peak RAM และขนาดโมเดล รายงานผลตามธุรกรรมและใช้การสุ่มซ้ำแบบจัดกลุ่มธุรกรรมเพื่อประมาณช่วงความไม่แน่นอน ไม่ตีความความต่างเล็กน้อยจากภาพใกล้ซ้ำว่าเป็นหลักฐานอิสระ

ตารางที่ 2 จุดตัดสินใจของการทดลอง

ขั้น	เปรียบเทียบ	เกณฑ์ตัดสินหลัก
ตรวจจับ	ฉากเดิม / ต่างฉาก	mAP และกรอบสูงสุด IoU≥0.5
OCR	EasyOCR / Tesseract	CER และความถูกต้องของฟิลด์
LLM	โมเดล × quantization × grammar	schema validity / field accuracy / RAM / latency
ส่งออก	ONNX / RKNN PC; RKLLM เมื่อพร้อม	ผ่าน conversion และผลเลขสมเหตุสมผล

5.4 การจำลองบน PC และการตรวจบนอุปกรณ์ในอนาคต

ระยะปัจจุบันใช้ PC เป็นฐานวัดและใช้ SDK เพื่อตรวจการแปลงโมเดลสำหรับเป้าหมาย RK3588 โดยบันทึกเวอร์ชันเครื่องมือ โมเดล ค่าพารามิเตอร์ และข้อมูลทดสอบ การจำกัด thread/RAM บน PC เป็นเพียงการศึกษาความไวต่อทรัพยากร ไม่ใช่การจำลองเวลา NPU แบบ cycle-accurate และไม่ใช้แทนการวัดพลังงานจริง [9, 10]

สเปกอ้างอิงสำหรับการขอยืมภายหลังคือ Radxa ROCK 5B หรือบอร์ดเทียบเท่าที่ใช้ RK3588, RAM 16 GB, ที่เก็บข้อมูลอย่างน้อย 64 GB, Linux image ที่มี NPU driver และ RKNN/RKLLM runtime ที่เข้ากันได้ พร้อมไฟเลี้ยงและการระบายความร้อน หากคณะมีรุ่น 8 GB จะประเมินขนาดโมเดลอีกครั้ง สเปกนี้เป็นกรอบคัดเลือก ไม่ใช่รายการจัดซื้อหรือผลทดสอบ อุปกรณ์จริงต้องยืนยันเวอร์ชัน SDK และความสามารถ constrained decoding ก่อนกำหนดวิธีทดลองบน NPU [9–11, 13]

5.5 การเชื่อมต่อปลายน้ำและความเป็นส่วนตัว

เมื่อ JSON ผ่านการตรวจแล้วจึงทดสอบส่งข้อความจำลองผ่าน MQTT ไปยังระบบบ้านอัจฉริยะ โดยแยกคะแนนความถูกต้องของข้อมูลต้นทางออกจากการส่งข้อความ ใบเสร็จบอกการซื้อเข้า ไม่ได้บอกอัตราการบริโภคโดยตรง การพยากรณ์ burn rate จึงต้องมีข้อมูลปริมาณคงเหลือหรือการใช้จริงตามเวลาเพิ่มเติม และยังไม่ใช่ข้ออ้างผลสำเร็จของระยะนี้

เก็บภาพดิบและ OCR ดิบในที่เก็บส่วนตัว จำกัดผู้เข้าถึง ใช้รหัสภาพแทนชื่อ และลบหรือปกปิดชื่อ เบอร์โทร เลขสมาชิก ที่อยู่ และข้อมูลการชำระเงินก่อนเผยแพร่ผล หากจะเก็บข้อมูลจากผู้เข้าร่วมหรือประเมินอัตราการแก้ไขโดยมนุษย์ ให้หารืออาจารย์และกระบวนการจริยธรรมของคณะก่อนเริ่มขั้นนั้น

6 ขอบเขตและข้อจำกัดของการวิจัย

ขอบเขตเชิงสถาปัตยกรรมครอบคลุม e-Senses และกระบวนการสามชั้นตามภาพที่ 1 ขอบเขตการทดลองหลักระยะแรกใช้ภาพใบซื้อสินค้าภาษาไทย/อังกฤษเพื่อตรวจจับ OCR และสกัด JSON บน PC พร้อมตรวจความเข้ากันได้ของ RKNN/RKLLM ตามความพร้อมของเครื่องมือ e-Nose, e-Skin, กล้อง IP แบบเรียลไทม์ และระบบบ้านอัจฉริยะเต็มรูปแบบเป็นส่วนต่อยอด ยังไม่มีบอร์ดสำหรับทดสอบ RK3588 จริง จึงไม่รวมผล NPU ในผลนำร่อง

ข้อจำกัดปัจจุบันคือข้อมูลหลายภาพอาจมาจากธุรกรรมเดียวกัน label ตรวจโดยผู้ช่วยและต้องให้ผู้วิจัยตรวจซ้ำ จำนวนทดสอบต่างฉากยังเล็ก และเฉลยข้อความ/JSON ยังไม่ครบ จึงไม่รายงาน CER, field accuracy หรือข้อสรุปด้าน NPU จากหลักฐานปัจจุบัน

7 สถานที่ทำวิจัย

ดำเนินการเตรียมข้อมูล ฝึกและทดสอบเบื้องต้นบนคอมพิวเตอร์ส่วนตัวของผู้จัดทำและสภาพแวดล้อม PC/WSL ที่บันทึกเวอร์ชันไว้ ใช้พื้นที่เก็บข้อมูลส่วนตัวที่ไม่ซิงก์ภาพดิบขึ้น

โฟลเดอร์ส่งงาน สถานที่ทดสอบบอร์ดจริงจะกำหนดภายหลังร่วมกับอาจารย์ที่ปรึกษาเมื่อมีอุปกรณ์

8 ประโยชน์ที่คาดว่าจะได้รับ

- ได้กรอบสถาปัตยกรรม e-Senses และข้อกำหนดการส่งข้อมูลระหว่างชั้นที่ใช้พัฒนาระบบบ้านอัจฉริยะในระยะต่อไป
- ได้ชุดข้อมูลและเฉลยที่ตรวจสอบย้อนหลังได้สำหรับใบซื้อสินค้าไทย/อังกฤษ พร้อมข้อกำหนดการแบ่งชุดตามธุรกรรม
- ได้หลักฐานว่าแต่ละขั้นของ e-Eye ผิดพลาดตรงไหน โดยเฉพาะเมื่อฉากภาพเปลี่ยน และมีวิธีประเมิน JSON ที่แยกความถูกต้องโครงสร้างจากเนื้อหา
- ได้ข้อมูล trade-off บน PC ที่ช่วยคัดแบบจำลองและกำหนดการทดลองบนฮาร์ดแวร์จริงอย่างมีเหตุผล โดยไม่สับสนผลจำลองกับ NPU

9 แผนและระยะเวลาดำเนินการ

ตารางที่ 3 แผนดำเนินงานระยะ PC นับจากการรับรองเค้าโครง

ช่วง	กิจกรรม	ผลส่งมอบ
สัปดาห์ 1	ตรวจประเภทภาพ/กลุ่มธุรกรรมและ label	manifest และ split ที่ตรวจซ้ำ
สัปดาห์ 2–3	ทำเฉลยข้อความและ JSON สองรอบ	gold set พร้อมคู่มือ annotation
สัปดาห์ 3–4	เปรียบเทียบ OCR และปรับตรวจจับข้ามฉาก	CER / field metrics / detection metrics
สัปดาห์ 4–5	ทดลองโมเดลภาษาและ constrained output บน PC	ตารางความแม่นยำ เวลา และ RAM
สัปดาห์ 6	ทวน RKNN/RKLLM PC-side และเขียนผล	รายงานข้อจำกัดและขั้นทดสอบบอร์ด

หลังระยะ PC หากมีบอร์ดยืมและการอนุมัติที่เกี่ยวข้อง จึงย้ายโมเดลที่เข้ากันได้ไปวัด latency, RAM และพลังงานจริงบนอุปกรณ์ โดยคงชุดทดสอบและเวอร์ชันโมเดลไว้เทียบกับ PC กิจกรรมนี้เป็นระยะต่อเนื่องภายหลังการศึกษาเบื้องต้น

10 งบประมาณ

ระยะ PC ใช้คอมพิวเตอร์ พื้นที่เก็บข้อมูล และซอฟต์แวร์ที่มีสิทธิใช้อยู่ จึงไม่มีวงเงินจัดซื้อฮาร์ดแวร์ในระยะนี้ ส่วนบอร์ด RK3588 และอุปกรณ์ประกอบจะดำเนินเรื่องขอยืมผ่านคณะเมื่อเริ่มระยะทดสอบจริง หากต้องจัดหาใหม่ จะเสนอรายการรุ่น ราคา และความเข้ากันได้ต่ออาจารย์ก่อนกำหนดงบประมาณ ไม่ใส่ราคาที่ยังไม่ได้สำรวจ

11 เอกสารอ้างอิง

[1] Husom, E. J., et al. (2025). Sustainable LLM inference for edge AI: Evaluating quantized LLMs for energy efficiency, output accuracy, and inference latency. ACM Transactions on Internet of Things, 6(4), Article 28. https://doi.org/10.1145/3767742

[2] Giedra, H., et al. (2026). Benchmarking large language model inference on limited-resource edge systems. Electronics, 15(11), 2451. doi:10.3390/electronics15112451.

[3] Zheng, L., et al. (2024). SGLang: Efficient execution of structured language model programs. Advances in Neural Information Processing Systems, 37, 62557-62583. https://doi.org/10.52202/079017-2000

[4] ณัชพล เพ็งพล และ ธนบดี เริ่มรักสกุล. (2569). ผลนำร่อง e-Eye บน PC ณ วันที่ 17 ตุลาคม 2569. บันทึกผลภายในโครงงาน.

[5] ggml-org. (2026). GBNF guide, llama.cpp. https://github.com/ggml-org/llama.cpp/tree/master/grammars

[6] Ultralytics. (2026). YOLO performance metrics. https://docs.ultralytics.com/guides/yolo-performance-metrics/

[7] Tesseract OCR. (2026). Data files and language support. https://github.com/tesseract-ocr/tessdata

[8] Jaided AI. (2026). EasyOCR. https://github.com/JaidedAI/EasyOCR

[9] Rockchip. (2026). RKNN Toolkit2. https://github.com/airockchip/rknn-toolkit2

[10] Rockchip. (2026). RKLLM. https://github.com/airockchip/rknn-llm

[11] Rockchip. (2022). RK3588 brief datasheet. https://www.rock-chips.com/a/en/products/RK35_Series/2022/0926/1660.html

[12] ณัชพล เพ็งพล และ ธนบดี เริ่มรักสกุล. (2569). การพัฒนาระบบประสาทส่วนกลางอัจฉริยะในที่พักอาศัยเพื่อสกัดและวิเคราะห์ข้อมูลห่วงโซ่อุปทานในครัวเรือนด้วยปัญญาประดิษฐ์ประมวลผลเฉพาะถิ่น. รายงานทบทวนวรรณกรรม 32 หน้า, เอกสารภายในโครงงาน.

[13] Radxa. (2026). ROCK 5B introduction and specifications. https://docs.radxa.com/en/rock5/rock5b/getting-started/introduction

[14] Rivkin, D., et al. (2025). AIoT smart home via autonomous LLM agents. IEEE Internet of Things Journal, 12(3), 2458-2472. https://doi.org/10.1109/JIOT.2024.3471904

[15] Sawalha, S., & Al-Naymat, G. (2025). An adaptive Holt-Winters model for seasonal forecasting of Internet of Things (IoT) data streams. IoT, 6(3), Article 39. https://doi.org/10.3390/iot6030039

[16] Serepas, F., et al. (2025). Lightweight embedded IoT gateway for smart homes based on an ESP32 microcontroller. Computers, 14(9), Article 391. https://doi.org/10.3390/computers14090391

[17] Yin, W., et al. (2026). ShadowNPU: System and algorithm co-design for NPU-centric on-device LLM inference. Proceedings of MobiSys 2026, 294-308. https://doi.org/10.1145/3745756.3809205

ลงชื่อ ..... (นายณัชพล เพ็งพล) ผู้เสนอโครงงาน

ลงชื่อ ..... (นายธนบดี เริ่มรักสกุล) ผู้เสนอโครงงาน

วันที่ 17 ตุลาคม 2569