การเสนอเค้าโครงโครงงานคอมพิวเตอร์

ภาควิชาวิทยาการคอมพิวเตอร์ คณะวิทยาศาสตร์ มหาวิทยาลัยขอนแก่น

นายณัชพล เพ็งพล รหัสนักศึกษา 673380267-4

นายธนบดี เริ่มรักสกุล รหัสนักศึกษา 673380270-5

นักศึกษาระดับปริญญาตรี หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์

อาจารย์ที่ปรึกษาโครงงาน ผศ.บุญทรัพย์ ไวคำ

1 ชื่อหัวข้อโครงงาน

ภาษาไทย

การพัฒนาระบบประสาทส่วนกลางอัจฉริยะในที่พักอาศัยเพื่อสกัดและวิเคราะห์ข้อมูลห่วงโซ่อุปทานในครัวเรือนด้วยปัญญาประดิษฐ์ประมวลผลเฉพาะถิ่น

ภาษาอังกฤษ DEVELOPMENT OF A LOCALIZED RESIDENTIAL INTELLIGENCE ENGINE FOR HOUSEHOLD SUPPLY-CHAIN ANALYTICS USING EDGE COMPUTING AND HOME NETWORK INFRASTRUCTURE

2 หลักการและเหตุผล

โครงงานเสนอระบบประสาทส่วนกลางอัจฉริยะในที่พักอาศัยที่รับข้อมูลจากประสาทสัมผัสดิจิทัลหลายชนิด หรือ e-Senses แล้วแปลงเป็นข้อมูลที่ตรวจสอบและใช้วิเคราะห์ได้ e-Eye รับภาพเอกสารซื้อสินค้า e-Nose อาจรับข้อมูลก๊าซหรือกลิ่น และ e-Skin อาจรับน้ำหนักหรือแรงสัมผัส ระยะแรกเลือก e-Eye เพื่อทำการทดลองที่มีข้อมูลจริง ส่วนโหนดอื่นยังเป็นส่วนขยายในกรอบระบบ ไม่ใช่ผลทดลองที่สำเร็จแล้ว

ฐานของข้อเสนอนี้คือสถาปัตยกรรมสามชั้นในรายงานทบทวนวรรณกรรมเดิม: รับภาพเอกสารจากกล้องหรือภาพถ่ายแล้วตรวจจับด้วย YOLO และอ่านด้วย OCR; ใช้ Local LLM ที่เลือกขนาดและระดับ quantization ให้เหมาะกับเครื่อง พร้อมควบคุมรูปแบบผลลัพธ์เป็น JSON; และส่งข้อมูลที่ตรวจแล้วผ่าน MQTT ไปยัง Home Assistant เพื่อใช้วิเคราะห์ปลายน้ำ [12] การเพิ่มกรอบ e-Senses ตามข้อเสนอแนะของอาจารย์ช่วยแสดงว่าระบบกลางอาจรับข้อมูลชนิดอื่นในอนาคต โดยการศึกษาระยะนี้ยังไม่ครอบคลุมการสร้าง e-Nose หรือ e-Skin

ข้อมูลซื้อสินค้าในครัวเรือนอยู่ในใบเสร็จที่มีรูปแบบ ภาษา และคุณภาพภาพถ่ายต่างกัน การแปลงภาพเป็นรายการสินค้าแบบมีโครงสร้างต้องผ่านการตรวจจับเอกสาร การรู้จำข้อความ และการสกัดฟิลด์ ความผิดพลาดของขั้นต้นอาจส่งต่อถึงผล JSON และการวิเคราะห์ปลายน้ำ จึงต้องวัดทั้งความแม่นยำและทรัพยากรที่ใช้ในแต่ละชั้น

รายงานทบทวนวรรณกรรม 32 หน้าของโครงงานใช้บทความวิจัย 12 ฉบับ โดย 11 ฉบับสังเคราะห์ในสามมิติ คือ quantization และฮาร์ดแวร์ การสร้างผลลัพธ์แบบมีโครงสร้าง และบริบทบ้านอัจฉริยะ/IoT ส่วน P5 สนับสนุนแนวคิดข้ามศาสตร์ งานที่ทบทวนให้แนวทางวัด trade-off
แต่ยังไม่ตอบโดยตรงว่าขั้นตอนเหล่านี้ทำงานร่วมกันได้ดีเพียงใดกับใบซื้อสินค้าจริงภาษาไทย/อังกฤษภายใต้ทรัพยากรจำกัด ช่องว่างนี้กล่าวเฉพาะชุดวรรณกรรมที่ทบทวน ไม่ใช่ข้อสรุปว่าไม่มีงานอื่นศึกษาเรื่องเดียวกัน [1–3, 12]

ผลนำร่องล่าสุดรับภาพ 124 ไฟล์ เหลือภาพไม่ซ้ำระดับไฟล์ 113 ภาพ และคัดภาพผู้สมัครใบซื้อสินค้ามีรายการ 59 ภาพ โมเดล YOLOv8n บน PC ได้ mAP@0.5 เท่ากับ 0.928 ในภาพตรวจ 10 ภาพจากชุดแรก และ 0.237 ในภาพส่งเพิ่ม 6 ภาพซึ่งกันไว้ทดสอบโมเดลเดิมโดยไม่ฝึกเพิ่ม ภาพชุดหลังต่างฉากด้วย
จึงยังแยกสาเหตุของคะแนนที่ต่างกันไม่ได้ ต้องเพิ่มภาพและตรวจกรอบอ้างอิงก่อนสรุปประสิทธิภาพของระบบ [4]

3 วัตถุประสงค์ของโครงงาน

(1) ออกแบบกรอบสถาปัตยกรรม e-Senses และกระบวนการสามชั้น ได้แก่ การรับรู้และสกัดข้อมูล การประมวลผลเฉพาะถิ่น และการใช้งานในระบบบ้านอัจฉริยะ โดยใช้ e-Eye เป็นกรณีศึกษาระยะแรก

(2) พัฒนาต้นแบบแปลงภาพใบซื้อสินค้าเป็นข้อมูล JSON ที่ตรวจสอบย้อนหลังได้ และวัดความผิดพลาดของการตรวจจับ OCR และการสกัดข้อมูลทั้งรายชั้นและปลายทาง

(3) เปรียบเทียบผลของโมเดลขนาดเล็ก ระดับ quantization และการบังคับรูปแบบ JSON ต่อความถูกต้อง เวลา และหน่วยความจำภายใต้ทรัพยากรจำกัด โดยเริ่มบน PC และตรวจการส่งออกโมเดลสำหรับ RK3588

(4) ออกแบบการส่งข้อมูลที่ผ่านการตรวจแล้วสู่ระบบบ้านอัจฉริยะ และกำหนดข้อมูลเพิ่มเติมที่จำเป็นต่อการประเมินปริมาณคงเหลือหรืออัตราการใช้สินค้า ก่อนทดลองบนอุปกรณ์จริงเมื่อมีความพร้อม

4 ทฤษฎีและผลงานวิจัยที่เกี่ยวข้อง

4.1 การประมวลผลเฉพาะถิ่นและ trade-off

การลด precision ของโมเดลช่วยลดภาระทรัพยากร แต่ต้องประเมินความแม่นยำร่วมกับเวลาและพลังงาน ไม่อาจเลือกจากขนาดไฟล์เพียงอย่างเดียว Husom และคณะศึกษาการอนุมาน quantized LLM บนอุปกรณ์ edge ขณะที่ Giedra และคณะเสนอการประเมินหลายตัวชี้วัดบนระบบที่มีทรัพยากรจำกัด [1, 2] งาน ShadowNPU ศึกษาการแบ่งงานระหว่างหน่วยประมวลผลบนอุปกรณ์ [17]
ในโครงงานนี้การเปรียบเทียบจะยึดงานสกัดใบซื้อสินค้าไทย/อังกฤษแทน benchmark ทั่วไป

รายงานทบทวนวรรณกรรมเดิมเปรียบเทียบงานกลุ่ม quantization/hardware โดยชี้ว่าผลจาก Raspberry Pi, Jetson และ GPU ระดับศูนย์ข้อมูลถ่ายโอนมาใช้กับเครื่องเป้าหมายโดยตรงไม่ได้ งานของ Giedra และคณะเสนอให้พิจารณาความแม่นยำร่วมกับพลังงานในแต่ละชุด model-configuration ส่วน ShadowNPU เป็นแนวคิดเรื่องการแบ่งภาระระหว่างตัวเร่งกับ CPU [2, 12, 17] โครงงานจึงจะบันทึกรุ่นโมเดล ระดับบีบอัด และเครื่องที่ทดสอบคู่กับผล JSON เสมอ; การแบ่งงานแบบ ShadowNPU ยังเป็นแนวทางศึกษา มิใช่ผลการพัฒนาของโครงงาน

4.2 การสร้างผลลัพธ์แบบมีโครงสร้าง

SGLang ศึกษาการเร่งการทำงานของโปรแกรมภาษาแบบมีโครงสร้าง [3] และ llama.cpp รองรับ grammar/JSON schema บางส่วน [5] โครงงานจะเปรียบเทียบการสร้าง JSON แบบเปิดกับแบบบังคับ schema โดยวัดทั้งความถูกต้องของโครงสร้างและค่าฟิลด์ เพราะ JSON ที่ parse ได้ยังอาจมีรายการสินค้าหรือราคาไม่ตรงหลักฐาน

รายงานทบทวนวรรณกรรมเดิมใช้แนวคิด grammar-constrained decoding และ jump-forward ของ SGLang เป็นแรงจูงใจให้ลดงานที่ต้องสร้างโทเคนซ้ำของคีย์ JSON [3, 12] ระยะทดลองจะเริ่มจากความสามารถของ runtime ที่เลือกจริง แล้วตรวจ parse rate, schema-valid rate และความถูกต้องของค่าแยกกัน; ยังไม่อ้างว่าจะพอร์ตกลไก jump-forward หรือได้ความเร็วเท่าระบบในบทความ

4.3 การเชื่อมระบบบ้านอัจฉริยะและข้อมูลปลายน้ำ

รายงานทบทวนวรรณกรรมเดิมสังเคราะห์งานบ้านอัจฉริยะสามแนวทาง: ตัวแทน LLM สำหรับควบคุมบ้าน [14], การพยากรณ์ข้อมูล IoT แบบอนุกรมเวลา [15] และเกตเวย์ ESP32 สำหรับการเชื่อมต่อ [16] โครงงานนี้จะส่งเฉพาะข้อมูลรายการซื้อที่ผ่านการตรวจแล้วผ่าน MQTT และแยกข้อมูลการซื้อเข้าออกจากข้อมูลปริมาณคงเหลือ เพราะใบเสร็จเพียงอย่างเดียวไม่บอกอัตราการใช้จริง [12]

สถาปัตยกรรมเดิมระบุ Home Assistant, MQTT, การพยากรณ์แบบ Adaptive Holt-Winters และ dashboard เป็นปลายทางที่ต้องศึกษาความเป็นไปได้ [12, 15, 16] ขั้นแรกจะทดสอบข้อความจำลองที่มี provenance และสถานะตรวจสอบได้ ส่วน burn rate ต้องมีอนุกรมเวลาของปริมาณคงเหลือหรือการใช้จริงเพียงพอก่อน จึงยังไม่เป็นผลส่งมอบที่รับรองจากภาพใบเสร็จชุดปัจจุบัน

4.4 การตรวจจับเอกสารและเครื่องมือส่งออก

mAP@0.5 ใช้วัดการตรวจจับที่เกณฑ์ IoU 0.5 ส่วน mAP@0.5:0.95 ใช้หลายเกณฑ์ [6] สำหรับภาษาไทย Tesseract มีข้อมูลภาษา tha และ EasyOCR รองรับ th ร่วมกับ en [7, 8] Rockchip แยก RKNN Toolkit2 สำหรับการแปลง/ทดสอบโมเดลภาพและ RKLLM สำหรับการแปลง/รันโมเดลภาษา จึงต้องตรวจความเข้ากันได้ของแต่ละส่วนแยกกัน [9, 10]

4.5 การสังเคราะห์จากรายงานทบทวนวรรณกรรมสู่ตัวแปรวิจัย

ตารางที่ 1 ฐานวรรณกรรมเดิมและการใช้ในเค้าโครงนี้

มิติเดิม	แนวคิดที่คงไว้	การทดสอบในโครงงาน
Quantization / hardware	Husom, Giedra, ShadowNPU [1, 2, 17]	ความถูกต้อง JSON คู่กับเวลา RAM และพลังงานเมื่อมีบอร์ด
Structured output	SGLang และ grammar [3, 5]	เปิด/ปิดการบังคับ schema และตรวจค่าจริง
Smart home / IoT	Rivkin, Sawalha, Serepas [14–16]	ส่ง JSON ที่ตรวจแล้วผ่าน MQTT; ประเมินข้อมูลที่ต้องมีเพิ่มก่อน burn rate

4.6 สาระจากงานวิจัย 12 ฉบับที่ใช้เป็นฐาน

รายงานเดิมคัดบทความจาก 57 รายการจนเหลือ 12 ฉบับ โดย 11 ฉบับสังเคราะห์กรอบสามมิติและ P5 เป็นหลักฐานสนับสนุนข้ามศาสตร์ งานแต่ละฉบับตอบคำถามต่างกัน จึงพิจารณาทั้งวิธีทดลอง ฮาร์ดแวร์ ผลลัพธ์ที่วัด และขอบเขตการนำมาใช้กับระบบใบซื้อสินค้า ไม่รวมคะแนนจากต่างแพลตฟอร์มเป็นผลของโครงงาน [12]

Cai และคณะเสนอ Edge-LLM ซึ่งให้อุปกรณ์ปลายทางทำงานร่วมกับคลาวด์ พร้อม adaptive quantization การแคช และการจัดลำดับงาน ผลการศึกษาช่วยชี้ว่าการจัดการภาระงานเป็นส่วนของการออกแบบ edge inference แต่แนวทาง hybrid ไม่ตรงกับเป้าหมายการประมวลผลหลักในบ้านของโครงงานนี้ จึงใช้เป็นจุดเปรียบเทียบเชิงสถาปัตยกรรม มิใช่วิธีที่นำมาติดตั้งตรงตัว [18]

Husom และคณะประเมิน quantized LLM หลายแบบบน Raspberry Pi 4 โดยวัดความถูกต้อง ความหน่วง และพลังงานด้วยเครื่องมือวัดภายนอก งานนี้ให้แนวทางบันทึกคุณภาพผลลัพธ์คู่กับต้นทุนการประมวลผล โครงงานจะนำแนวคิดการวัดแบบจับคู่มาใช้กับงานสกัดฟิลด์จริง แต่ไม่ใช้ผลความแม่นยำจากชุดทดสอบเดิมแทนความแม่นยำของชื่อสินค้าภาษาไทย [1]

Moon และคณะเสนอระบบ Hybe ที่ประสาน GPU กับ NPU สำหรับบริบทยาวมาก
งานนี้แสดงผลของการแบ่งงานระหว่างขั้น prefill และ decode
แต่ทดลองบนฮาร์ดแวร์ที่ต่างจากบอร์ดเป้าหมายอย่างมาก โครงงานจึงใช้เป็นกรณีเปรียบเทียบขอบเขตฮาร์ดแวร์
ไม่ตั้งสมมติฐานว่าความเร็วจากงานดังกล่าวจะเกิดซ้ำบน RK3588 [19]

Yin และคณะพัฒนา ShadowNPU ที่เน้น NPU และแบ่งการคำนวณตามความไวของส่วนต่าง ๆ
ต่อความละเอียดเชิงตัวเลข แนวคิดนี้ช่วยตั้งคำถามว่าการบีบอัดทั้งโมเดลให้เท่ากันเหมาะสมหรือไม่ อย่างไรก็ตาม
การทดลองอยู่บนอุปกรณ์และ runtime คนละชนิด
ระยะแรกของโครงงานจะตรวจความเข้ากันได้และผลรวมของโมเดลก่อนพิจารณาการแบ่งเลเยอร์ขั้นสูง [17]

Oloko-Oba และคณะทบทวน edge machine learning สำหรับอุปกรณ์สวมใส่ทางการแพทย์
และชี้ปัญหาคุณภาพข้อมูลภาคสนามกับการรับส่งข้อมูลออกนอกอุปกรณ์ แม้ไม่ใช่งานเอกสารซื้อสินค้า
รายงานเดิมใช้เพื่อสนับสนุนหลักการออกแบบที่ให้ข้อมูลอยู่ใกล้แหล่งกำเนิดและต้องตรวจความน่าเชื่อถือของข้อมูล
จริง ไม่ใช่หลักฐานว่าระบบบ้านของโครงงานให้ผลเท่ากับระบบการแพทย์ [20]

Zheng และคณะสำรวจการออกแบบและรัน edge LLM ตั้งแต่การลดขนาดโมเดลถึงการใช้ฮาร์ดแวร์ต่างระดับ
งานสำรวจช่วยจัดหมวดตัวเลือกของ runtime และข้อจำกัดหน่วยความจำ
แต่ไม่ได้ให้คะแนนทดลองสำหรับใบซื้อสินค้า
โครงงานใช้เป็นกรอบเลือกแบบจำลองและบันทึกเหตุผลที่ตัดตัวเลือกซึ่งไม่เหมาะกับเครื่อง [21]

Giedra และคณะเปรียบเทียบแบบจำลองที่บีบอัดหลายขนาดบนอุปกรณ์ edge โดยรายงานความแม่นยำ ความเร็ว
และพลังงานร่วมกัน การใช้ชุดค่าคอนฟิกที่ระบุชัดเจนมีประโยชน์ต่อการออกแบบตารางทดลองของโครงงาน
แต่ชุดทดสอบทั่วไปของบทความไม่ทดสอบ JSON จากใบเสร็จ
จึงต้องเพิ่มเกณฑ์ความถูกต้องของโครงสร้างและค่าฟิลด์ที่เฉพาะกับงานนี้ [2]

Zheng และคณะเสนอ SGLang สำหรับโปรแกรมภาษาแบบมีโครงสร้าง
และใช้การจัดการแคชกับการถอดรหัสที่รู้ข้อจำกัดของรูปแบบ ข้อค้นพบเป็นแรงจูงใจให้ทดลอง grammar-
constrained output เพราะคีย์ของ JSON หลายช่องคงที่ อย่างไรก็ตาม
ความเร็วในบทความมาจากระบบและฮาร์ดแวร์อีกระดับ จึงต้องวัด runtime ที่ใช้งานจริงแยกต่างหาก [3]

Hu และคณะเสนอ mPLUG-DocOwl2 สำหรับความเข้าใจเอกสารหลายหน้าแบบ OCR-free ด้วยการบีบอัด
visual token งานนี้เป็นแนวทางทางเลือกต่อ pipeline ที่แยก YOLO และ OCR
แต่ขนาดงานและทรัพยากรต่างจากกรณีใบซื้อสินค้าบนเครื่องจำกัด โครงงานจะบันทึกข้อดีข้อเสียของแนวทาง
OCR-free ในการอภิปราย โดยไม่เพิ่มเป็นตัวแปรหลักก่อนพิสูจน์ baseline ที่วางไว้ [22]

Rivkin และคณะศึกษาตัวแทน LLM สำหรับสั่งงานบ้านอัจฉริยะ โดยวัดการทำงานสำเร็จของคำสั่ง องค์ประกอบการเชื่อมข้อมูลกับระบบบ้านเกี่ยวข้องกับชั้นประยุกต์ใช้ของโครงงาน แต่การสั่งอุปกรณ์ไม่เท่ากับการสกัดชื่อสินค้าและราคา จึงต้องวัดความถูกต้องต้นทางก่อนส่งข้อความไปยัง Home Assistant [14]

Sawalha และ Al-Naymat เสนอ Adaptive Holt-Winters สำหรับข้อมูล IoT ตามเวลา วิธีดังกล่าวเป็นฐานของการพยากรณ์ปลายน้ำตามรายงานเดิม แต่ใบเสร็จแสดงการซื้อเข้าเท่านั้น การประเมินอัตราการใช้จะทำได้เมื่อมีปริมาณคงเหลือหรือเหตุการณ์การใช้ตามช่วงเวลาที่เพียงพอและตรวจความถูกต้องแล้ว [15]

Serepas และคณะออกแบบเกตเวย์ ESP32 สำหรับบ้านอัจฉริยะที่รองรับ MQTT และ REST API งานนี้ช่วยกำหนดจุดเชื่อมข้อมูลระหว่างเครื่องประมวลผลกับระบบบ้าน แต่การมีเกตเวย์ที่ส่งข้อความสำเร็จไม่ได้ยืนยันความถูกต้องของ JSON ที่ส่ง โครงงานจะแยกตัววัดการส่งข้อความออกจากตัววัดเนื้อหาสินค้า [16]

4.7 ข้อสอดคล้อง ข้อแตกต่าง และข้อจำกัดการถ่ายโอนผล

งานกลุ่ม quantization เห็นร่วมกันว่าการใช้ทรัพยากรลดลงต้องพิจารณาคู่กับคุณภาพผลลัพธ์ ไม่ควรเลือกระดับบีบอัดจากขนาดไฟล์อย่างเดียว [1, 2, 17–19] อย่างไรก็ตาม ผลของแต่ละงานมาจาก Raspberry Pi, Jetson, สมาร์ตโฟน หรือระบบระดับศูนย์ข้อมูล ซึ่งมีหน่วยความจำ ตัวเร่ง และ runtime ต่างกัน ดังนั้นผลเวลาและพลังงานไม่สามารถแทนค่าบนบอร์ดที่โครงงานจะใช้ในอนาคตได้ [12]

งานด้าน structured output และความเข้าใจเอกสารมีจุดต่างในระดับวิธีรับข้อมูล SGLang เน้นขั้นสร้างข้อความที่มีโครงสร้างหลังมีอินพุตข้อความแล้ว ส่วน mPLUG-DocOwl2 พยายามทำความเข้าใจเอกสารจากภาพโดยตรง [3, 22] สถาปัตยกรรมเดิมเลือก YOLO⟶OCR⟶LLM เพื่อให้ตรวจข้อผิดพลาดรายชั้นได้ การเลือกนี้ต้องพิสูจน์ด้วยผลจริง เพราะการแยกชั้นอาจเพิ่มเวลาและส่งต่อความผิดพลาดจาก OCR ได้ [12]

งานบ้านอัจฉริยะวัดความสำเร็จคนละปลายทาง: Rivkin วัดการควบคุมอุปกรณ์, Serepas วัดการเชื่อมต่อเกตเวย์ และ Sawalha วัดการพยากรณ์อนุกรมเวลา [14–16] ไม่มีตัววัดใดแทนความถูกต้องของการอ่านใบซื้อสินค้าต้นทางได้ จึงต้องกำหนด provenance และสถานะตรวจสอบของแต่ละรายการก่อนส่งต่อ ผลสังเคราะห์นี้จำกัดเฉพาะ 12 บทความที่คัดในรายงานเดิม [12]

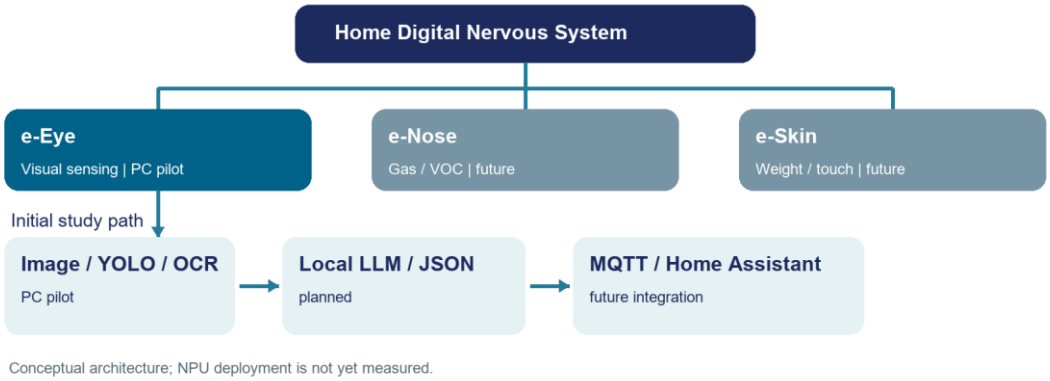
4.8 ช่องว่างวิจัยและผลต่อการออกแบบการทดลอง

ช่องว่างจากชุดวรรณกรรมที่ทบทวนคือการขาดผลวัดร่วมกันของการตรวจเอกสาร การอ่านข้อความ การสร้าง JSON และการใช้งานปลายน้ำภายใต้ข้อจำกัดทรัพยากรเดียวกันในบริบทใบซื้อสินค้าไทย/อังกฤษ [12]
ข้อความนี้เป็นข้อสรุปภายในชุดวรรณกรรมที่คัด ไม่ใช่การยืนยันว่าไม่มีงานวิจัยอื่นในโลกศึกษาเรื่องดังกล่าว
จึงกำหนดหน่วยวิเคราะห์เป็นธุรกรรมที่ตรวจความซ้ำแล้ว เปรียบเทียบผลแบบมีเฉลยของแต่ละชั้น
และใช้ข้อมูลเดียวกันกับทุกค่าคอนฟิกของโมเดล การรายงานจะแยกกรณีข้อความ OCR
จากภาพจริงกับข้อความเฉลยที่ป้อนให้โมเดลภาษา เพื่อเห็นความผิดพลาดที่เกิดในขั้นภาพ/ข้อความและขั้นสร้าง JSON ตามลำดับ การวัดเวลารายชั้นพร้อม end-to-end ทำให้ระบุต้นทุนของขั้นที่เพิ่มขึ้นได้
ชั้นปลายน้ำจะทดสอบการรับข้อความที่ผ่านการตรวจแล้วโดยใช้ข้อมูลจำลองและบันทึกผลการรับส่งแยกจากความถูกต้องของรายการสินค้า
ส่วนการพยากรณ์อัตราการใช้ไม่อยู่ในผลนำร่องจนกว่าจะมีข้อมูลคงเหลือหรือการใช้ตามเวลาเพียงพอ
ขอบเขตนี้รักษาแนวคิด Home Assistant และ Adaptive Holt-Winters จากรายงานเดิม
พร้อมหลีกเลี่ยงการสรุปเกินข้อมูลที่มี [12, 15, 16]

5 วิธีดำเนินการวิจัย

5.1 สถาปัตยกรรมรวมและผลนำร่องที่มีแล้ว

ภาพที่ 1 ขยายสถาปัตยกรรมสามชั้นจากรายงานทบทวนวรรณกรรมเดิม ให้เห็น e-Senses
ของบ้านและเส้นทางศึกษาระยะแรก ชั้นรับรู้ใช้ e-Eye รับภาพใบซื้อสินค้าจากภาพถ่ายก่อน; การรับจาก IP Camera ตามแผนเดิมยังไม่ได้ทดสอบ ตรวจกรอบเอกสารด้วย YOLO และอ่านด้วย OCR
ชั้นประมวลผลจะใช้โมเดลภาษาขนาดเล็กที่เลือก quantization ตามผลวัด สกัด JSON พร้อมตรวจ schema และค่าจากหลักฐาน ก่อนส่งต่อชั้นประยุกต์ใช้ผ่าน MQTT/Home Assistant เมื่อข้อมูลพร้อม ส่วน e-Nose และ e-Skin ยังเป็นโหนดแนวคิดสำหรับระยะต่อเนื่อง [12]



ภาพที่ 1 กรอบสถาปัตยกรรม e-Senses และเส้นทางศึกษา e-Eye ระยะแรก (ออกแบบโดยผู้วิจัย)

ปัจจุบันฝึก YOLOv8n ด้วย PC CPU และตรวจ OCR แบบ spot-check เท่านั้น RKNN Toolkit2 บน PC แปลง ONNX เป็น RKNN เป้าหมาย RK3588 แบบไม่ quantize และรัน inference ได้หนึ่งภาพ ยังไม่มีการประเมิน JSON/LLM แบบมีเฉลยตรวจซ้ำหรือการวัดบนบอร์ด การตรวจเพิ่มพบว่าภาพส่งเพิ่มทั้ง 6 ใบมีตัวหนังสือหมุนข้าง เมื่อลองหมุนภาพและกรอบเฉลยให้ตรงโดยไม่ฝึกเพิ่ม mAP@0.5 ของ 6 ภาพเปลี่ยนจาก 0.237 เป็น 0.714 อีกด้านหนึ่งการหมุน 7 ภาพที่อ่านตรงในชุดแรกไป 90 องศาทำให้คะแนนเปลี่ยนจาก 0.995 เป็น 0.492 ผลแบบจับคู่นี้ชี้ความไวต่อการหมุนเฉพาะชุดเล็ก ยังไม่พิสูจน์สาเหตุเดียวของคะแนนต่างระหว่างชุด [4, 9]

ตารางที่ 2 ผลนำร่องและขอบเขตการตีความ

รายการ	ผล ณ 17 ต.ค. 2569	ข้อจำกัด
ข้อมูล	124 ไฟล์ / 113 ไม่ซ้ำ / 59 ผู้สมัคร	ภาพไม่เท่ากับธุรกรรมอิสระ
YOLOv8n PC	38 ฝึก / 10 ตรวจ; mAP@0.5 0.928	ฉากเดิมคล้ายกัน; label รอตรวจซ้ำ
ชุดต่างฉาก	6 ภาพ; mAP@0.5 0.237	กลุ่มเล็ก; ยังไม่ใช่ final test
EasyOCR	3 ภาพ; spot-check วันที่/ยอด 4/6	ตรวจคนรอบเดียว; ไม่ใช่ CER
RKNN PC	ONNX ⟶ RKNN ⟶ PC inference สำเร็จ	ไม่ใช่ benchmark NPU จริง

5.2 ชุดข้อมูลและเฉลยอ้างอิง

ใช้เฉพาะใบซื้อสินค้าที่มองเห็นรายการสินค้า จำนวน และราคาเป็นชุดหลัก
เอกสารชำระเงินหรือใบค่าหอเก็บเป็นชุดเสริมหรือทดสอบชนิดเอกสาร ไม่ปะปนกับคะแนนสกัดรายการสินค้า 59 ภาพปัจจุบันเป็นผู้สมัคร; จะรวมภาพที่ถ่ายซ้ำและเอกสารคู่เป็นกลุ่มธุรกรรมก่อนแบ่งชุดฝึก/ตรวจ/ทดสอบ เพื่อไม่ให้ข้อมูลใกล้ซ้ำข้ามชุด เป้าหมายระยะถัดไปคือเพิ่มความหลากหลายของร้าน ฉาก แสง มุม และอุปกรณ์ถ่าย และขยายเป็นอย่างน้อย 100 ธุรกรรมอิสระหากการเก็บข้อมูลและเวลาทำได้

การตรวจชื่อสินค้าเบื้องต้นในภาพผู้สมัคร 59 ภาพพบว่า ถอดชื่อครบครั้งแรก 12 ภาพ ถอดไม่ครบ 45 ภาพ โดย 28 ภาพมีช่วงชื่อที่อ่านได้แน่ชัดและ 17 ภาพยังไม่มีช่วงชื่อที่ยืนยันได้ อีก 2 ภาพไม่มีบรรทัดชื่อสินค้า ตัวเลขอักษรจากส่วนที่อ่านได้ยังใช้แทนสัดส่วนภาษาของทั้งชุดไม่ได้ และยังไม่มีผู้ตรวจซ้ำ

เฉลยแต่ละภาพจะประกอบด้วยกรอบเอกสาร ข้อความอ้างอิง และ JSON schema คงที่: transaction_date, merchant, items[{name, quantity, unit, unit_price, line_total}], grand_total, currency ตามไฟล์ receipt_schema.json ทุกคีย์ต้องปรากฏ และกำหนด null สำหรับข้อมูลที่ไม่ปรากฏในเอกสาร สถานะอ่านไม่ออกและสถานะตรวจยืนยันบันทึกใน manifest แยกจากผลสกัด เพื่อแยกข้อมูลที่ไม่มีออกจากข้อมูลที่ยังอ่านไม่ได้ จะให้ผู้วิจัยสองคนตรวจเฉลยแยกกันแล้วแก้ข้อขัดแย้งร่วมกัน พร้อมบันทึก version, กลุ่มธุรกรรม และเหตุผลการตัดภาพออก
การวัดมุมเอียงละเอียดต้องกำหนดแนวอ้างอิงของกระดาษหรือบรรทัด
ส่วนสัดส่วนตัวอักษรไทย/อังกฤษจะนับจากข้อความเฉลยที่ตรวจแล้ว ไม่ใช้ OCR ดิบเป็นค่าจริง

5.3 การทดลองและตัวชี้วัด

การตรวจจับใช้กรอบ receipt_region หนึ่งบริเวณต่อภาพเท่าที่นิยามอนุญาต รายงาน mAP@0.5, mAP@0.5:0.95, precision, recall และสัดส่วนกรอบคะแนนสูงสุดที่ IoU≥0.5 แยกฉากเดิมกับฉากใหม่ พร้อมรายงานจำนวนภาพและช่วงความไม่แน่นอนเมื่อขนาดชุดทดสอบเหมาะสม การตรวจ OCR เปรียบเทียบอย่างน้อย EasyOCR กับ Tesseract บนภาพและการ crop เดียวกัน ใช้ CER หลังประกาศกฎ normalize Unicode/ช่องว่าง และวัดความถูกต้องวันที่ ยอดรวม และบรรทัดสินค้าแยกจาก CER [6–8]

การสกัด JSON ใช้ข้อความ OCR เดียวกันในแต่ละเงื่อนไข และใช้ข้อความเฉลยแทน OCR อีกชุดหนึ่งเพื่อแยกความผิดพลาดต้นทาง
เปรียบเทียบอย่างน้อยสองโมเดลขนาดเล็กที่ตรวจสิทธิและความเข้ากันได้แล้ว × สองระดับ quantization × เปิด/ปิด constrained decoding ภายใต้ prompt, schema, seed และขีดจำกัดโทเคนเดียวกัน ตัวชี้วัดหลักคือ parse rate, schema-valid rate, exact-match รายฟิลด์, ความคลาดเคลื่อนจำนวนเงิน และความครบของรายการสินค้า ตัวชี้วัดทรัพยากรคือเวลา end-to-end, เวลาแต่ละขั้น, peak RAM และขนาดโมเดล รายงานผลตามธุรกรรมและใช้การสุ่มซ้ำแบบจัดกลุ่มธุรกรรมเพื่อประมาณช่วงความไม่แน่นอน ไม่ตีความความต่างเล็กน้อยจากภาพใกล้ซ้ำว่าเป็นหลักฐานอิสระ

ตัวให้คะแนนเบื้องต้นตรวจ schema ก่อนให้คะแนน และตรวจทุกฟิลด์ใน receipt_schema.json โดยปรับข้อความเป็น Unicode NFC และตัดช่องว่างหัวท้าย เปรียบเทียบตัวเลขตามค่า จับคู่รายการที่ตรงทุกฟิลด์ก่อน แล้วจึงจับคู่ชื่อที่เหลือแบบหนึ่งต่อหนึ่งด้วย SequenceMatcher ที่เกณฑ์ 0.6 ฟิลด์ผิดนับทั้ง false positive และ false negative รายการเกินลด precision และรายการขาดลด recall ผล exact-match ต้องตรงทุกฟิลด์และไม่มีรายการเกินหรือขาด ผลที่ไม่ผ่าน schema หรือไม่มีไฟล์คำตอบนับเป็นความล้มเหลว วิธีนี้ใช้กับเฉลยที่ตรวจครบแล้วเท่านั้น ภาพที่ยังถอดไม่ครบจะแยกรายงานจำนวนและไม่ใช้ null กลบส่วนที่อ่านไม่ได้ ปัจจุบันตัวให้คะแนนผ่านการทดสอบด้วยข้อมูลสมมติ ยังไม่มีผลประเมินโมเดล JSON จริง

ตารางที่ 3 จุดตัดสินใจของการทดลอง

ขั้น	เปรียบเทียบ	เกณฑ์ตัดสินหลัก
ตรวจจับ	ฉากเดิม / ต่างฉาก	mAP และกรอบสูงสุด IoU≥0.5
OCR	EasyOCR / Tesseract	CER และความถูกต้องของฟิลด์
LLM	โมเดล × quantization × grammar	schema validity / field accuracy / RAM / latency

ขั้น	เปรียบเทียบ	เกณฑ์ตัดสินหลัก
ส่งออก	ONNX / RKNN PC; RKLLM เมื่อพร้อม	ผ่าน conversion และผลเลขสมเหตุสมผล

5.4 การจำลองบน PC และการตรวจบนอุปกรณ์ในอนาคต

ระยะปัจจุบันใช้ PC เป็นฐานวัดและใช้ SDK เพื่อตรวจการแปลงโมเดลสำหรับเป้าหมาย RK3588 โดยบันทึกเวอร์ชันเครื่องมือ โมเดล ค่าพารามิเตอร์ และข้อมูลทดสอบ การจำกัด thread/RAM บน PC เป็นเพียงการศึกษาความไวต่อทรัพยากร ไม่ใช่การจำลองเวลา NPU แบบ cycle-accurate และไม่ใช้แทนการวัดพลังงานจริง [9, 10]

สเปกอ้างอิงสำหรับการขอยืมภายหลังคือ Radxa ROCK 5B หรือบอร์ดเทียบเท่าที่ใช้ RK3588, RAM 16 GB, ที่เก็บข้อมูลอย่างน้อย 64 GB, Linux image ที่มี NPU driver และ RKNN/RKLLM runtime ที่เข้ากันได้ พร้อมไฟเลี้ยงและการระบายความร้อน หากคณะมีรุ่น 8 GB จะประเมินขนาดโมเดลอีกครั้ง สเปกนี้เป็นกรอบคัดเลือก ไม่ใช่รายการจัดซื้อหรือผลทดสอบ อุปกรณ์จริงต้องยืนยันเวอร์ชัน SDK และความสามารถ constrained decoding ก่อนกำหนดวิธีทดลองบน NPU [9–11, 13]

5.5 การเชื่อมต่อปลายน้ำและความเป็นส่วนตัว

เมื่อ JSON ผ่านการตรวจแล้วจึงทดสอบส่งข้อความจำลองผ่าน MQTT ไปยังระบบบ้านอัจฉริยะ โดยแยกคะแนนความถูกต้องของข้อมูลต้นทางออกจากการส่งข้อความ ตามฐานรายงานทบทวนวรรณกรรมเดิมจะพิจารณา dashboard และวิธีพยากรณ์อนุกรมเวลา เช่น Adaptive Holt-Winters เมื่อมีข้อมูลปริมาณคงเหลือหรือการใช้จริงหลายช่วงเวลา ใบเสร็จบอกเพียงการซื้อเข้า จึงยังไม่อ้างผล burn rate จากชุดปัจจุบัน [12, 15, 16]

ภาพต้นฉบับ 124 ไฟล์และ manifest ได้เผยแพร่ใน repository ของโครงงานแล้ว ณ 18 ต.ค. 2569 การใช้ข้อมูลต่อไปต้องตรวจและปกปิดชื่อ เบอร์โทร เลขสมาชิก ที่อยู่ และข้อมูลการชำระเงินก่อนนำไปเผยแพร่เพิ่มเติม ส่วน OCR ดิบและเฉลยที่ยังตรวจไม่ครบเก็บในพื้นที่ทำงานส่วนตัว หากจะเก็บข้อมูลจากผู้เข้าร่วมหรือประเมินอัตราการแก้ไขโดยมนุษย์ ให้หารืออาจารย์และกระบวนการจริยธรรมของคณะก่อนเริ่มขั้นนั้น

5.6 การไหลของข้อมูลและจุดตรวจสอบแต่ละชั้น

ข้อมูลนำเข้าหนึ่งหน่วยเป็นภาพที่ผูกกับรหัสธุรกรรม เมื่อระบบตรวจพบกรอบเอกสารจะบันทึกพิกัด คะแนนความเชื่อมั่น และเวอร์ชันโมเดลก่อน crop ภาพเข้าสู่ OCR ข้อความที่ได้จะเก็บทั้งรูปดิบและรูปที่ผ่านการจัดรูปแบบ โดยไม่เขียนทับต้นฉบับ ขั้นสกัด JSON จะอ้างรหัสภาพและบริเวณข้อความที่ใช้ยืนยันค่าฟิลด์ การบันทึกดังกล่าวทำให้ตรวจย้อนจากรายการสินค้ากลับไปยังภาพได้และแยกจุดผิดพลาดของแต่ละชั้น

ก่อนส่งข้อมูลไป MQTT จะตรวจว่า JSON parse ได้ ตรง schema และผ่านกฎพื้นฐาน เช่น ยอดรวมเป็นตัวเลขที่อนุญาตและรายการมีชื่อหรือสถานะอ่านไม่ออก สำหรับฟิลด์ที่ไม่มีหลักฐานจะใช้ null หรือสถานะรอตรวจ ไม่ใช้โมเดลเติมค่าด้วยการเดา ข้อความที่ส่งออกจะมีรหัสธุรกรรม เวลาประมวลผล และสถานะยืนยันเพื่อไม่ให้ dashboard ตีความรายการที่ยังไม่ตรวจเป็นข้อมูลจริง

การทดลองจะบันทึกจำนวนรายการที่ตกหล่นในแต่ละจุด ได้แก่ ภาพที่หากรอบไม่พบ ข้อความที่ OCR อ่านไม่ได้ JSON ที่ parse หรือ schema ไม่ผ่าน และฟิลด์ที่ผ่านรูปแบบแต่ค่าผิดจากเฉลย ผล end-to-end จะนับความสำเร็จจากภาพต้นทางถึงรายการ JSON ที่ตรวจตรงเฉลย ไม่ใช้ค่า mAP ของตัวตรวจจับแทนคุณภาพปลายทาง

5.7 การเปรียบเทียบแบบจำลองและความเที่ยงตรงของผล

การเปรียบเทียบระดับ quantization จะตรึงภาพ ชุดฝึก/ตรวจ เฉลย prompt และ schema ไว้เหมือนกันทุกเงื่อนไข เริ่มด้วย baseline ที่ไม่บังคับรูปแบบ แล้วเปิด grammar ใน runtime เดียวกันเพื่อแยกผลของข้อจำกัดโครงสร้าง จากนั้นจึงเปรียบเทียบขนาดหรือระดับบีบอัดภายใต้ขีดจำกัดหน่วยความจำเดียวกัน หาก runtime ใดไม่รองรับ grammar หรือโมเดลที่เลือก จะบันทึกว่าเป็นเงื่อนไขที่ทดสอบไม่ได้ แทนการเติมคะแนนประมาณ [1–3, 5]

การวัดทรัพยากรบน PC จะเก็บสภาพแวดล้อม รุ่น CPU/RAM เวอร์ชันไลบรารี จำนวน thread และเวลา warm-up ก่อนจับเวลาหลายรอบต่อเงื่อนไข รายงานค่ามัธยฐานและการกระจายของ latency แยกการโหลดโมเดลออกจากเวลาประมวลผลต่อภาพ ส่วนพลังงานจะรายงานเฉพาะเมื่อมีเครื่องมือวัดที่ระบุวิธีสอบเทียบได้ ไม่ใช้ค่า TDP หรือเวลาคูณกำลังไฟสมมติเป็นพลังงานที่วัดจริง [1, 2]

ความเสี่ยงต่อความเที่ยงตรงของผลรวมถึงภาพใกล้ซ้ำระหว่างชุดฝึกกับชุดทดสอบ ความต่างของฉากและทิศตัวหนังสือ ชื่อสินค้าที่อ่านไม่ครบ และเฉลยที่ยังไม่มีผู้ตรวจคนที่สอง จึงต้องจัดกลุ่มธุรกรรมก่อนแบ่งข้อมูล เก็บกลุ่มฉากใหม่ไว้ต่างหาก ตรวจเฉลยสองรอบ และรายงานจำนวนตัวอย่างของทุกคะแนน ผลนำร่องปัจจุบันใช้เพื่อเลือกประเด็นทดลองต่อ ไม่ใช้ยืนยันสมรรถนะทั่วไปของระบบ

5.8 ลำดับส่งมอบตามสถาปัตยกรรมเดิม

ผลส่งมอบระยะแรกคือชุดข้อมูลที่ตรวจชนิดและธุรกรรมซ้ำ คู่มือทำเฉลย และ baseline ของ YOLO/OCR บน PC
ระยะที่สองคือการสกัด JSON และตารางผลเปรียบเทียบ schema/ค่าฟิลด์/ทรัพยากร
ระยะที่สามคือการตรวจข้อความ MQTT และ dashboard ด้วยข้อมูลที่ผ่านการตรวจ
ก่อนพิจารณาข้อมูลคงเหลือเพื่อประเมินอัตราการใช้ หากได้รับบอร์ดและ runtime ที่เข้ากันได้
จะเพิ่มผลวัดอุปกรณ์จริงเป็นระยะถัดไป แผนนี้สืบจาก roadmap
เจ็ดระยะในรายงานเดิมแต่ปรับสถานะตามหลักฐานปัจจุบัน [12]

6 ขอบเขตและข้อจำกัดของการวิจัย

ขอบเขตเชิงสถาปัตยกรรมครอบคลุม e-Senses และกระบวนการสามชั้นตามภาพที่ 1
ขอบเขตการทดลองหลักระยะแรกใช้ภาพใบซื้อสินค้าภาษาไทย/อังกฤษเพื่อตรวจจับ OCR และสกัด JSON บน PC
พร้อมตรวจความเข้ากันได้ของ RKNN/RKLLM ตามความพร้อมของเครื่องมือ e-Nose, e-Skin, กล้อง IP
แบบเรียลไทม์ และระบบบ้านอัจฉริยะเต็มรูปแบบเป็นส่วนต่อยอด ยังไม่มีบอร์ดสำหรับทดสอบ RK3588 จริง
จึงไม่รวมผล NPU ในผลนำร่อง

ข้อจำกัดปัจจุบันคือข้อมูลหลายภาพอาจมาจากธุรกรรมเดียวกัน label ตรวจโดยผู้ช่วยและต้องให้ผู้วิจัยตรวจซ้ำ
จำนวนทดสอบต่างฉากยังเล็ก และเฉลยข้อความ/JSON ยังไม่ครบ จึงไม่รายงาน CER, field accuracy
หรือข้อสรุปด้าน NPU จากหลักฐานปัจจุบัน

7 สถานที่ทำวิจัย

ดำเนินการเตรียมข้อมูล ฝึกและทดสอบเบื้องต้นบนคอมพิวเตอร์ส่วนตัวของผู้จัดทำและสภาพแวดล้อม PC/WSL
ที่บันทึกเวอร์ชันไว้ ภาพต้นฉบับและ manifest มีสำเนาใน repository ของโครงงาน ส่วนผล OCR
และเฉลยระหว่างตรวจเก็บในพื้นที่ทำงานส่วนตัว
สถานที่ทดสอบบอร์ดจริงจะกำหนดภายหลังร่วมกับอาจารย์ที่ปรึกษาเมื่อมีอุปกรณ์

8 ประโยชน์ที่คาดว่าจะได้รับ

(1) ได้กรอบสถาปัตยกรรม e-Senses
และข้อกำหนดการส่งข้อมูลระหว่างชั้นที่ใช้พัฒนาระบบบ้านอัจฉริยะในระยะต่อไป

(2) ได้ชุดข้อมูลและเฉลยที่ตรวจสอบย้อนหลังได้สำหรับใบซื้อสินค้าไทย/อังกฤษ
พร้อมข้อกำหนดการแบ่งชุดตามธุรกรรม

(3) ได้หลักฐานว่าแต่ละขั้นของ e-Eye ผิดพลาดตรงไหน โดยเฉพาะเมื่อฉากภาพเปลี่ยน และมีวิธีประเมิน JSON ที่แยกความถูกต้องโครงสร้างจากเนื้อหา

(4) ได้ข้อมูล trade-off บน PC ที่ช่วยคัดแบบจำลองและกำหนดการทดลองบนฮาร์ดแวร์จริงอย่างมีเหตุผล โดยไม่สับสนผลจำลองกับ NPU

9 แผนและระยะเวลาดำเนินการ

Implementation Roadmap เจ็ดระยะในรายงานทบทวนวรรณกรรมเดิมยังเป็นแผนแม่บท: (1) ทบทวนวรรณกรรมและสถาปัตยกรรมเสร็จแล้ว (2) ต้นแบบ YOLO/OCR เริ่มนำร่องบน PC (3) Local LLM และ JSON (4) MQTT/Home Assistant และการวิเคราะห์ปลายน้ำ (5) เก็บและประเมินข้อมูลนำร่อง (6) จริยธรรมสำหรับการศึกษากับผู้ใช้เมื่อเกี่ยวข้อง และ (7) ประเมิน trade-off แบบครบระบบ [12] ตารางต่อไปแตกงานระยะ PC ที่ทำได้ก่อนมีบอร์ด โดยระยะ 3–7 ยังไม่ใช่ผลการดำเนินงานที่สำเร็จแล้ว

ตารางที่ 4 แผนดำเนินงานระยะ PC นับจากการรับรองเค้าโครง

ช่วง	กิจกรรม	ผลส่งมอบ
สัปดาห์ 1	ตรวจประเภทภาพ/กลุ่มธุรกรรมและ label	manifest และ split ที่ตรวจซ้ำ
สัปดาห์ 2–3	ทำเฉลยข้อความและ JSON สองรอบ	gold set พร้อมคู่มือ annotation
สัปดาห์ 3–4	เปรียบเทียบ OCR และปรับตรวจจับข้ามฉาก	CER / field metrics / detection metrics
สัปดาห์ 4–5	ทดลองโมเดลภาษาและ constrained output บน PC	ตารางความแม่นยำ เวลา และ RAM
สัปดาห์ 6	ทวน RKNN/RKLLM PC-side และเขียนผล	รายงานข้อจำกัดและขั้นทดสอบบอร์ด

หลังระยะ PC หากมีบอร์ดยืมและการอนุมัติที่เกี่ยวข้อง จึงย้ายโมเดลที่เข้ากันได้ไปวัด latency, RAM และพลังงานจริงบนอุปกรณ์ โดยคงชุดทดสอบและเวอร์ชันโมเดลไว้เทียบกับ PC
กิจกรรมนี้เป็นระยะต่อเนื่องภายหลังการศึกษาเบื้องต้น

10 งบประมาณ

ระยะศึกษาเบื้องต้นใช้คอมพิวเตอร์ พื้นที่เก็บข้อมูล และซอฟต์แวร์ที่มีอยู่ จึงไม่มีรายการจัดซื้อในระยะนี้ การทดสอบบอร์ด RK3588 จะเริ่มเมื่อได้รับอุปกรณ์ยืมจากคณะ หากต้องจัดหาอุปกรณ์เพิ่มเติม จะสำรวจรุ่น ราคา และความเข้ากันได้ก่อนเสนอรายการงบประมาณ

11 เอกสารอ้างอิง

[1] Husom, E. J., et al. (2025). Sustainable LLM inference for edge AI: Evaluating quantized LLMs for energy efficiency, output accuracy, and inference latency. ACM Transactions on Internet of Things, 6(4), Article 28. https://doi.org/10.1145/3767742

[2] Giedra, H., et al. (2026). Benchmarking large language model inference on limited-resource edge systems. Electronics, 15(11), 2451. doi:10.3390/electronics15112451.

[3] Zheng, L., et al. (2024). SGLang: Efficient execution of structured language model programs. Advances in Neural Information Processing Systems, 37, 62557-62583. https://doi.org/10.52202/079017-2000

[4] ณัชพล เพ็งพล และ ธนบดี เริ่มรักสกุล. (2569). ผลนำร่อง e-Eye บน PC ณ วันที่ 17 ตุลาคม 2569. บันทึกผลภายในโครงงาน. https://github.com/natchapolp-glitch/Capstone-Project/blob/main/ass5_ready_evidence.md

[5] ggml-org. (2026). GBNF guide, llama.cpp. https://github.com/ggml-org/llama.cpp/tree/master/grammars

[6] Ultralytics. (2026). YOLO performance metrics. https://docs.ultralytics.com/guides/yolo-performance-metrics/

[7] Tesseract OCR. (2026). Data files and language support. https://github.com/tesseract-ocr/tessdata

[8] Jaided AI. (2026). EasyOCR. https://github.com/JaidedAI/EasyOCR

[9] Rockchip. (2026). RKNN Toolkit2. https://github.com/airockchip/rknn-toolkit2

[10] Rockchip. (2026). RKLLM. https://github.com/airockchip/rknn-llm

[11] Rockchip. (2022). RK3588 brief datasheet. https://www.rock-chips.com/a/en/products/RK35_Series/2022/0926/1660.html

[12] ณัชพล เพ็งพล และ ธนบดี เริ่มรักสกุล. (2569). การพัฒนาระบบประสาทส่วนกลางอัจฉริยะในที่พักอาศัยเพื่อสกัดและวิเคราะห์ข้อมูลห่วงโซ่อุปทานในครัวเรือนด้วยปัญญาประดิษฐ์ประมวลผลเฉพาะถิ่น. รายงานทบทวนวรรณกรรม 32 หน้า, เอกสารภายในโครงงาน.

[13] Radxa. (2026). ROCK 5B introduction and specifications. https://docs.radxa.com/en/rock5/rock5b/getting-started/introduction

[14] Rivkin, D., et al. (2025). AIoT smart home via autonomous LLM agents. IEEE Internet of Things Journal, 12(3), 2458-2472. https://doi.org/10.1109/JIOT.2024.3471904

[15] Sawalha, S., & Al-Naymat, G. (2025). An adaptive Holt-Winters model for seasonal forecasting of Internet of Things (IoT) data streams. IoT, 6(3), Article 39. https://doi.org/10.3390/iot6030039

[16] Serepas, F., et al. (2025). Lightweight embedded IoT gateway for smart homes based on an ESP32 microcontroller. Computers, 14(9), Article 391. https://doi.org/10.3390/computers14090391

[17] Yin, W., et al. (2026). ShadowNPU: System and algorithm co-design for NPU-centric on-device LLM inference. Proceedings of MobiSys 2026, 294-308. https://doi.org/10.1145/3745756.3809205

[18] Cai, F., Yuan, D., Yang, Z., & Cui, L. (2024). Edge-LLM: A collaborative framework for large language model serving in edge computing. In 2024 IEEE International Conference on Web Services (ICWS) (pp. 799–809). https://doi.org/10.1109/ICWS62655.2024.00099

[19] Moon, S., Cha, J., Park, H., & Kim, J.-Y. (2025). Hybe: GPU-NPU hybrid system for efficient LLM inference with million-token context window. In Proceedings of the 52nd Annual International Symposium on Computer Architecture (pp. 808–820). https://doi.org/10.1145/3695053.3731051

[20] Oloko-Oba, M., Esenogho, E., & Aruleba, K. (2026). From biosignals to bedside: A review of real-time edge machine learning for wearable health monitoring. Bioengineering, 13(5), 559. https://doi.org/10.3390/bioengineering13050559

[21] Zheng, Y., Chen, Y., Qian, B., Shi, X., Shu, Y., & Chen, J. (2025). A review on edge large language models: Design, execution, and applications. ACM Computing Surveys, 57(8), Article 209. https://doi.org/10.1145/3719664

[22] Hu, A., Xu, H., Zhang, L., Ye, J., Yan, M., Zhang, J., Jin, Q., Huang, F., & Zhou, J. (2025). mPLUG-DocOwl2: High-resolution compressing for OCR-free multi-page document understanding. In Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers) (pp. 5817–5834). https://doi.org/10.18653/v1/2025.acl-long.291

ลงชื่อ ..... (นายณัชพล เพ็งพล) ผู้เสนอโครงงาน

ลงชื่อ ..... (นายธนบดี เริ่มรักสกุล) ผู้เสนอโครงงาน

วันที่ 18 ตุลาคม 2569