การเสนอเค้าโครงโครงงานคอมพิวเตอร์

ภาควิชาวิทยาการคอมพิวเตอร์ คณะวิทยาศาสตร์ มหาวิทยาลัยขอนแก่น

นายณัชพล เพ็งพล รหัสนักศึกษา 673380267-4

นายธนบดี เริ่มรักสกุล รหัสนักศึกษา 673380270-5

นักศึกษาระดับปริญญาตรี หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์

อาจารย์ที่ปรึกษาโครงงาน ผศ.บุญทรัพย์ ไวคำ

หมายเลขโครงงาน SCS3-4 กลุ่มสอบ SCS3

1 ชื่อหัวข้อโครงงาน

ภาษาไทย

การพัฒนาระบบประสาทส่วนกลางอัจฉริยะในที่พักอาศัยเพื่อสกัดและวิเคราะห์ข้อมูลห่วงโซ่อุปทานในครัวเรือนด้วยปัญญาประดิษฐ์ประมวลผลเฉพาะถิ่น

ภาษาอังกฤษ DEVELOPMENT OF A LOCALIZED RESIDENTIAL INTELLIGENCE ENGINE FOR HOUSEHOLD SUPPLY-CHAIN ANALYTICS USING EDGE COMPUTING AND HOME NETWORK INFRASTRUCTURE

2 หลักการและเหตุผล

โครงงานเสนอระบบประสาทส่วนกลางอัจฉริยะในที่พักอาศัยที่รับข้อมูลจากประสาทสัมผัสดิจิทัลหลายชนิด หรือ e-Senses แล้วแปลงเป็นข้อมูลที่ตรวจสอบและใช้วิเคราะห์ได้ e-Eye รับภาพเอกสารซื้อสินค้า e-Nose อาจรับข้อมูลก๊าซหรือกลิ่น และ e-Skin อาจรับน้ำหนักหรือแรงสัมผัส ระยะแรกเลือก e-Eye เพื่อทำการทดลองที่มีข้อมูลจริง ส่วนโหนดอื่นยังเป็นส่วนขยายในกรอบระบบ ไม่ใช่ผลทดลองที่สำเร็จแล้ว

ฐานของข้อเสนอนี้คือสถาปัตยกรรมสามชั้นในรายงานทบทวนวรรณกรรมเดิม: รับภาพเอกสารจากกล้องหรือภาพถ่ายแล้วตรวจจับด้วย YOLO และอ่านด้วย OCR; ใช้ Local LLM ที่เลือกขนาดและระดับ quantization ให้เหมาะกับเครื่อง พร้อมควบคุมรูปแบบผลลัพธ์เป็น JSON; และส่งข้อมูลที่ตรวจแล้วผ่าน MQTT ไปยัง Home Assistant เพื่อใช้วิเคราะห์ปลายน้ำ [12] การเพิ่มกรอบ e-Senses ตามข้อเสนอแนะของอาจารย์ช่วยแสดงว่าระบบกลางอาจรับข้อมูลชนิดอื่นในอนาคต โดยการศึกษาระยะนี้ยังไม่ครอบคลุมการสร้าง e-Nose หรือ e-Skin

ข้อมูลซื้อสินค้าในครัวเรือนอยู่ในใบเสร็จที่มีรูปแบบ ภาษา และคุณภาพภาพถ่ายต่างกัน
การแปลงภาพเป็นรายการสินค้าแบบมีโครงสร้างต้องผ่านการตรวจจับเอกสาร การรู้จำข้อความ และการสกัดฟิลด์
ความผิดพลาดของขั้นต้นอาจส่งต่อถึงผล JSON และการวิเคราะห์ปลายน้ำ
จึงต้องวัดทั้งความแม่นยำและทรัพยากรที่ใช้ในแต่ละขั้น

รายงานทบทวนวรรณกรรม 32 หน้าของโครงงานใช้บทความวิจัย 12 ฉบับ โดย 11 ฉบับสังเคราะห์ในสามมิติ คือ quantization และฮาร์ดแวร์ การสร้างผลลัพธ์แบบมีโครงสร้าง และบริบทบ้านอัจฉริยะ/IoT ส่วน P5 สนับสนุนแนวคิดข้ามศาสตร์ งานที่ทบทวนให้แนวทางวัด trade-off
แต่ยังไม่ตอบโดยตรงว่าขั้นตอนเหล่านี้ทำงานร่วมกันได้ดีเพียงใดกับใบซื้อสินค้าจริงภาษาไทย/อังกฤษภายใต้ทรัพยากรจำกัด ช่องว่างนี้กล่าวเฉพาะชุดวรรณกรรมที่ทบทวน ไม่ใช่ข้อสรุปว่าไม่มีงานอื่นศึกษาเรื่องเดียวกัน [1–3, 12]

ผลนำร่องระยะแรกรับภาพ 124 ไฟล์ เหลือภาพไม่ซ้ำระดับไฟล์ 113 ภาพ และคัดภาพผู้สมัครใบซื้อสินค้ามีรายการ 59 ภาพ โมเดล YOLOv8n บน PC ได้ mAP@0.5 เท่ากับ 0.928 ในภาพตรวจ 10 ภาพจากชุดแรก และ 0.237 ในภาพส่งเพิ่ม 6 ภาพซึ่งกันไว้ทดสอบโมเดลเดิมโดยไม่ฝึกเพิ่ม ภาพชุดหลังต่างฉากด้วย
จึงยังแยกสาเหตุของคะแนนที่ต่างกันไม่ได้ ต้องเพิ่มภาพและตรวจกรอบอ้างอิงก่อนสรุปประสิทธิภาพของระบบ [4]
ผลเพิ่มเติมใช้ข้อความอ้างอิงหนึ่งรอบครบ 59 ภาพ เปรียบเทียบ OCR บนข้อความผ่านเกณฑ์ 24 ภาพ ทดลองรูปแบบ JSON ด้วย Local LLM และเชื่อมเดโมถึง Home Assistant บน PC โดยแสดงรายละเอียด ตัวหาร และข้อจำกัดในหัวข้อ 5.9–5.12 [23]

3 วัตถุประสงค์ของโครงงาน

(1) ออกแบบกรอบสถาปัตยกรรม e-Senses และกระบวนการสามชั้น ได้แก่ การรับรู้และสกัดข้อมูล การประมวลผลเฉพาะถิ่น และการใช้งานในระบบบ้านอัจฉริยะ โดยใช้ e-Eye เป็นกรณีศึกษาระยะแรก

(2) พัฒนาต้นแบบแปลงภาพใบซื้อสินค้าเป็นข้อมูล JSON ที่ตรวจสอบย้อนหลังได้ และวัดความผิดพลาดของการตรวจจับ OCR และการสกัดข้อมูลทั้งรายชั้นและปลายทาง

(3) เปรียบเทียบผลของโมเดลขนาดเล็ก ระดับ quantization และการบังคับรูปแบบ JSON ต่อความถูกต้อง เวลา และหน่วยความจำภายใต้ทรัพยากรจำกัด โดยเริ่มบน PC และตรวจการส่งออกโมเดลสำหรับ RK3588

(4) ออกแบบการส่งข้อมูลที่ผ่านการตรวจแล้วสู่ระบบบ้านอัจฉริยะ และกำหนดข้อมูลเพิ่มเติมที่จำเป็นต่อการประเมินปริมาณคงเหลือหรืออัตราการใช้สินค้า ก่อนทดลองบนอุปกรณ์จริงเมื่อมีความพร้อม

4 ทฤษฎีและผลงานวิจัยที่เกี่ยวข้อง

4.1 การประมวลผลเฉพาะถิ่นและ trade-off

การลด precision ของโมเดลช่วยลดภาระทรัพยากร แต่ต้องประเมินความแม่นยำร่วมกับเวลาและพลังงาน ไม่อาจเลือกจากขนาดไฟล์เพียงอย่างเดียว Husom และคณะศึกษาการอนุมาน quantized LLM บนอุปกรณ์ edge ขณะที่ Giedra และคณะเสนอการประเมินหลายตัวชี้วัดบนระบบที่มีทรัพยากรจำกัด [1, 2] งาน ShadowNPU ศึกษาการแบ่งงานระหว่างหน่วยประมวลผลบนอุปกรณ์ [17]
ในโครงงานนี้การเปรียบเทียบจะยึดงานสกัดใบซื้อสินค้าไทย/อังกฤษแทน benchmark ทั่วไป

รายงานทบทวนวรรณกรรมเดิมเปรียบเทียบงานกลุ่ม quantization/hardware โดยชี้ว่าผลจาก Raspberry Pi, Jetson และ GPU ระดับศูนย์ข้อมูลถ่ายโอนมาใช้กับเครื่องเป้าหมายโดยตรงไม่ได้ งานของ Giedra และคณะพิจารณาความแม่นยำและทรัพยากรตามสภาพแวดล้อมที่ทดลอง ส่วน ShadowNPU ใช้ sparse attention ร่วมกับ NPU และ CPU/GPU เพื่อลดภาระจากส่วน attention ที่ไวต่อ quantization [2, 12, 17] โครงงานจึงบันทึกรุ่นโมเดล ระดับบีบอัด และเครื่องที่ทดสอบคู่กับผล JSON เสมอ การออกแบบแบบ ShadowNPU ยังเป็นแนวทางศึกษา มิใช่ผลการพัฒนาของโครงงาน

4.2 การสร้างผลลัพธ์แบบมีโครงสร้าง

SGLang ศึกษาการเร่งการทำงานของโปรแกรมภาษาแบบมีโครงสร้าง [3] และ llama.cpp รองรับ grammar/JSON schema บางส่วน [5] โครงงานจะเปรียบเทียบการสร้าง JSON แบบเปิดกับแบบบังคับ schema โดยวัดทั้งความถูกต้องของโครงสร้างและค่าฟิลด์ เพราะ JSON ที่ parse
ได้ยังอาจมีรายการสินค้าหรือราคาไม่ตรงหลักฐาน

รายงานทบทวนวรรณกรรมเดิมใช้แนวคิด grammar-constrained decoding และ jump-forward ของ SGLang เป็นแรงจูงใจให้ลดงานที่ต้องสร้างโทเคนซ้ำของคีย์ JSON [3, 12] ระยะทดลองจะเริ่มจากความสามารถของ runtime ที่เลือกจริง แล้วตรวจ parse rate, schema-valid rate และความถูกต้องของค่าแยกกัน;
ยังไม่อ้างว่าจะพอร์ตกลไก jump-forward หรือได้ความเร็วเท่าระบบในบทความ

4.3 การเชื่อมระบบบ้านอัจฉริยะและข้อมูลปลายน้ำ

รายงานทบทวนวรรณกรรมเดิมสังเคราะห์งานบ้านอัจฉริยะสามแนวทาง: ตัวแทน LLM สำหรับควบคุมบ้าน [14], การพยากรณ์ข้อมูล IoT แบบอนุกรมเวลา [15] และเกตเวย์ ESP32 สำหรับการเชื่อมต่อ [16]
โครงงานนี้จะส่งเฉพาะข้อมูลรายการซื้อที่ผ่านการตรวจแล้วผ่าน MQTT
และแยกข้อมูลการซื้อเข้าออกจากข้อมูลปริมาณคงเหลือ เพราะใบเสร็จเพียงอย่างเดียวไม่บอกอัตราการใช้จริง [12]

สถาปัตยกรรมเดิมระบุ Home Assistant, MQTT, การพยากรณ์แบบ Adaptive Holt-Winters และ dashboard เป็นปลายทางที่ต้องศึกษาความเป็นไปได้ [12, 15, 16] ระยะนี้เชื่อมผลจากภาพจริงไปยัง Home Assistant ในสภาพแวดล้อมทดลองแล้ว โดยบันทึกแหล่งที่มาและสถานะการยืนยัน
การวัดทางเทคนิคใช้การยืนยันอัตโนมัติและแยกจากความถูกต้องของเนื้อหา ส่วน burn rate
ต้องมีอนุกรมเวลาของปริมาณคงเหลือหรือการใช้จริงเพียงพอก่อน
จึงยังไม่เป็นผลส่งมอบที่รับรองจากภาพใบเสร็จชุดปัจจุบัน [23]

4.4 การตรวจจับเอกสารและเครื่องมือส่งออก

mAP@0.5 ใช้วัดการตรวจจับที่เกณฑ์ IoU 0.5 ส่วน mAP@0.5:0.95 ใช้หลายเกณฑ์ [6] สำหรับภาษาไทย Tesseract มีข้อมูลภาษา tha และ EasyOCR รองรับ th ร่วมกับ en [7, 8] Rockchip แยก RKNN Toolkit2 สำหรับการแปลง/ทดสอบโมเดลภาพและ RKLLM สำหรับการแปลง/รันโมเดลภาษา
จึงต้องตรวจความเข้ากันได้ของแต่ละส่วนแยกกัน [9, 10]

4.5 การสังเคราะห์จากรายงานทบทวนวรรณกรรมสู่ตัวแปรวิจัย

ตารางที่ 1 ฐานวรรณกรรมเดิมและการใช้ในเค้าโครงนี้

มิติเดิม	แนวคิดที่คงไว้	การทดสอบในโครงงาน
Quantization / hardware	Husom, Giedra, ShadowNPU [1, 2, 17]	ความถูกต้อง JSON คู่กับเวลา RAM และพลังงานเมื่อมีบอร์ด
Structured output	SGLang และ grammar [3, 5]	เปิด/ปิดการบังคับ schema และตรวจค่าจริง
Smart home / IoT	Rivkin, Sawalha, Serepas [14–16]	ส่ง JSON ที่ตรวจแล้วผ่าน MQTT; ประเมินข้อมูลที่ต้องมีเพิ่มก่อน burn rate

4.6 สาระจากงานวิจัย 12 ฉบับที่ใช้เป็นฐาน

รายงานเดิมคัดบทความจาก 57 รายการจนเหลือ 12 ฉบับ โดย 11 ฉบับสังเคราะห์กรอบสามมิติและ P5 เป็นหลักฐานสนับสนุนข้ามศาสตร์ งานแต่ละฉบับตอบคำถามต่างกัน จึงพิจารณาทั้งวิธีทดลอง ฮาร์ดแวร์ ผลลัพธ์ที่วัด และขอบเขตการนำมาใช้กับระบบใบซื้อสินค้า ไม่รวมคะแนนจากต่างแพลตฟอร์มเป็นผลของโครงงาน [12]

Cai และคณะเสนอ Edge-LLM เป็นกรอบการทำงานร่วมกันสำหรับให้บริการโมเดลภาษาขนาดใหญ่ในระบบ edge computing งานนี้ใช้เป็นฐานเปรียบเทียบการแบ่งภาระประมวลผลระหว่างองค์ประกอบของระบบ
กับแนวทางประมวลผลหลักภายในบ้านของโครงงาน
โดยยังไม่นำผลสมรรถนะของบทความมาอ้างแทนอุปกรณ์และข้อมูลของโครงงาน [18]

Husom และคณะประเมิน quantized LLM หลายแบบบน Raspberry Pi 4 โดยวัดความถูกต้อง ความหน่วง และพลังงานด้วยเครื่องมือวัดภายนอก งานนี้ให้แนวทางบันทึกคุณภาพผลลัพธ์คู่กับต้นทุนการประมวลผล
โครงงานจะนำแนวคิดการวัดแบบจับคู่มาใช้กับงานสกัดฟิลด์จริง
แต่ไม่ใช้ผลความแม่นยำจากชุดทดสอบเดิมแทนความแม่นยำของชื่อสินค้าภาษาไทย [1]

Moon และคณะเสนอระบบ Hybe ที่ประสาน GPU กับ NPU สำหรับบริบทยาวมาก
งานนี้แสดงผลของการแบ่งงานระหว่างขั้น prefill และ decode
แต่ทดลองบนฮาร์ดแวร์ที่ต่างจากบอร์ดเป้าหมายอย่างมาก โครงงานจึงใช้เป็นกรณีเปรียบเทียบขอบเขตฮาร์ดแวร์
ไม่ตั้งสมมติฐานว่าความเร็วจากงานดังกล่าวจะเกิดซ้ำบน RK3588 [19]

Yin และคณะพัฒนา ShadowNPU โดยใช้ sparse attention และการประสาน NPU กับ CPU/GPU
เพื่อลดภาระที่ต้องย้อนกลับไปคำนวณนอก NPU เนื่องจากความไวต่อ quantization
งานนี้ช่วยชี้ว่าข้อจำกัดของตัวดำเนินการและการจัดตารางคำนวณมีผลต่อประสิทธิภาพ
โครงงานใช้เป็นกรอบอภิปรายความเข้ากันได้ของ runtime โดยยังไม่ได้ติดตั้งเทคนิคดังกล่าวหรือทดสอบบน RK3588 [17]

Oloko-Oba และคณะทบทวน edge machine learning สำหรับอุปกรณ์สวมใส่ทางการแพทย์
และชี้ปัญหาคุณภาพข้อมูลภาคสนามกับการรับส่งข้อมูลออกนอกอุปกรณ์ แม้ไม่ใช่งานเอกสารซื้อสินค้า
รายงานเดิมใช้เพื่อสนับสนุนหลักการออกแบบที่ให้ข้อมูลอยู่ใกล้แหล่งกำเนิดและต้องตรวจความน่าเชื่อถือของข้อมูลจริง ไม่ใช่หลักฐานว่าระบบบ้านของโครงงานให้ผลเท่ากับระบบการแพทย์ [20]

Zheng และคณะสำรวจการออกแบบและรัน edge LLM ตั้งแต่การลดขนาดโมเดลถึงการใช้ฮาร์ดแวร์ต่างระดับ
งานสำรวจช่วยจัดหมวดตัวเลือกของ runtime และข้อจำกัดหน่วยความจำ
แต่ไม่ได้ให้คะแนนทดลองสำหรับใบซื้อสินค้า
โครงงานใช้เป็นกรอบเลือกแบบจำลองและบันทึกเหตุผลที่ตัดตัวเลือกซึ่งไม่เหมาะกับเครื่อง [21]

Giedra และคณะประเมินโมเดลที่บีบอัดหลายขนาด โดยวัดความถูกต้องบน PC
และวัดประสิทธิภาพการประมวลผลบน Jetson Orin Nano Super
การระบุแพลตฟอร์มและค่าคอนฟิกแยกกันมีประโยชน์ต่อการออกแบบการทดลองของโครงงาน
แต่ชุดทดสอบของบทความไม่ใช่การสกัด JSON จากใบเสร็จ จึงต้องวัดโครงสร้างและค่าฟิลด์เฉพาะงานเพิ่มเติม [2]

Zheng และคณะเสนอ SGLang สำหรับโปรแกรมภาษาแบบมีโครงสร้าง
และใช้การจัดการแคชกับการถอดรหัสที่รู้ข้อจำกัดของรูปแบบ ข้อค้นพบเป็นแรงจูงใจให้ทดลอง grammar-constrained output เพราะคีย์ของ JSON หลายช่องคงที่ อย่างไรก็ตาม
ความเร็วในบทความมาจากระบบและฮาร์ดแวร์อีกระดับ จึงต้องวัด runtime ที่ใช้งานจริงแยกต่างหาก [3]

Hu และคณะเสนอ mPLUG-DocOwl2 สำหรับความเข้าใจเอกสารหลายหน้าแบบ OCR-free ด้วยการบีบอัด visual token งานนี้เป็นแนวทางทางเลือกต่อ pipeline ที่แยก YOLO และ OCR
แต่ขนาดงานและทรัพยากรต่างจากกรณีใบซื้อสินค้าบนเครื่องจำกัด โครงงานจะบันทึกข้อดีข้อเสียของแนวทาง OCR-free ในการอภิปราย โดยไม่เพิ่มเป็นตัวแปรหลักก่อนพิสูจน์ baseline ที่วางไว้ [22]

Rivkin และคณะศึกษาตัวแทน LLM สำหรับสั่งงานบ้านอัจฉริยะ โดยวัดการทำงานสำเร็จของคำสั่ง
องค์ประกอบการเชื่อมข้อมูลกับระบบบ้านเกี่ยวข้องกับขั้นประยุกต์ใช้ของโครงงาน
แต่การสั่งอุปกรณ์ไม่เท่ากับการสกัดชื่อสินค้าและราคา จึงต้องวัดความถูกต้องต้นทางก่อนส่งข้อความไปยัง Home Assistant [14]

Sawalha และ Al-Naymat เสนอ Adaptive Holt-Winters สำหรับข้อมูล IoT ตามเวลา
วิธีดังกล่าวเป็นฐานของการพยากรณ์ปลายน้ำตามรายงานเดิม แต่ใบเสร็จแสดงการซื้อเข้าเท่านั้น
การประเมินอัตราการใช้จะทำได้เมื่อมีปริมาณคงเหลือหรือเหตุการณ์การใช้ตามช่วงเวลาที่เพียงพอและตรวจความถูกต้องแล้ว [15]

Serepas และคณะออกแบบเกตเวย์ ESP32 สำหรับบ้านอัจฉริยะที่รองรับ MQTT และ REST API
งานนี้ช่วยกำหนดจุดเชื่อมข้อมูลระหว่างเครื่องประมวลผลกับระบบบ้าน
แต่การมีเกตเวย์ที่ส่งข้อความสำเร็จไม่ได้ยืนยันความถูกต้องของ JSON ที่ส่ง
โครงงานจะแยกตัววัดการส่งข้อความออกจากตัววัดเนื้อหาสินค้า [16]

4.7 ข้อสอดคล้อง ข้อแตกต่าง และข้อจำกัดการถ่ายโอนผล

งานกลุ่ม quantization เห็นร่วมกันว่าการใช้ทรัพยากรลดลงต้องพิจารณาคู่กับคุณภาพผลลัพธ์
ไม่ควรเลือกระดับบีบอัดจากขนาดไฟล์อย่างเดียว [1, 2, 17–19] อย่างไรก็ตาม ผลของแต่ละงานมาจาก Raspberry Pi, Jetson, สมาร์ตโฟน หรือระบบระดับศูนย์ข้อมูล ซึ่งมีหน่วยความจำ ตัวเร่ง และ runtime ต่างกัน
ดังนั้นผลเวลาและพลังงานไม่สามารถแทนค่าบนบอร์ดที่โครงงานจะใช้ในอนาคตได้ [12]

งานด้าน structured output และความเข้าใจเอกสารมีจุดต่างในระดับวิธีรับข้อมูล SGLang เน้นขั้นสร้างข้อความที่มีโครงสร้างหลังมีอินพุตข้อความแล้ว ส่วน mPLUG-DocOwl2 พยายามทำความเข้าใจเอกสารจากภาพโดยตรง [3, 22] สถาปัตยกรรมเดิมเลือก YOLO⟶OCR⟶LLM เพื่อให้ตรวจข้อผิดพลาดรายชั้นได้ การเลือกนี้ต้องพิสูจน์ด้วยผลจริง เพราะการแยกชั้นอาจเพิ่มเวลาและส่งต่อความผิดพลาดจาก OCR ได้ [12]

งานบ้านอัจฉริยะวัดความสำเร็จคนละปลายทาง: Rivkin วัดการควบคุมอุปกรณ์, Serepas วัดการเชื่อมต่อเกตเวย์ และ Sawalha วัดการพยากรณ์อนุกรมเวลา [14–16] ไม่มีตัววัดใดแทนความถูกต้องของการอ่านใบซื้อสินค้าต้นทางได้ จึงต้องกำหนด provenance และสถานะตรวจสอบของแต่ละรายการก่อนส่งต่อ ผลสังเคราะห์นี้จำกัดเฉพาะ 12 บทความที่คัดในรายงานเดิม [12]

4.8 ช่องว่างวิจัยและผลต่อการออกแบบการทดลอง

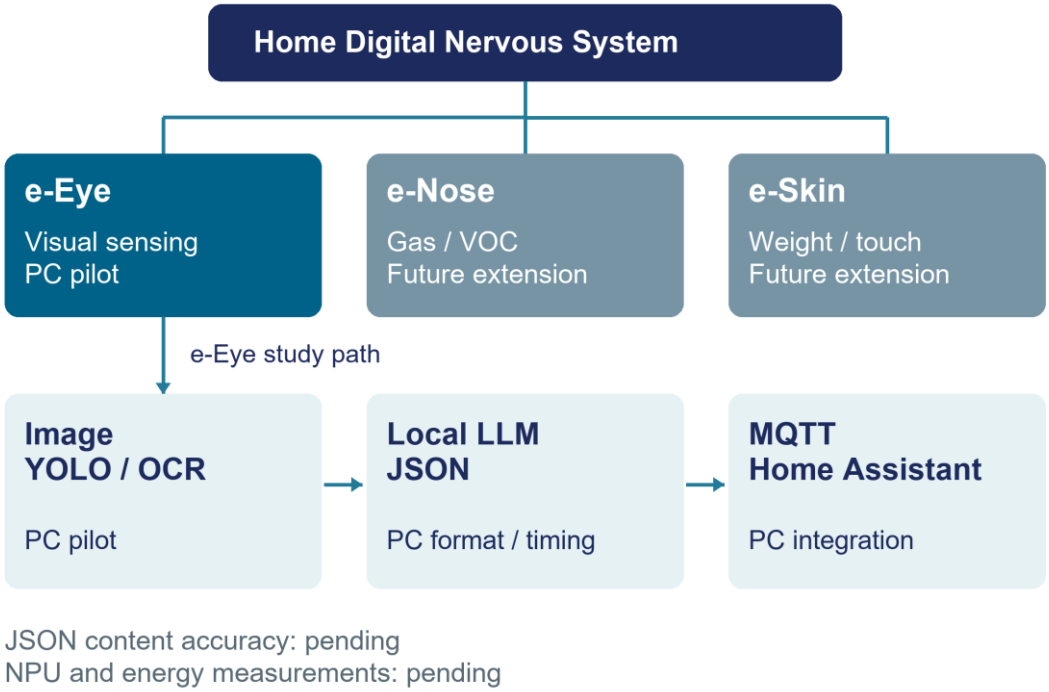
ช่องว่างจากชุดวรรณกรรมที่ทบทวนคือการขาดผลวัดร่วมกันของการตรวจเอกสาร การอ่านข้อความ การสร้าง JSON และการใช้งานปลายน้ำภายใต้ข้อจำกัดทรัพยากรเดียวกันในบริบทใบซื้อสินค้าไทย/อังกฤษ [12] ข้อความนี้เป็นข้อสรุปภายในชุดวรรณกรรมที่คัด ไม่ใช่การยืนยันว่าไม่มีงานวิจัยอื่นในโลกศึกษาเรื่องดังกล่าว จึงกำหนดหน่วยวิเคราะห์เป็นธุรกรรมที่ตรวจความซ้ำแล้ว เปรียบเทียบผลแบบมีเฉลยของแต่ละชั้น และใช้ข้อมูลเดียวกันกับทุกค่าคอนฟิกของโมเดล การรายงานจะแยกกรณีข้อความ OCR จากภาพจริงกับข้อความเฉลยที่ป้อนให้โมเดลภาษา เพื่อเห็นความผิดพลาดที่เกิดในขั้นภาพ/ข้อความและขั้นสร้าง JSON ตามลำดับ การวัดเวลารายชั้นพร้อม end-to-end ทำให้ระบุต้นทุนของขั้นที่เพิ่มขึ้นได้

ชั้นปลายน้ำแยกผลการรับส่งข้อความออกจากความถูกต้องของรายการสินค้า ปัจจุบันมีหลักฐานเชื่อมข้อมูลจากภาพจริงผ่าน MQTT ไปยัง Home Assistant โดยใช้การยืนยันอัตโนมัติในสภาพแวดล้อมทดลองและตรวจค่าที่ปลายทาง [23] ส่วนการพยากรณ์อัตราการใช้ยังไม่ได้ทดลอง เพราะยังไม่มีข้อมูลคงเหลือหรือการใช้ตามเวลาเพียงพอ ขอบเขตนี้รักษาแนวคิด Home Assistant และ Adaptive Holt-Winters จากรายงานเดิม [12, 15, 16]

5 วิธีดำเนินการวิจัย

5.1 สถาปัตยกรรมรวมและผลนำร่องที่มีแล้ว

ภาพที่ 1 ขยายสถาปัตยกรรมสามชั้นจากรายงานทบทวนวรรณกรรมเดิมให้เห็น e-Senses ของบ้าน ชั้นรับรู้ใช้ e-Eye รับภาพใบซื้อสินค้า ตรวจกรอบด้วย YOLO และอ่านข้อความด้วย OCR ชั้นประมวลผลใช้ Local LLM สกัด JSON และตรวจ schema ก่อนให้ผู้ใช้ตรวจยืนยัน ชั้นประยุกต์ใช้ส่งข้อมูลผ่าน MQTT ไปยัง Home Assistant ต้นแบบบน PC เชื่อมกระบวนการนี้ได้แล้วในสภาพแวดล้อมทดลอง ส่วน IP Camera, e-Nose และ e-Skin ยังเป็นส่วนขยายตามแผน [12, 23]



ภาพที่ 1 กรอบสถาปัตยกรรม e-Senses และเส้นทางศึกษา e-Eye ระยะแรก (ออกแบบโดยผู้วิจัย)

ผลนำร่องเดิมประกอบด้วย YOLOv8n บน PC การตรวจ EasyOCR แบบ spot-check และการแปลง ONNX เป็น RKNN เป้าหมาย RK3588 แบบไม่ quantize ซึ่งรัน inference ผ่าน SDK บน PC ได้หนึ่งภาพ ภาพส่งเพิ่ม 6 ภาพมีตัวหนังสือหมุนข้าง เมื่อหมุนภาพและกรอบอ้างอิงให้ตรงโดยไม่ฝึกเพิ่ม mAP@0.5 เปลี่ยนจาก 0.237 เป็น 0.714 ส่วนการหมุน 7 ภาพที่อ่านตรงในชุดแรกไป 90 องศาทำให้คะแนนเปลี่ยนจาก 0.995 เป็น 0.492 ผลนี้แสดงความไวต่อการหมุนเฉพาะชุดเล็ก ผลทดลองเพิ่มเติมด้าน OCR, Local LLM และ MQTT รายงานในหัวข้อ 5.9–5.11 โดยยังไม่มีผลวัดบนบอร์ด [4, 9, 23]

ตารางที่ 2 ผลนำร่องและขอบเขตการตีความ

รายการ	ผล ณ 17 ต.ค. 2569	ข้อจำกัด
ข้อมูล	124 ไฟล์ / 113 ไม่ซ้ำ / 59 ผู้สมัคร	ภาพไม่เท่ากับธุรกรรมอิสระ
YOLOv8n PC	38 ฝึก / 10 ตรวจ; mAP@0.5 0.928	ฉากเดิมคล้ายกัน; label รอตรวจซ้ำ
ชุดต่างฉาก	6 ภาพ; mAP@0.5 0.237	กลุ่มเล็ก; ยังไม่ใช่ final test
EasyOCR	3 ภาพ; spot-check วันที่/ยอด 4/6	ตรวจคนรอบเดียว; ไม่ใช่ CER
RKNN PC	ONNX ⟶ RKNN ⟶ PC inference สำเร็จ	ไม่ใช่ benchmark NPU จริง

5.2 ชุดข้อมูลและเฉลยอ้างอิง

ใช้เฉพาะใบซื้อสินค้าที่มองเห็นรายการสินค้า จำนวน และราคาเป็นชุดหลัก
เอกสารชำระเงินหรือใบค่าหอเก็บเป็นชุดเสริมหรือทดสอบชนิดเอกสาร ไม่ปะปนกับคะแนนสกัดรายการสินค้า 59 ภาพปัจจุบันเป็นผู้สมัคร; จะรวมภาพที่ถ่ายซ้ำและเอกสารคู่เป็นกลุ่มธุรกรรมก่อนแบ่งชุดฝึก/ตรวจ/ทดสอบ เพื่อไม่ให้ข้อมูลใกล้ซ้ำข้ามชุด เป้าหมายระยะถัดไปคือเพิ่มความหลากหลายของร้าน ฉาก แสง มุม และอุปกรณ์ถ่าย และขยายเป็นอย่างน้อย 100 ธุรกรรมอิสระหากการเก็บข้อมูลและเวลาทำได้

การตรวจชื่อสินค้าเบื้องต้นใน 59 ภาพเคยแบ่งเป็นถอดชื่อครบครั้งแรก 12 ภาพ ถอดไม่ครบ 45 ภาพ และไม่มีบรรทัดชื่อสินค้า 2 ภาพ ตัวเลขนี้เป็นผลตรวจเฉพาะชื่อสินค้าในระยะก่อนหน้า ส่วนข้อมูลล่าสุดเป็นข้อความทุกบรรทัดที่ผู้จัดทำบันทึกหนึ่งรอบ 59 ภาพจากชุด 59 ภาพ จึงเป็นคนละขอบเขตการตรวจและใช้แทนกันไม่ได้ ยังไม่มีสัดส่วนภาษาไทย/อังกฤษของชื่อสินค้าที่รับรองครบทั้งชุด [4, 23]

ชุดข้อมูล 59 ภาพ มีข้อความอ้างอิงจากการตรวจหนึ่งรอบ 59 ภาพ โดยนายณัชพล เพ็งพลเป็นผู้บันทึก เก็บประวัติการแก้ไขและสถานะข้อความไม่ครบไว้ตามจริง ไม่มีภาพค้างบันทึกข้อความแล้ว การตรวจรอบนี้เน้นข้อความ จึงไม่รับรองช่อง JSON ที่เว้นว่างหรือมีค่าเริ่มต้นว่าเป็นข้อมูลไม่ปรากฏจริง schema กำหนด transaction_date, merchant, items[{name, quantity, unit, unit_price, line_total}], grand_total และ currency ส่วนสถานะอ่านไม่ออกเก็บในบันทึกประกอบ การวัดความถูกต้องของฟิลด์ยังค้างเพราะไม่มีเฉลย JSON ที่ตรวจครบ และไม่มีข้อกำหนดให้ผู้จัดทำกลับไปกรอกรอบสองในระยะนี้ [23]

5.3 การทดลองและตัวชี้วัด

การตรวจจับใช้กรอบ receipt_region ตามนิยามของชุดข้อมูล รายงาน mAP@0.5, mAP@0.5:0.95, precision, recall และสัดส่วนกรอบคะแนนสูงสุดที่ IoU≥0.5 แยกชุดและจำนวนภาพ การทดลอง OCR เปรียบเทียบ EasyOCR กับ Tesseract บนพิกเซลภาพ crop เดียวกัน ใช้ CER จากข้อความหนึ่งรอบหลังตัดเฉพาะป้ายอ้างอิง [cite: N] แล้วปรับ Unicode NFC และช่องว่างตามกฎที่บันทึกไว้ ผลนี้เป็นการเปรียบเทียบเชิงพรรณนา การวัดวันที่ ยอดรวม และรายการสินค้าแยกต่างหากยังต้องมีเฉลยฟิลด์ที่ตรวจครบ [6–8, 23]

การทดลอง Local LLM เปรียบเทียบ Qwen3 ขนาด 0.6B และ 1.7B ที่ Q8_0 และ Q4_K_M พร้อมเปิด/ปิด grammar ใช้ข้อความที่ผู้จัดทำบันทึกและข้อความ Tesseract ของภาพเดียวกัน ภายใต้ prompt, schema, seed และขีดจำกัดโทเคนคงที่ ตัวชี้วัดที่วัดได้ในระยะนี้คือ parse validity, schema validity, เวลา และ RSS ของกระบวนการโมเดล ส่วน exact match รายฟิลด์ ความคลาดเคลื่อนจำนวนเงิน และความครบของรายการยังไม่มีคะแนน เพราะไม่มีเฉลย JSON ที่ตรวจครบ การรันซ้ำใช้ศึกษาความแปรผันของเวลา ไม่เพิ่มจำนวนภาพหรือธุรกรรมอิสระ [23]

ตัวให้คะแนนเบื้องต้นตรวจ schema ก่อนให้คะแนน และตรวจทุกฟิลด์ใน receipt_schema.json โดยปรับข้อความเป็น Unicode NFC และตัดช่องว่างหัวท้าย เปรียบเทียบตัวเลขตามค่า จับคู่รายการที่ตรงทุกฟิลด์ก่อน แล้วจึงจับคู่ชื่อที่เหลือแบบหนึ่งต่อหนึ่งด้วย SequenceMatcher ที่เกณฑ์ 0.6 ฟิลด์ผิดนับทั้ง false positive และ false negative รายการเกินลด precision และรายการขาดลด recall ผล exact-match ต้องตรงทุกฟิลด์และไม่มีรายการเกินหรือขาด ผลที่ไม่ผ่าน schema หรือไม่มีไฟล์คำตอบนับเป็นความล้มเหลว วิธีนี้ใช้กับเฉลยที่ตรวจครบแล้วเท่านั้น ภาพที่ยังถอดไม่ครบจะแยกรายงานจำนวนและไม่ใช้ null กลบส่วนที่อ่านไม่ได้ ตัวให้คะแนนผ่านการทดสอบกรณี JSON ผิดรูปแบบและการจับคู่รายการด้วยข้อมูลทดสอบ ส่วนการรันโมเดลจริงมีผลตรวจ parse/schema และทรัพยากรแล้ว แต่ยังไม่ใช้ตัวให้คะแนนเนื้อหาจนกว่าจะมีเฉลยฟิลด์ครบ

ตารางที่ 3 จุดตัดสินใจของการทดลอง

ขั้น	เปรียบเทียบ	เกณฑ์ตัดสินหลัก
ตรวจจับ	ฉากเดิม / ต่างฉาก	mAP และกรอบสูงสุด IoU≥0.5
OCR	EasyOCR / Tesseract	CER และความถูกต้องของฟิลด์
LLM	โมเดล × quantization × grammar	schema validity / field accuracy / RAM / latency
ส่งออก	ONNX / RKNN PC; RKLLM เมื่อพร้อม	ผ่าน conversion และผลเลขสมเหตุสมผล

5.4 การจำลองบน PC และการตรวจบนอุปกรณ์ในอนาคต

ระยะปัจจุบันใช้ PC เป็นฐานวัดและใช้ SDK เพื่อตรวจการแปลงโมเดลสำหรับเป้าหมาย RK3588 โดยบันทึกเวอร์ชันเครื่องมือ โมเดล ค่าพารามิเตอร์ และข้อมูลทดสอบ การจำกัด thread/RAM บน PC เป็นเพียงการศึกษาความไวต่อทรัพยากร ไม่ใช่การจำลองเวลา NPU แบบ cycle-accurate และไม่ใช้แทนการวัดพลังงานจริง [9, 10]

สเปกอ้างอิงสำหรับการขอยืมภายหลังคือ Radxa ROCK 5B หรือบอร์ดเทียบเท่าที่ใช้ RK3588, RAM 16 GB, ที่เก็บข้อมูลอย่างน้อย 64 GB, Linux image ที่มี NPU driver และ RKNN/RKLLM runtime ที่เข้ากันได้ พร้อมไฟเลี้ยงและการระบายความร้อน หากคณะมีรุ่น 8 GB จะประเมินขนาดโมเดลอีกครั้ง สเปกนี้เป็นกรอบคัดเลือก ไม่ใช่รายการจัดซื้อหรือผลทดสอบ อุปกรณ์จริงต้องยืนยันเวอร์ชัน SDK และความสามารถ constrained decoding ก่อนกำหนดวิธีทดลองบน NPU [9–11, 13]

5.5 การเชื่อมต่อปลายน้ำและความเป็นส่วนตัว

ต้นแบบบน PC ส่งผลจากภาพจริงผ่าน YOLO, OCR และ Local LLM ไปยังหน้าตรวจยืนยัน ก่อนส่ง MQTT และแสดงยอดรวมกับจำนวนรายการใน Home Assistant การทดสอบการส่งใช้การยืนยันอัตโนมัติแทนมนุษย์เฉพาะในสภาพแวดล้อมทดลอง และตรวจว่าค่าที่ปลายทางตรงกับ JSON ที่ส่ง จึงเป็นหลักฐานการเชื่อมต่อ ไม่ใช่คะแนนความถูกต้องของสินค้าและไม่ใช่การศึกษาผู้ใช้ ตามฐานรายงานเดิมจะพิจารณา Adaptive Holt-Winters เมื่อมีข้อมูลคงเหลือหรือการใช้หลายช่วงเวลา ใบเสร็จบอกการซื้อเข้า จึงยังไม่มีผล burn rate [12, 15, 16, 23]

ภาพต้นฉบับ 124 ไฟล์และ manifest ได้เผยแพร่ใน repository ของโครงงานแล้ว ณ 18 ต.ค. 2569
การใช้ข้อมูลต่อไปต้องตรวจและปกปิดชื่อ เบอร์โทร เลขสมาชิก ที่อยู่
และข้อมูลการชำระเงินก่อนนำไปเผยแพร่เพิ่มเติม ส่วน OCR
ดิบและเฉลยที่ยังตรวจไม่ครบเก็บในพื้นที่ทำงานส่วนตัว
หากจะเก็บข้อมูลจากผู้เข้าร่วมหรือประเมินอัตราการแก้ไขโดยมนุษย์
ให้หารืออาจารย์และกระบวนการจริยธรรมของคณะก่อนเริ่มขั้นนั้น

5.6 การไหลของข้อมูลและจุดตรวจสอบแต่ละชั้น

ข้อมูลนำเข้าแต่ละภาพมีรหัสภาพและค่า SHA-256 สำหรับตรวจย้อนกลับ ระบบบันทึกกรอบเอกสาร
คะแนนความเชื่อมั่น การหมุนภาพ และรุ่นโมเดลก่อน crop เข้าสู่ OCR จากนั้นเก็บข้อความดิบ คำขอและคำตอบ
LLM พร้อม JSON ที่แยกได้โดยไม่เขียนทับต้นฉบับ ข้อมูลยืนยันและข้อความ MQTT
ผูกกับรหัสการประมวลผลและ event_id
ส่วนการรับรองกลุ่มธุรกรรมซ้ำและการผูกค่าทุกฟิลด์กับบริเวณข้อความยังไม่ครบ จึงไม่อ้างว่าทำ provenance
ระดับฟิลด์สำเร็จทั้งหมด

ก่อนส่ง MQTT ระบบตรวจ JSON ด้วย parser ที่ปฏิเสธคีย์ซ้ำและค่าตัวเลขที่ไม่ใช่จำนวนจำกัด จากนั้นตรวจ
schema และรับการยืนยันผ่านหน้าตรวจ ข้อกำหนดอนุญาต null
ในฟิลด์ที่ไม่มีข้อมูลและไม่บังคับว่าต้องมีรายการสินค้า การผ่าน schema
จึงไม่ได้พิสูจน์ความถูกต้องหรือความครบของเนื้อหา ข้อความส่งออกมี event_id
และสถานะยืนยันเพื่อป้องกันการตีความข้อมูลที่ยังรอตรวจเป็นรายการยืนยันแล้ว

การทดลองจะบันทึกจำนวนรายการที่ตกหล่นในแต่ละจุด ได้แก่ ภาพที่หากรอบไม่พบ ข้อความที่ OCR อ่านไม่ได้
JSON ที่ parse หรือ schema ไม่ผ่าน และฟิลด์ที่ผ่านรูปแบบแต่ค่าผิดจากเฉลย ผล end-to-end
จะนับความสำเร็จจากภาพต้นทางถึงรายการ JSON ที่ตรวจตรงเฉลย ไม่ใช้ค่า mAP
ของตัวตรวจจับแทนคุณภาพปลายทาง

5.7 การเปรียบเทียบแบบจำลองและความเที่ยงตรงของผล

การเปรียบเทียบระดับ quantization จะตรึงภาพ ชุดฝึก/ตรวจ เฉลย prompt และ schema
ไว้เหมือนกันทุกเงื่อนไข เริ่มด้วย baseline ที่ไม่บังคับรูปแบบ แล้วเปิด grammar ใน runtime
เดียวกันเพื่อแยกผลของข้อจำกัดโครงสร้าง
จากนั้นจึงเปรียบเทียบขนาดหรือระดับบีบอัดภายใต้ขีดจำกัดหน่วยความจำเดียวกัน หาก runtime ใดไม่รองรับ
grammar หรือโมเดลที่เลือก จะบันทึกว่าเป็นเงื่อนไขที่ทดสอบไม่ได้ แทนการเติมคะแนนประมาณ [1–3, 5]

การวัดทรัพยากรบน PC จะเก็บสภาพแวดล้อม รุ่น CPU/RAM เวอร์ชันไลบรารี จำนวน thread และเวลา warm-up ก่อนจับเวลาหลายรอบต่อเงื่อนไข รายงานค่ามัธยฐานและการกระจายของ latency แยกการโหลดโมเดลออกจากเวลาประมวลผลต่อภาพ ส่วนพลังงานจะรายงานเฉพาะเมื่อมีเครื่องมือวัดที่ระบุวิธีสอบเทียบได้ ไม่ใช้ค่า TDP หรือเวลาคูณกำลังไฟสมมติเป็นพลังงานที่วัดจริง [1, 2]

ข้อจำกัดของการทดลองคือข้อความอ้างอิงผ่านผู้บันทึกหนึ่งคนหนึ่งรอบและอาจมีการจัดรูปแบบใหม่ มีผล OCR ให้ดูระหว่างกรอก จึงไม่ใช่เฉลยอิสระที่ปิดบังคำตอบโมเดล ภาพใกล้ซ้ำและกลุ่มธุรกรรมยังไม่รับรองครบ การทดลองใช้ภาพเดิมและยังไม่มีชุดภาพต่างฉากใหม่ที่แยกจากการพัฒนา ผลจึงรายงานเชิงพรรณนาพร้อมตัวหาร ไม่สร้างช่วงความเชื่อมั่นที่สมมติว่าภาพทุกใบอิสระ และไม่สรุปสมรรถนะทั่วไปของระบบ [23]

5.8 ลำดับส่งมอบตามสถาปัตยกรรมเดิม

แผนส่งมอบยังสืบจาก roadmap เจ็ดระยะในรายงานเดิม ปัจจุบันมีชุดภาพและข้อความหนึ่งรอบ ผล OCR และผลรูปแบบ JSON บน PC รวมถึงหลักฐานเชื่อม MQTT/Home Assistant แล้ว งานที่ยังค้างคือการรับรองกรอบและกลุ่มธุรกรรม เฉลย JSON สำหรับคะแนนเนื้อหา และการทดสอบภาพต่างฉากใหม่ ก่อนสรุปประสิทธิภาพปลายทาง ส่วนการวิเคราะห์การใช้สินค้าและการวัดบน RK3588 เป็นระยะต่อเนื่องเมื่อมีข้อมูลและอุปกรณ์ [12, 23]

5.9 ผลเปรียบเทียบ OCR กับข้อความอ้างอิงหนึ่งรอบ

ประเมินข้อความที่บันทึก 59 ภาพโดยคงข้อมูลดิบทุกภาพไว้ พบ 24 ภาพผ่านเกณฑ์คัดเข้า และ 35 ภาพไม่ใช้คำนวณ CER เต็มข้อความ เนื่องจากมีข้อความอ่านไม่ชัด ตารางที่จัดใหม่ หมายเหตุที่ไม่ใช่ข้อความในภาพ ตัวเลขย่อ หรือขอบเขตข้อความไม่ครบ หนึ่งภาพอาจมีหลายเหตุผล เกณฑ์อัตโนมัติและการตรวจภาพเฉพาะกรณียังไม่รับรองว่าข้อความ 24 ภาพถูกต้องครบทุกตัวอักษร [23]

CER คำนวณจากจำนวนการแทนที่ ลบ และแทรกตัวอักษรในการจัดแนวข้อความ หารด้วยจำนวนตัวอักษรอ้างอิง โดยรวมตัวเศษและตัวหารทุกภาพสำหรับ micro CER หลังตัดเฉพาะป้ายอ้างอิง [cite: N] จากข้อความทั้งสองฝั่ง แล้วปรับ Unicode NFC และช่องว่างตามโค้ดประเมิน ค่าต่ำหมายถึงผิดพลาดน้อยและอาจเกินร้อยละ 100 ได้ ตัวหารชุดหลักมี 28,011 ตัวอักษร ทั้งสองเครื่องมือใช้ภาพ crop เดียวกันที่ตรวจค่าแฮชแล้ว ผล EasyOCR และ Tesseract จึงเทียบกันบนข้อความอ้างอิงชุดเดียวกัน [23]

ตารางที่ 4 ความผิดพลาดตัวอักษรเชิงพรรณนา (micro CER)

ข้อความอ้างอิง	ภาพ	ตัวอักษร	EasyOCR	Tesseract
ผ่านเกณฑ์คัดเข้า	24	28,011	82.36%	94.57%
ไม่แจ้งใช้ OCR ช่วย	23	26,678	82.99%	95.34%
แจ้งใช้ OCR ช่วย	1	1,333	69.77%	79.07%

EasyOCR มี CER ต่ำกว่า Tesseract บนชุดที่คัดนี้ แต่ทั้งสองยังมีความผิดพลาดสูง การไม่แจ้งใช้ OCR ช่วยเป็นเพียงข้อมูลที่ผู้บันทึกระบุ ไม่ยืนยันความเป็นอิสระของเฉลย
จึงยังไม่เลือกเครื่องมือจากผลนี้เพื่ออ้างประสิทธิภาพทั่วไป ผล Tesseract ใช้การรันใหม่ทั้ง 59 ภาพหลังแก้ตัวอ่าน TSV ที่เคยตีความเครื่องหมายอัญประกาศผิด ผลจากตัวอ่านรุ่นเดิมเก็บเป็นประวัติและไม่ใช้คำนวณคะแนนนี้ [23]

5.10 ผล Local LLM ด้านรูปแบบและต้นทุนการประมวลผล

ชุดทดลองเลือก 6 ภาพที่มี crop เอกสารเดียวจากลำดับความยาวข้อความก่อนดูผลโมเดล โดยตรึงการเลือกตั้งแต่มีข้อความบันทึก 55 ภาพ ข้อความของหกภาพนี้ไม่เปลี่ยนหลังเติมครบ 59 ภาพ การเลือกนี้ไม่ใช่การสุ่มตัวแทนทั้งชุด ใช้ข้อความผู้บันทึกและ Tesseract ของแต่ละภาพ เปรียบเทียบ Qwen3 0.6B/1.7B ที่ Q8_0/Q4_K_M เปิดและปิด grammar และรันซ้ำ 3 รอบ รวมแผน 288 ครั้ง บันทึกแล้ว 288 ครั้ง สถานะ ครบตามเมทริกซ์ การรันซ้ำไม่ใช่ภาพเพิ่มอีกชุด [23]

ใช้ PC Intel Core Ultra 7 155H, RAM ติดตั้งประมาณ 16 GB และ Windows 11 รัน llama.cpp b11714 บน CPU จำนวน 6 threads, context 8,192 tokens, output limit 2,048 tokens, temperature 0 และ seed 20261018 ปิด reasoning และ prompt cache พร้อม warm-up ก่อนจับเวลาแต่ละการโหลดโมเดล Q4_K_M แปลงต่อจาก Q8_0 ของผู้เผยแพร่ จึงไม่ใช่การเปรียบเทียบ quantization ที่เริ่มจาก BF16 เดียวกัน โมเดลและอินพุตมี SHA-256 พร้อมคำขอและคำตอบดิบ ผลเวลาอาจได้รับอิทธิพลจากงานเบื้องหลังบน PC [23]

ตารางที่ 5 ผล LLM จากข้อความผู้บันทึก

โมเดล	**บังคับ**	**Parse**	**Schema**	**วินาที[1]**	**GiB[2]**
0.6B-Q8_0	ปิด	12/18	3/18	16.16	1.58
0.6B-Q8_0	เปิด	18/18	18/18	22.16	1.62
0.6B-Q4_K_M	ปิด	18/18	18/18	13.26	1.55
0.6B-Q4_K_M	เปิด	18/18	18/18	13.30	1.55
1.7B-Q8_0	ปิด	18/18	18/18	35.62	2.71
1.7B-Q8_0	เปิด	18/18	18/18	32.59	2.72
1.7B-Q4_K_M	ปิด	18/18	18/18	27.41	2.67
1.7B-Q4_K_M	เปิด	18/18	18/18	26.23	2.67

[1] มัธยฐานเวลาต่อคำขอ รวมครั้งล้มเหลวที่บันทึก [2] RSS สูงสุดที่สุ่มวัดของกระบวนการโมเดล
แต่ละเงื่อนไขครบเมื่อมี 18 ครั้งจาก 6 ภาพ × 3 รอบ ค่า Parse/Schema เป็นจำนวนผ่านหารจำนวนครั้งที่รันจริง

ตารางที่ 6 ผล LLM จากข้อความ Tesseract

โมเดล	**บังคับ**	**Parse**	**Schema**	**วินาที[1]**	**GiB[2]**
0.6B-Q8_0	ปิด	15/18	0/18	7.43	1.58
0.6B-Q8_0	เปิด	18/18	18/18	9.45	1.63
0.6B-Q4_K_M	ปิด	18/18	18/18	7.09	1.55
0.6B-Q4_K_M	เปิด	18/18	18/18	7.15	1.55
1.7B-Q8_0	ปิด	3/18	3/18	20.68	2.71
1.7B-Q8_0	เปิด	18/18	18/18	21.30	2.72
1.7B-Q4_K_M	ปิด	12/18	12/18	14.40	2.67
1.7B-Q4_K_M	เปิด	15/18	15/18	13.58	2.67

[1] มัธยฐานเวลาต่อคำขอ รวมครั้งล้มเหลวที่บันทึก [2] RSS สูงสุดที่สุ่มวัดของกระบวนการโมเดล
แต่ละเงื่อนไขครบเมื่อมี 18 ครั้งจาก 6 ภาพ × 3 รอบ ค่า Parse/Schema เป็นจำนวนผ่านหารจำนวนครั้งที่รันจริง

การตรง schema ยืนยันเพียงโครงสร้างและชนิดข้อมูล แม้ผลลัพธ์ใช้ null หรือรายการว่างก็อาจผ่านได้
ยังไม่มีคะแนนความถูกต้องวันที่ ยอดรวม หรือรายการสินค้า และไม่สรุปว่าโมเดลหรือ grammar
ใดแม่นยำกว่าในเชิงเนื้อหาจากตารางนี้ [23]

การตรวจสถานะคำตอบพบ truncated จากเพดาน 2,048 tokens จำนวน 6 ครั้ง และคำขอล้มเหลว 0 ครั้ง
ทุกครั้งยังรวมในตัวหาร ตาราง parse/schema ตรวจจากข้อความดิบที่โมเดลคืนมาโดยไม่มีการซ่อมคำตอบ
จึงต้องอ่านควบคู่กับสถานะการจบคำตอบ [23]

ในกลุ่มที่เปิด grammar พบคำตอบถูกตัด 3 ครั้ง จึงต้องตรวจว่าคำตอบจบครบก่อนใช้งาน
การบังคับรูปแบบช่วยจำกัดโทเคนที่สร้างได้ แต่ไม่ได้ยกเลิกเพดานความยาว และยังไม่ยืนยันความถูกต้องเชิงเนื้อหา
[23]

5.11 เดโมครบกระบวนการและทรัพยากรบน PC

ชุดวัด PC ใช้ YOLOv8n ตรวจกรอบ เครื่องมือ OCR tesseract และโมเดล qwen3-0.6B-Q4_K_M โดย เปิด
grammar กำหนดชุดนี้เพื่อวัดการเชื่อมต่อและทรัพยากร หมุนภาพตามทิศที่บันทึกไว้โดยผู้จัดทำ
จึงยังไม่ใช่การตรวจทิศภาพอัตโนมัติ [23]

ต้นแบบเชื่อมภาพจริงกับการตรวจกรอบ OCR Local LLM หน้าตรวจยืนยัน MQTT และ Home Assistant แล้ว
หลักฐานทดสอบการเชื่อมต่อใช้ 3 ภาพ ตรวจ event_id ยอดรวม และจำนวนรายการที่ปลายทาง รวมทั้งกรณี
broker หยุดแล้วส่งซ้ำ การยืนยันซ้ำ และ JSON ไม่ผ่าน schema
การยืนยันในชุดทดสอบนี้เป็นคำสั่งอัตโนมัติเฉพาะสภาพแวดล้อมทดลอง ไม่ใช่การตรวจเนื้อหาโดยผู้ใช้ [23]

ผลวัดอ้างอิงการรัน pc-delivery-profile-engineering-v3 ใช้ 3 ภาพ × 3 รอบ รวม 9 ครั้ง ล้มเหลว 0 ครั้ง
โหลดโมเดลค้างในหน่วยความจำและตัด warm-up ออกจากสถิติ ใช้ตัวอ่าน Tesseract TSV รุ่นแก้ไขแล้ว [23]

ตารางที่ 7 เวลาและหน่วยความจำของเดโม PC

ตัวชี้วัด	**ครั้ง**	**มัธยฐาน**	**ต่ำสุด–สูงสุด**
ภาพถึงสังเกตค่าใน HA (วินาที)	9	10.758	6.215–14.807
เริ่มส่งถึงสังเกตค่าใน HA (วินาที)	9	0.103	0.056–0.127
Windows host RSS (GiB)	9	1.985	1.980–1.990
Home Assistant RSS (MiB)	9	229.008	228.949–229.098
MQTT broker RSS (MiB)	9	8.488	8.488–8.492

เมื่อแยกขั้นตอน มัธยฐานเวลาและหน่วยความจำที่วัดได้คือ ตรวจกรอบและเตรียมภาพ 0.441 วินาที และ RSS สูงสุดที่สุ่มวัด 1.964 GiB; OCR รวมการเรียกจาก Windows 0.881 วินาที และ RSS สูงสุดที่สุ่มวัด 1.990 GiB; Local LLM 8.874 วินาที และ RSS สูงสุดที่สุ่มวัด 1.559 GiB; บันทึกการยืนยันอัตโนมัติ 0.053 วินาที และ RSS สูงสุดที่สุ่มวัด 1.949 GiB; MQTT client จนรับ PUBACK และปิดการเชื่อมต่อ 0.046 วินาที และ RSS สูงสุดที่สุ่มวัด 1.949 GiB โดย RSS ของการตรวจกรอบและ OCR ฝั่ง Windows รวมโมเดลที่โหลดค้างในกระบวนการ ไม่ใช่หน่วยความจำที่เพิ่มขึ้นเฉพาะขั้นตอนนั้น [23]

เฉพาะโปรเซส Tesseract ใน Linux มีมัธยฐานเวลา 0.541 วินาที และ peak RSS สูงสุด 50.762 MiB วัดด้วย RUSAGE_CHILDREN แยกจากค่า Windows client จึงไม่รวมค่าทั้งสองเป็นหน่วยความจำสุทธิ [23]

เวลาเริ่มส่งถึงสังเกตค่า Home Assistant รวมรอบ HTTP polling จึงเป็นขอบเขตเวลาสังเกต ไม่ใช่เวลา processing ภายใน HA โดยตรง

เวลาเต็มกระบวนการแทนช่วงผู้ใช้ตรวจด้วยการยืนยันอัตโนมัติและไม่รวมเวลาตรวจของมนุษย์ RSS ฝั่ง Windows และบริการ Linux วัดคนละขอบเขต จึงไม่บวกเป็น RAM รวมระบบ การรันซ้ำ 3 ภาพเป็นผลเชิงวิศวกรรม ไม่ใช่คะแนนทดสอบทั่วไปหรือหลักฐานว่าใช้ได้บน NPU [23]

5.12 สถานะงานก่อนมีบอร์ดและสิ่งที่ยังค้าง

(1) มีภาพ 59 ภาพและข้อความหนึ่งรอบ 59 ภาพ แต่กรอบและกลุ่มธุรกรรมยังไม่รับรองครบ (2) มี CER เชิงพรรณนา 24 ภาพ (3) มีผลรัน LLM ด้านรูปแบบและทรัพยากร (4) มีเดโมส่งข้อมูลถึง Home Assistant และการตรวจค่าปลายทางในสภาพแวดล้อมทดลอง (5) มีการวัดเวลาและ RAM บน PC การวัดความถูกต้องเชิงเนื้อหาของฟิลด์ JSON และการทดสอบภาพต่างฉากใหม่ระบุสถานะว่ายังไม่ได้ทดลอง เนื่องจากยังไม่มีเฉลยฟิลด์ที่ตรวจครบและชุดภาพใหม่ตามลำดับ ส่วนคะแนน NPU และพลังงานต้องรออุปกรณ์จริง [23]

6 ขอบเขตและข้อจำกัดของการวิจัย

ขอบเขตเชิงสถาปัตยกรรมครอบคลุม e-Senses และกระบวนการสามชั้นตามภาพที่ 1
ขอบเขตการทดลองหลักระยะแรกใช้ภาพใบซื้อสินค้าภาษาไทย/อังกฤษเพื่อตรวจจับ OCR และสกัด JSON บน PC พร้อมตรวจความเข้ากันได้ของ RKNN/RKLLM ตามความพร้อมของเครื่องมือ e-Nose, e-Skin, กล้อง IP แบบเรียลไทม์ และระบบบ้านอัจฉริยะเต็มรูปแบบเป็นส่วนต่อยอด ยังไม่มีบอร์ดสำหรับทดสอบ RK3588 จริง จึงไม่รวมผล NPU ในผลนำร่อง

ชุดข้อมูลยังมีข้อจำกัดด้านข้อความไม่ครบ กลุ่มธุรกรรมซ้ำ และกรอบที่ยังไม่รับรองทั้งหมด รายงาน CER จึงใช้เพียงภาพที่ผ่านเกณฑ์คัดข้อความของการเปรียบเทียบหนึ่งรอบ ส่วนผล JSON รายงานเฉพาะการอ่านรูปแบบและการตรง schema ยังไม่มี field accuracy หรือ end-to-end semantic accuracy อีกทั้งยังไม่มีชุดภาพต่างฉากใหม่สำหรับทดสอบสุดท้าย ผล NPU และพลังงานจริงยังค้าง ข้อจำกัดเหล่านี้ทำให้งานวิจัยก่อนมีบอร์ดทั้งห้าข้อยังไม่ถือว่าทดลองครบ [23]

7 สถานที่ทำวิจัย

ดำเนินการเตรียมข้อมูล ฝึกและทดสอบเบื้องต้นบนคอมพิวเตอร์ส่วนตัวของผู้จัดทำและสภาพแวดล้อม PC/WSL ที่บันทึกเวอร์ชันไว้ ภาพต้นฉบับและ manifest มีสำเนาใน repository ของโครงงาน ส่วนผล OCR และเฉลยระหว่างตรวจเก็บในพื้นที่ทำงานส่วนตัว
สถานที่ทดสอบบอร์ดจริงจะกำหนดภายหลังร่วมกับอาจารย์ที่ปรึกษาเมื่อมีอุปกรณ์

8 ประโยชน์ที่คาดว่าจะได้รับ

(1) ได้กรอบสถาปัตยกรรม e-Senses
และข้อกำหนดการส่งข้อมูลระหว่างชั้นที่ใช้พัฒนาระบบบ้านอัจฉริยะในระยะต่อไป

(2) ได้ชุดข้อมูลและเฉลยที่ตรวจสอบย้อนหลังได้สำหรับใบซื้อสินค้าไทย/อังกฤษ พร้อมข้อกำหนดการแบ่งชุดตามธุรกรรม

(3) ได้หลักฐานว่าแต่ละขั้นของ e-Eye ผิดพลาดตรงไหน โดยเฉพาะเมื่อฉากภาพเปลี่ยน และมีวิธีประเมิน JSON ที่แยกความถูกต้องโครงสร้างจากเนื้อหา

(4) ได้ข้อมูล trade-off บน PC ที่ช่วยคัดแบบจำลองและกำหนดการทดลองบนฮาร์ดแวร์จริงอย่างมีเหตุผล โดยไม่สับสนผลจำลองกับ NPU

9 แผนและระยะเวลาดำเนินการ

Implementation Roadmap เจ็ดระยะจากรายงานเดิมยังเป็นแผนแม่บท ได้แก่ ทบทวนวรรณกรรมและสถาปัตยกรรม ต้นแบบ YOLO/OCR การสกัด JSON การเชื่อม MQTT/Home Assistant การประเมินข้อมูลนำร่อง จริยธรรมเมื่อศึกษากับผู้ใช้ และการวัด trade-off ครบระบบ ระยะ PC มีผลเชื่อมระบบและวัดรูปแบบ/ทรัพยากรแล้ว แต่ผลเนื้อหาและการทดสอบต่างฉากใหม่ยังค้าง ตารางที่ 8 แสดงแผนต่อเนื่องนับจากการรับรองเค้าโครง [12, 23]

ตารางที่ 8 แผนดำเนินงานระยะ PC นับจากการรับรองเค้าโครง

ช่วง	กิจกรรม	ผลส่งมอบ
สัปดาห์ 1	ตรวจประเภทภาพ/กลุ่มธุรกรรมและ label	กรอบและกลุ่มธุรกรรมที่รับรองแล้ว
สัปดาห์ 2–3	ใช้ข้อความหนึ่งรอบ และกำหนดเฉลยฟิลด์สำหรับระยะถัดไป	ข้อความ 59 ภาพ; เฉลย JSON ยังค้าง
สัปดาห์ 3–4	เปรียบเทียบ OCR และปรับตรวจจับข้ามฉาก	CER / field metrics / detection metrics
สัปดาห์ 4–5	ทดลองโมเดลภาษาและ constrained output บน PC	ตารางความแม่นยำ เวลา และ RAM
สัปดาห์ 6	ทวน RKNN/RKLLM PC-side และเขียนผล	ข้อจำกัดและแผนทดลองบนบอร์ดจริง

หลังระยะ PC หากมีบอร์ดยืมและการอนุมัติที่เกี่ยวข้อง จึงย้ายโมเดลที่เข้ากันได้ไปวัด latency, RAM และพลังงานจริงบนอุปกรณ์ โดยคงชุดทดสอบและเวอร์ชันโมเดลไว้เทียบกับ PC
กิจกรรมนี้เป็นระยะต่อเนื่องภายหลังการศึกษาเบื้องต้น

10 งบประมาณ

ระยะศึกษาเบื้องต้นใช้คอมพิวเตอร์ พื้นที่เก็บข้อมูล และซอฟต์แวร์ที่มีอยู่ จึงไม่มีรายการจัดซื้อในระยะนี้ การทดสอบบอร์ด RK3588 จะเริ่มเมื่อได้รับอุปกรณ์ยืมจากคณะ หากต้องจัดหาอุปกรณ์เพิ่มเติม จะสำรวจรุ่น ราคา และความเข้ากันได้ก่อนเสนอรายการงบประมาณ

11 เอกสารอ้างอิง

[1] Husom, E. J., et al. (2025). Sustainable LLM inference for edge AI: Evaluating quantized LLMs for energy efficiency, output accuracy, and inference latency. ACM Transactions on Internet of Things, 6(4), Article 28. https://doi.org/10.1145/3767742

[2] Giedra, H., et al. (2026). Benchmarking large language model inference on limited-resource edge systems. Electronics, 15(11), 2451. doi:10.3390/electronics15112451.

[3] Zheng, L., et al. (2024). SGLang: Efficient execution of structured language model programs. Advances in Neural Information Processing Systems, 37, 62557-62583. https://doi.org/10.52202/079017-2000

[4] ณัชพล เพ็งพล และ ธนบดี เริ่มรักสกุล. (2569). ผลนำร่อง e-Eye บน PC ณ วันที่ 17 ตุลาคม 2569. บันทึกผลภายในโครงงาน. https://github.com/natchapolp-glitch/Capstone-Project/blob/main/ass5_ready_evidence.md

[5] ggml-org. (2026). GBNF guide, llama.cpp. https://github.com/ggml-org/llama.cpp/tree/master/grammars

[6] Ultralytics. (2026). YOLO performance metrics. https://docs.ultralytics.com/guides/yolo-performance-metrics/

[7] Tesseract OCR. (2026). Data files and language support. https://github.com/tesseract-ocr/tessdata

[8] Jaided AI. (2026). EasyOCR. https://github.com/JaidedAI/EasyOCR

[9] Rockchip. (2026). RKNN Toolkit2. https://github.com/airockchip/rknn-toolkit2

[10] Rockchip. (2026). RKLLM. https://github.com/airockchip/rknn-llm

[11] Rockchip. (2022). RK3588 brief datasheet. https://www.rock-chips.com/a/en/products/RK35_Series/2022/0926/1660.html

[12] ณัชพล เพ็งพล และ ธนบดี เริ่มรักสกุล. (2569). การพัฒนาระบบประสาทส่วนกลางอัจฉริยะในที่พักอาศัยเพื่อสกัดและวิเคราะห์ข้อมูลห่วงโซ่อุปทานในครัวเรือนด้วยปัญญาประดิษฐ์ประมวลผลเฉพาะถิ่น. รายงานทบทวนวรรณกรรม 32 หน้า, เอกสารภายในโครงงาน.

[13] Radxa. (2026). ROCK 5B introduction and specifications. https://docs.radxa.com/en/rock5/rock5b/getting-started/introduction

[14] Rivkin, D., et al. (2025). AIoT smart home via autonomous LLM agents. IEEE Internet of Things Journal, 12(3), 2458-2472. https://doi.org/10.1109/JIOT.2024.3471904

[15] Sawalha, S., & Al-Naymat, G. (2025). An adaptive Holt-Winters model for seasonal forecasting of Internet of Things (IoT) data streams. IoT, 6(3), Article 39. https://doi.org/10.3390/iot6030039

[16] Serepas, F., et al. (2025). Lightweight embedded IoT gateway for smart homes based on an ESP32 microcontroller. Computers, 14(9), Article 391. https://doi.org/10.3390/computers14090391

[17] Yin, W., et al. (2026). ShadowNPU: System and algorithm co-design for NPU-centric on-device LLM inference. Proceedings of MobiSys 2026, 294-308. https://doi.org/10.1145/3745756.3809205

[18] Cai, F., Yuan, D., Yang, Z., & Cui, L. (2024). Edge-LLM: A collaborative framework for large language model serving in edge computing. In 2024 IEEE International Conference on Web Services (ICWS) (pp. 799–809). https://doi.org/10.1109/ICWS62655.2024.00099

[19] Moon, S., Cha, J., Park, H., & Kim, J.-Y. (2025). Hybe: GPU-NPU hybrid system for efficient LLM inference with million-token context window. In Proceedings of the 52nd Annual International Symposium on Computer Architecture (pp. 808–820). https://doi.org/10.1145/3695053.3731051

[20] Oloko-Oba, M., Esenogho, E., & Aruleba, K. (2026). From biosignals to bedside: A review of real-time edge machine learning for wearable health monitoring. Bioengineering, 13(5), 559. https://doi.org/10.3390/bioengineering13050559

[21] Zheng, Y., Chen, Y., Qian, B., Shi, X., Shu, Y., & Chen, J. (2025). A review on edge large language models: Design, execution, and applications. ACM Computing Surveys, 57(8), Article 209. https://doi.org/10.1145/3719664

[22] Hu, A., Xu, H., Zhang, L., Ye, J., Yan, M., Zhang, J., Jin, Q., Huang, F., & Zhou, J. (2025). mPLUG-DocOwl2: High-resolution compressing for OCR-free multi-page document understanding. In Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers) (pp. 5817–5834). https://doi.org/10.18653/v1/2025.acl-long.291

[23] ณัชพล เพ็งพล และ ธนบดี เริ่มรักสกุล. (2569). ผลทดลองก่อนมีบอร์ด: ข้อความอ้างอิงหนึ่งรอบ OCR Local LLM และการเชื่อม MQTT/Home Assistant. ชุดหลักฐานพร้อมค่าแฮชและข้อจำกัด. https://github.com/natchapolp-glitch/Capstone-Project/tree/pc-preboard-implementation/reports/preboard

ลงชื่อ ..... (นายณัชพล เพ็งพล) ผู้เสนอโครงงาน

ลงชื่อ ..... (นายธนบดี เริ่มรักสกุล) ผู้เสนอโครงงาน

วันที่ 18 ตุลาคม 2569