ชื่อ-นามสกุล: ณัชพล เพ็งพล รหัสนักศึกษา: 673380267-4 Sec: 1

Assignment 3: **การเขียน** Literature Review

หัวข้อ: การพัฒนาระบบประสาทส่วนกลางอัจฉริยะในที่พักอาศัยด้วยปัญญาประดิษฐ์ประมวลผลเฉพาะถิ่น (Local/Edge AI)

บทนำ (Introduction)

ในยุคที่ปัญญาประดิษฐ์แบบประมวลผลเฉพาะถิ่น (Local/Edge AI) เข้ามามีบทบาทมากขึ้นในชีวิตประจำวัน
การนำแบบจำลองภาษาขนาดใหญ่ (Large Language Model, LLM) มาประมวลผลโดยตรงบนอุปกรณ์ในที่พักอาศัย
โดยไม่ต้องพึ่งพาการเชื่อมต่อคลาวด์ ได้กลายเป็นแนวทางที่ตอบโจทย์ทั้งด้านความเป็นส่วนตัวของข้อมูล ความหน่วงในการตอบสนอง
และต้นทุนการใช้งานระยะยาว
โครงงานวิทยานิพนธ์นี้มุ่งพัฒนาระบบประสาทส่วนกลางอัจฉริยะในที่พักอาศัยเพื่อสกัดและวิเคราะห์ข้อมูลห่วงโซ่อุปทานในครัวเรือน
โดยอาศัยสถาปัตยกรรมที่เชื่อมโยงตั้งแต่กล้อง IP Camera ตรวจจับเอกสาร (YOLO) การสกัดข้อความด้วย OCR การประมวลผลด้วย
Quantized Local LLM เพื่อสร้างโครงสร้างข้อมูล JSON และการเชื่อมต่อเข้ากับระบบบ้านอัจฉริยะ (Home Assistant ผ่าน MQTT)
สำหรับพยากรณ์อัตราการสิ้นเปลืองสินค้าในครัวเรือน (burn rate)

ความสำคัญของการประมวลผลแบบเรียลไทม์บนอุปกรณ์ (real-time on-device inference)
ภายใต้ทรัพยากรจำกัดมิได้จำกัดอยู่เฉพาะสายวิทยาการคอมพิวเตอร์เท่านั้น แต่เป็นความท้าทายร่วมที่ปรากฏข้ามศาสตร์วิชา
ดังจะเห็นได้จากงานทบทวนวรรณกรรมของ Oloko-Oba et al. (2026) ในสาขาวิศวกรรมชีวการแพทย์
ที่ให้เห็นว่าการประมวลสัญญาณชีวภาพแบบเรียลไทม์บนอุปกรณ์ edge สำหรับการติดตามสุขภาพด้วยอุปกรณ์สวมใส่นั้น
เผชิญกับความท้าทายด้าน latency สัญญาณรบกวนของข้อมูลภาคสนาม และความน่าเชื่อถือของระบบในสภาพแวดล้อมการใช้งานจริง
ในลักษณะที่คล้ายคลึงกับความท้าทายของการประมวลผลข้อมูลครัวเรือนแบบเรียลไทม์ในโครงงานนี้
แม้จะเป็นคนละโดเมนการประยุกต์ใช้งาน แต่โดยเชิงงานวิจัยดังกล่าวจึงถูกใช้ในที่นี้เป็นหลักฐานสนับสนุน (motivation evidence)
ที่ตอกย้ำว่าการอนุมานแบบจำลองบนอุปกรณ์ที่มีทรัพยากรจำกัดจริง ภายใต้เงื่อนไขที่ต้องรักษาทั้งความเร็ว ความแม่นยำ
และความน่าเชื่อถือไปพร้อมกัน เป็นปัญหาวิจัยที่มีคุณค่าและสามารถถ่ายโอนหลักการข้ามโดเมนได้จริง
มิใช่ปัญหาเฉพาะทางของสายวิศวกรรมคอมพิวเตอร์เพียงอย่างเดียว ทั้งนี้งานฉบับนี้มิได้ถูกใช้เป็นเสาหลักทางเทคนิค (technical pillar)
ที่จะนำมาสังเคราะห์ร่วมกับสถาปัตยกรรมฮาร์ดแวร์ P1-P4 โดยตรง แต่ใช้เพียงเพื่อยืนยันความสำคัญของโจทย์วิจัยในบทนำเท่านั้น

อย่างไรก็ตาม เมื่อพิจารณางานวิจัยที่เกี่ยวข้องโดยตรงกับสถาปัตยกรรมของโครงงานนี้
พบว่างานวิจัยที่ผ่านมายังคงศึกษาปัจจัยด้านประสิทธิภาพของ on-device LLM inference แยกออกจากกันเป็นสามมิติ
โดยไม่มีงานใดประเมินปฏิสัมพันธ์ร่วมกันของทั้งสามมิตินี้บนอุปกรณ์ single-board computer (SBC)
ที่มีทรัพยากรจำกัดจริงในบริบทที่พักอาศัย รายละเอียดของการทบทวนวรรณกรรมทั้ง 12 ฉบับ และช่องว่างทางความรู้ที่พบ
นำเสนอไว้ในหัวข้อถัดไป

1. Synthesis Matrix (**ตารางสังเคราะห์**)

จากบทความวิจัยที่เกี่ยวข้องกับโครงงานจำนวน 12 ฉบับ ซึ่งผ่านการตรวจสอบสถานะการจัดทำดัชนีในฐานข้อมูล Scopus แล้ว จัดกลุ่มตาม 3 มิติของกรอบ Performance Trade-off ที่โครงงานนี้มุ่งศึกษา ได้แก่ (1) quantization/hardware trade-off (P1-P4, P6, P10) (2) grammar-constrained decoding/structured output (P8-P9) และ (3) บริบทบ้านอัจฉริยะ/IoT ปลายน้ำ (P7, P11-P12) ส่วน P5 ใช้เป็นหลักฐานสนับสนุนเชิง cross-disciplinary motivation มีรายละเอียดดังนี้

P1: Cai, Yuan, Yang & Cui (2024)

P2: Husom et al. (2025)

P3: Moon, Cha, Park & Kim (2025)

P4: Yin et al. (2026)

P5: Oloko-Oba, Esenogho & Aruleba (2026)

P6: Zheng, Chen, Qian, Shi, Shu & Chen (2025)

P7: Rivkin, Hogan, Feriani, Konar, Sigal, Liu & Dudek (2025)

P8: Zheng, Yin, Xie, Sun, Huang, Yu, Cao, Kozyrakis, Stoica, Gonzalez et al. (2024)

P9: Hu, Xu, Zhang, Ye, Yan, Zhang, Jin, Huang & Zhou (2025)

P10: Giedra, Matuzevi**č**ius, Sledevi**č**, Shubitidze & Serackis (2026)

P11: Sawalha & Al-Naymat (2025)

P12: Serepas, Papias, Christakis, Dimitropoulos & Marinakis (2025)

ตารางที่ 1: P1 - P3

ประเด็นเปรียบเทียบ	P1	P2	P3
แพลตฟอร์มฮาร์ดแวร์ที่ใช้	อุปกรณ์ Edge ทั่วไป ร่วมกับเซิร์ฟเวอร์คลาวด์ (Cloud-Edge Collaboration)	Raspberry Pi 4 (RAM 4 GB) — ประมวลผลด้วย CPU เพียงอย่างเดียว	NVIDIA H100 GPU ร่วมกับ NPU ที่ออกแบบเฉพาะด้วยเทคโนโลยี 4 นาโนเมตร (Custom Silicon)
แนวทาง/เทคนิคหลักที่นำเสนอ	Adaptive Quantization, FM Cache และ Value-Density-First (VDF) Scheduling เพื่อลดภาระ GPU	ประเมินแบบจำลอง Quantized LLM จำนวน 28 แบบจำลองจากไลบรารี Ollama บนชุดข้อมูลมาตรฐาน 5 ชุด พร้อมวัดพลังงานจริงด้วยอุปกรณ์ Joulescope	สถาปัตยกรรมแบบผสมผสาน GPU-NPU, การส่งผ่าน Key-Value แบบละเอียด (Fine-grained KV Transmission) และการทำ Pipelining ตามลำดับขั้น
ตัวชี้วัดหลักที่มุ่งเน้น	การลดภาระประมวลผลฝั่ง GPU โดยไม่ลดทอนความแม่นยำ	ประสิทธิภาพเชิงพลังงาน (Energy Efficiency), ความแม่นยำของผลลัพธ์ และความหน่วงในการอนุมาน	ความเร็ว (Speedup) และประสิทธิภาพเชิงพลังงานสำหรับหน้าต่างบริบทขนาดใหญ่ระดับล้านโทเคน
ระดับการพึ่งพาคลาวด์	พึ่งพาคลาวด์บางส่วน (Hybrid Cloud-Edge) สำหรับภาระงานที่หนัก	ประมวลผลในเครื่องทั้งหมด (Fully Local) ไม่มีการเชื่อมต่อคลาวด์	ประมวลผลภายในเครื่อง (On-premises) แต่อาศัยฮาร์ดแวร์ระดับสูงคล้ายศูนย์ข้อมูล
ข้อจำกัด / ช่องว่างที่พบในงานวิจัย	ยังคงต้องพึ่งพาการเชื่อมต่อเครือข่ายภายนอกบางส่วน จึงไม่เหมาะกับบริบทที่ต้องตัดขาดจากอินเทอร์เน็ตโดยสมบูรณ์	พบข้อจำกัดด้านความแม่นยำเมื่อลดระดับการบีบอัด (Quantization) ลงต่ำ โดยเฉพาะในงานที่ต้องการความละเอียดสูง	ออกแบบสำหรับฮาร์ดแวร์ระดับเซิร์ฟเวอร์ที่มีต้นทุนสูง ไม่สอดคล้องกับข้อจำกัดด้านขนาดและงบประมาณของ Edge Server ในที่พักอาศัย

ตารางที่ 2: P4 - P5

ประเด็นเปรียบเทียบ	P4	P5
แพลตฟอร์มฮาร์ดแวร์ที่ใช้	หน่วยประมวลผล NPU บนสมาร์ตโฟน (Mobile NPU)	อุปกรณ์สวมใส่ (Wearable) ร่วมกับสมาร์ตโฟนที่จับคู่ (Paired Phone)
แนวทาง/เทคนิคหลักที่นำเสนอ	Sparse Attention (shadowAttn) ที่คำนวณเฉพาะโทเคนสำคัญด้วย NPU-based Pilot Compute เพื่อลดการพึ่งพา CPU/GPU	การทบทวนวรรณกรรมเชิงบรรยาย (Narrative Review) ครอบคลุมกระบวนการตั้งแต่การรับสัญญาณ การแบ่งหน้าต่างข้อมูล จนถึงกลุ่มแบบจำลองที่เหมาะกับการอนุมานบนอุปกรณ์
ตัวชี้วัดหลักที่มุ่งเน้น	ความแม่นยำและประสิทธิภาพของการคำนวณ Attention บน NPU ภายใต้ทรัพยากร CPU/GPU ที่จำกัด	ความน่าเชื่อถือทางคลินิกและความสามารถในการประมวลผลตามเวลาจริงในสภาพแวดล้อมการใช้งานจริง
ระดับการพึ่งพาคลาวด์	ประมวลผลภายในอุปกรณ์ทั้งหมด (Fully On-device)	ประมวลผลภายในอุปกรณ์เป็นหลัก ใช้คลาวด์เฉพาะเพื่อแสดงผลสรุปบนแดชบอร์ด (Dashboard/Summarisation)
ข้อจำกัด / ช่องว่างที่พบในงานวิจัย	ทดสอบเฉพาะบนอุปกรณ์สมาร์ตโฟน ยังไม่มีการทดสอบบน Single-Board Computer หรือ Edge Server ลักษณะที่ใช้ในบ้านพักอาศัย	ข้อมูลภาคสนามมีสัญญาณรบกวนสูง ป้ายกำกับข้อมูลล่าช้า และระบบนิเวศของอุปกรณ์เปลี่ยนแปลงตลอดเวลา (เป็นบริบทด้านการแพทย์ ไม่ใช่สายคอมพิวเตอร์)

ตารางที่ 3: P6, P10 (**มิติที่** 1 **เพิ่มเติม** — Quantization/Hardware Trade-off)

ประเด็นเปรียบเทียบ	P6	P10
แพลตฟอร์มฮาร์ดแวร์ที่ใช้	Survey ครอบคลุมอุปกรณ์ edge หลากหลายระดับ (mobile ถึง SBC) ไม่ผูกกับฮาร์ดแวร์เดียว	NVIDIA Jetson Orin Nano Super (8GB) — SBC ระดับ embedded GPU
แนวทาง/เทคนิคหลักที่นำเสนอ	ทบทวนวรรณกรรมเชิงระบบ (systematic review) ครอบคลุมตั้งแต่ resource-efficient model design จนถึง runtime inference optimization	Benchmark เชิงประจักษ์ 12 แบบจำลอง quantized (sub-1B ถึง 8B) วัด accuracy (lm-eval) และ efficiency (power/throughput) พร้อมกัน
ตัวชี้วัดหลักที่มุ่งเน้น	สังเคราะห์ตัวชี้วัดจากงานวิจัยจำนวนมาก ไม่มีการทดลองเชิงประจักษ์ของตัวเอง	Accuracy–efficiency trade-off (tok/J, throughput, power)
ระดับการพึ่งพาคลาวด์	ไม่ระบุเฉพาะเจาะจง (ครอบคลุมทั้งรูปแบบ on-device และ hybrid cloud-edge)	ประมวลผลภายในอุปกรณ์ทั้งหมด (Fully On-device)
ข้อจำกัด / ช่องว่างที่พบในงานวิจัย	เป็น survey กว้าง ไม่มีข้อมูลเชิงปริมาณของตัวเองที่ยืนยัน trade-off ระหว่าง quantization กับ structured/JSON output โดยตรง	ใช้ task ทั่วไป (IFEval, GSM8K, TruthfulQA) ไม่ได้ทดสอบ grammar-constrained decoding หรือความแม่นยำของ JSON/structured output

ตารางที่ 4: P8 - P9 (**มิติที่** 2 — Grammar-Constrained Decoding / Structured Output)

ประเด็นเปรียบเทียบ	P8	P9
แพลตฟอร์มฮาร์ดแวร์ที่ใช้	GPU ระดับ data center (ไม่ใช่ edge/SBC)	GPU ขนาดใหญ่ (multimodal LLM ระดับ research-scale)
แนวทาง/เทคนิคหลักที่นำเสนอ	RadixAttention (reuse KV cache) + compressed finite state machine สำหรับเร่งการถอดรหัสแบบมีโครงสร้าง	High-resolution DocCompressor ลดจำนวน visual token กว่า 80% สำหรับความเข้าใจเอกสารหลายหน้าแบบ OCR-

ประเด็นเปรียบเทียบ	P8	P9
	(grammar-constrained decoding)	free
ตัวชี้วัดหลักที่มุ่งเน้น	Throughput (เพิ่มขึ้นถึง 6.4 เท่าเทียบระบบทั่วไป) และความถูกต้องของ JSON/structured output	ความแม่นยำความเข้าใจเอกสารหลายหน้า และ latency ของ token แรก
ระดับการพึ่งพาคลาวด์	ออกแบบสำหรับ server-scale ไม่ใช่ edge	ไม่ระบุชัด (แบบจำลองขนาดใหญ่ ยังไม่ปรับให้ทำงานบน edge)
ข้อจำกัด / ช่องว่างที่พบในงานวิจัย	ไม่ได้ทดสอบบนอุปกรณ์ edge/NPU ทรัพยากรจำกัด จึงไม่ทราบว่า throughput gain จะคงอยู่หรือไม่เมื่อรวมกับ quantized model บน SBC	เป็นแบบจำลองขนาดใหญ่ ยังไม่ได้ทดสอบร่วมกับ quantized local LLM บน SBC หรือ pipeline ที่แยก OCR ต่างหากตามสถาปัตยกรรมของโครงงานนี้

ตารางที่ 5: P7, P11 - P12 (**มิติที่ 3 — บริบทบ้านอัจฉริยะ/IoT ปลายน้ำ**)

ประเด็นเปรียบเทียบ	P7	P11	P12
แพลตฟอร์มฮาร์ดแวร์ที่ใช้	อุปกรณ์บ้านอัจฉริยะทั่วไป (ไม่ระบุ SBC เฉพาะ)	ไม่ระบุฮาร์ดแวร์เฉพาะ (แบบจำลองพยากรณ์เชิงสถิติ ทดสอบบนชุดข้อมูล IoT ทั่วไป)	ไมโครคอนโทรลเลอร์ ESP32 (MCU-class, ต่ำกว่าระดับ SBC)
แนวทาง/เทคนิคหลักที่นำเสนอ	ตัวแทน LLM อัตโนมัติ (autonomous agent) สำหรับวางแผนและควบคุมอุปกรณ์ในบ้านอัจฉริยะ	Adaptive Holt–Winters (AHW) ผสานแบบจำลอง exponential smoothing สองชุด (ข้อมูลปัจจุบัน + ข้อมูลย้อนหลังที่มีรูปแบบใกล้เคียง)	ออกแบบ IoT gateway น้ำหนักเบา รองรับโปรโตคอล MQTT และ REST API สำหรับเชื่อมต่ออุปกรณ์ edge เข้ากับระบบบ้านอัจฉริยะ
ตัวชี้วัดหลักที่มุ่งเน้น	อัตราความสำเร็จของ task การควบคุมอุปกรณ์	ความแม่นยำการพยากรณ์อนุกรมเวลาตามฤดูกาลของข้อมูล IoT	การใช้ทรัพยากร (resource footprint) ของ gateway บน MCU ต้นทุนต่ำ
ระดับการพึ่งพาคลาวด์	ไม่ระบุชัด (ใช้ LLM agent ทั่วไป อาจพึ่งพา cloud API)	ไม่เกี่ยวข้อง (เป็นแบบจำลองพยากรณ์ ไม่ใช่ LLM)	Local control ร่วมกับ cloud analytics ผ่าน gateway
ข้อจำกัด / ช่องว่างที่พบในงานวิจัย	ไม่ได้กล่าวถึงข้อจำกัดฮาร์ดแวร์ระดับ SBC หรือความแม่นยำของการสกัดข้อมูลเชิงโครงสร้างจากเอกสารต้นทาง	ไม่เกี่ยวข้องกับ LLM หรือการสกัดข้อมูลต้นทาง เป็นเทคนิคพยากรณ์ปลายน้ำที่อาจนำมาปรับใช้กับ burn rate prediction เท่านั้น	เป็นเพียงชั้นเชื่อมต่อ (connectivity layer) เท่านั้น ไม่เกี่ยวข้องกับความแม่นยำของการสกัดข้อมูลจาก LLM ต้นทาง

2. **การวิเคราะห์ข้อมูลจาก** Synthesis Matrix

2.1 **จุดที่เห็นตรงกัน** (Consensus)

งานวิจัยทั้ง 12 ฉบับเห็นตรงกันในหลักการว่า การนำหน่วยประมวลผลเฉพาะทาง (NPU) หรือเทคนิคการบีบอัดแบบจำลอง (Quantization) มาใช้ร่วมกับการประมวลผลใกล้แหล่งข้อมูล (Edge/On-device)
เป็นแนวทางที่จำเป็นต่อการทำให้ระบบปัญญาประดิษฐ์ทำงานได้จริงภายใต้ทรัพยากรที่จำกัด โดยงานวิจัยของ Husom et al. (2025), Yin et al. (2026) และ Oloko-Oba et al. (2026) ต่างมุ่งลดการพึ่งพาคลาวด์ให้เหลือน้อยที่สุดหรือไม่มีเลย
เพื่อรักษาความเป็นส่วนตัวของข้อมูลผู้ใช้ ซึ่งสอดคล้องโดยตรงกับหลักการออกแบบสถาปัตยกรรม Local AI ของโครงงานนี้
ทิศทางเดียวกันนี้ยังปรากฏในงานสำรวจภาพรวมของ Zheng et al. (2025) ซึ่งยืนยันว่าสายงานวิจัย edge LLM ทั้งสายกำลังมุ่งไปทาง on-device inference เป็นหลัก และสอดคล้องกับผลวัดเชิงประจักษ์ของ Giedra et al. (2026) ที่ยืนยันว่าการรันแบบจำลอง quantized

บนอุปกรณ์ edge จริงอย่าง NVIDIA Jetson ให้ผลลัพธ์ที่ใช้งานได้จริงในทางปฏิบัติ
หลักการเดียวกันยังปรากฏสม่ำเสมอในงานวิจัยชั้นปลายน้ำของสถาปัตยกรรม กล่าวคือ Rivkin et al. (2025), Sawalha and Al-Naymat (2025) และ Serepas et al. (2025) ต่างออกแบบให้การเชื่อมต่อและประมวลผลข้อมูล IoT ในครัวเรือนเกิดขึ้นแบบเบา (lightweight) และไม่พึ่งพาทรัพยากรคำนวณส่วนกลางเช่นเดียวกัน แม้แต่ในสายงานการบังคับโครงสร้างผลลัพธ์ Zheng et al. (2024) และ Hu et al. (2025) ก็มีเป้าหมายร่วมกันคือการลดภาระการประมวลผลของแบบจำลองภาษาโดยไม่ลดทอนคุณภาพผลลัพธ์
ซึ่งเป็นหลักการเดียวกับที่พบในงานกลุ่ม quantization/hardware ข้างต้น

2.2 **จุดที่ขัดแย้ง/ต่างกัน** (Disagreement)

แม้จะเห็นพ้องในหลักการ แต่แต่ละงานวิจัยมีเป้าหมาย ระดับการพึ่งพาคลาวด์ และระดับฮาร์ดแวร์ที่แตกต่างกันอย่างมีนัยสำคัญ กล่าวคือ Cai et al. (2024) ยังคงอาศัยการทำงานร่วมกันระหว่างอุปกรณ์ Edge และเซิร์ฟเวอร์คลาวด์บางส่วน (Hybrid) ในขณะที่ Husom et al. (2025), Yin et al. (2026) และ Oloko-Oba et al. (2026) เลือกประมวลผลภายในอุปกรณ์ทั้งหมด นอกจากนี้ Moon et al. (2025) มุ่งแก้ปัญหาหน้าต่างบริบทขนาดใหญ่ระดับล้านโทเคน ด้วยฮาร์ดแวร์ระดับเซิร์ฟเวอร์ (NVIDIA H100 ร่วมกับ NPU ที่ผลิตขึ้นเฉพาะ) ซึ่งมีต้นทุนและขนาดสูงกว่าฮาร์ดแวร์ระดับ Raspberry Pi หรือสมาร์ตโฟนที่ใช้ในงานวิจัยอื่น ๆ อย่างมีนัยสำคัญ
แสดงให้เห็นว่าผลการทดลองเรื่องความเร็วและประสิทธิภาพพลังงานจากงานวิจัยที่ใช้ฮาร์ดแวร์ระดับสูงอาจไม่สามารถถ่ายโอนไปใช้กับ Edge Server ขนาดเล็กในบริบทที่พักอาศัยได้โดยตรง
ความแตกต่างด้านระดับฮาร์ดแวร์นี้ปรากฏชัดยิ่งขึ้นเมื่อพิจารณาสายงานการบังคับโครงสร้างผลลัพธ์ กล่าวคือ Zheng et al. (2024) ทดสอบเทคนิคเร่งความเร็ว grammar-constrained decoding บนฮาร์ดแวร์ระดับ data center และ Hu et al. (2025) ใช้แบบจำลองขนาดใหญ่ ยังไม่ได้ปรับให้ทำงานร่วมกับ quantized LLM บน SBC ในขณะที่ Giedra et al. (2026) วัดผล trade-off ระหว่างความแม่นยำและพลังงานบนอุปกรณ์ edge จริงโดยตรง (NVIDIA Jetson)
แสดงให้เห็นว่าแม้แต่ภายในสายงานเดียวกันก็ยังมีช่องว่างระหว่างงานที่ทดสอบบนฮาร์ดแวร์สมรรถนะสูงกับงานที่ทดสอบบนฮาร์ดแวร์ทรัพยากรจำกัดจริง ในทำนองเดียวกัน งานวิจัยชั้นปลายน้ำอย่าง Rivkin et al. (2025), Sawalha and Al-Naymat (2025) และ Serepas et al. (2025) ก็มิได้กล่าวถึงข้อจำกัดด้านฮาร์ดแวร์ SBC หรือคุณภาพของผลลัพธ์เชิงโครงสร้างที่ส่งต่อมาจากชั้นการประมวลผล LLM เลย — สะท้อนว่าแต่ละสายงาน ฮาร์ดแวร์/quantization, structured decoding, และการประยุกต์ใช้งานปลายน้ำ — ยังคงพัฒนาแยกกันโดยไม่มีงานใดเชื่อมโยงทั้งสามระดับเข้าด้วยกันภายใต้เงื่อนไขฮาร์ดแวร์เดียวกัน

2.3 **ช่องว่างทางความรู้** (Research Gap)

งานวิจัยด้านการอนุมานแบบจำลองภาษาบนอุปกรณ์ประมวลผลเฉพาะถิ่น (on-device LLM inference) ในช่วงที่ผ่านมา มีแนวโน้มศึกษาปัจจัยด้านประสิทธิภาพแยกออกจากกันเป็นสามมิติหลัก
แทนที่จะประเมินปฏิสัมพันธ์ร่วมกันภายใต้ทรัพยากรจำกัดจริงของอุปกรณ์ single-board computer (SBC) ในมิติแรก งานวิจัยกลุ่มที่มุ่งเน้นการบีบอัดแบบจำลอง (quantization)
และสถาปัตยกรรมฮาร์ดแวร์เร่งความเร็วมีจำนวนมากและมีความก้าวหน้าอย่างต่อเนื่อง Cai et al. (2024) เสนอกรอบการทำงาน Edge-LLM ที่ผสมผสาน adaptive quantization ร่วมกับกลไกแคชเพื่อลดภาระ GPU โดยยังคงพึ่งพาคลาวด์บางส่วน ขณะที่ Husom et al. (2025) ประเมินแบบจำลอง quantized LLM จำนวน 28 แบบจำลองบน Raspberry Pi 4
และพบว่าการลดระดับการบีบอัดส่งผลโดยตรงต่อทั้งประสิทธิภาพเชิงพลังงานและความแม่นยำของผลลัพธ์ Moon et al. (2025) และ Yin et al. (2026) นำเสนอสถาปัตยกรรมฮาร์ดแวร์เฉพาะทางระดับ GPU-NPU และ NPU-on-smartphone ตามลำดับ
เพื่อลดความหน่วงของการอนุมาน แต่ทั้งสองงานอาศัยฮาร์ดแวร์ที่มีต้นทุนสูงกว่าหรือมีระบบนิเวศต่างจาก SBC ในบริบทที่พักอาศัย Zheng et al. (2025)
สังเคราะห์ภาพรวมของสายงานนี้ไว้ในการทบทวนวรรณกรรมที่ครอบคลุมตั้งแต่การออกแบบแบบจำลองจนถึงการอนุมานขณะรันไทม์บนอุปกรณ์ edge ส่วน Giedra et al. (2026) ได้วัด trade-off ระหว่างความแม่นยำและประสิทธิภาพพลังงานของแบบจำลอง quantized ขนาด sub-1B ถึง 8B บนอุปกรณ์ NVIDIA Jetson โดยตรง

ซึ่งเป็นหลักฐานเชิงประจักษ์ล่าสุดที่ยืนยันว่าระดับการบีบอัดแบบจำลองส่งผลต่อทั้งความเร็วและความแม่นยำอย่างมีนัยสำคัญบนอุปกรณ์ที่มีทรัพยากรจำกัดจริง อย่างไรก็ตาม งานวิจัยกลุ่มนี้ทั้งหมดวัดผลกระทบของ quantization ต่อความแม่นยำเชิง benchmark ทั่วไป มิได้เชื่อมโยงกับความแม่นยำของผลลัพธ์ที่มีโครงสร้าง (structured output) ซึ่งเป็นรูปแบบผลลัพธ์ที่จำเป็นสำหรับงานสกัดข้อมูล

ในมิติที่สอง งานวิจัยด้านการบังคับโครงสร้างผลลัพธ์ของแบบจำลองภาษาก็เป็นสายงานที่พัฒนาแยกต่างหากเช่นกัน Zheng et al. (2024) นำเสนอ SGLang ซึ่งใช้เทคนิค compressed finite state machine เพื่อเร่งความเร็วการถอดรหัสแบบมีโครงสร้าง (grammar-constrained decoding) ให้ throughput สูงขึ้นถึง 6.4 เท่าเทียบกับระบบอนุมานทั่วไป แต่งานดังกล่าวทดสอบบนฮาร์ดแวร์ระดับ data center มิใช่ edge NPU ขณะที่ Hu et al. (2025) พัฒนา mPLUG-DocOwl2 สำหรับความเข้าใจเอกสารหลายหน้าแบบ OCR-free ที่ลดจำนวน visual token ได้มากกว่า 80% แต่เป็นแบบจำลองขนาดใหญ่ ยังไม่ได้ออกแบบมาเพื่อทำงานร่วมกับ quantized local LLM บน SBC งานทั้งสองฉบับนี้ชี้ให้เห็นว่าการบังคับ schema ระหว่างการถอดรหัสส่งผลโดยตรงต่อทั้งความเร็วและความถูกต้องของ JSON output แต่ยังไม่มีงานใดวัดผลกระทบนี้ร่วมกับระดับการบีบอัดแบบจำลองบนอุปกรณ์ edge NPU ทรัพยากรจำกัดพร้อมกัน

ในมิติที่สาม บริบทของการประยุกต์ใช้งานจริงในครัวเรือนก็เป็นสายงานที่พัฒนาคู่ขนานกันไปเช่นกัน Rivkin et al. (2025) นำเสนอตัวแทน LLM อัตโนมัติสำหรับควบคุมอุปกรณ์ในบ้านอัจฉริยะ (AIoT smart home) ซึ่งแสดงให้เห็นศักยภาพของ LLM ในการเชื่อมต่อกับระบบ IoT ในครัวเรือน แต่มิได้กล่าวถึงข้อจำกัดด้านฮาร์ดแวร์ระดับ SBC หรือความแม่นยำของการสกัดข้อมูลเชิงโครงสร้าง ส่วนในระดับปลายน้ำของสถาปัตยกรรม Sawalha and Al-Naymat (2025) เสนอแบบจำลอง Adaptive Holt–Winters สำหรับพยากรณ์ข้อมูลอนุกรมเวลาตามฤดูกาลจากข้อมูล IoT ซึ่งสามารถประยุกต์ใช้กับการพยากรณ์อัตราการสิ้นเปลืองสินค้าในครัวเรือน (burn rate) ได้ในเชิงหลักการ และ Serepas et al. (2025) นำเสนอการออกแบบ IoT gateway น้ำหนักเบาบนไมโครคอนโทรลเลอร์ ESP32 ที่รองรับโปรโตคอล MQTT สำหรับเชื่อมต่ออุปกรณ์ edge เข้ากับระบบบ้านอัจฉริยะ ซึ่งสอดคล้องโดยตรงกับ stage การเชื่อมต่อ Home Assistant ผ่าน MQTT ในสถาปัตยกรรมของโครงงานนี้ อย่างไรก็ตาม ทั้งสามงานนี้ศึกษาเฉพาะชั้นการเชื่อมต่อและการพยากรณ์ปลายน้ำ โดยไม่ได้เชื่อมโยงย้อนกลับไปถึงความแม่นยำของการสกัดข้อมูลต้นทางจาก LLM ภายใต้ข้อจำกัดด้าน quantization และ decoding ที่กล่าวถึงในมิติแรกและมิติที่สอง

โดยสรุป จากการทบทวนวรรณกรรมทั้ง 12 ฉบับ พบว่างานวิจัยที่ผ่านมาให้ความสำคัญกับการนำ NPU และเทคนิคการบีบอัดแบบจำลองมาใช้เพื่อให้การประมวลผลปัญญาประดิษฐ์เกิดขึ้นใกล้แหล่งข้อมูลมากที่สุดอย่างสม่ำเสมอ ทั้งในชั้นฮาร์ดแวร์ ชั้นการบังคับโครงสร้างผลลัพธ์ และชั้นการประยุกต์ใช้งานปลายน้ำ แต่ยังมีความแตกต่างกันในระดับการพึ่งพาคลาวด์และขนาด/ต้นทุนของฮาร์ดแวร์ที่ใช้ทดลองในแต่ละสายงาน อีกทั้งยังไม่พบงานวิจัยฉบับใดที่บูรณาการองค์ประกอบทั้งหมด ตั้งแต่การตรวจจับเอกสารด้วยกล้อง การสกัดข้อความ การประมวลผลด้วย Local LLM จนถึงการเชื่อมต่อกับระบบบ้านอัจฉริยะเพื่อพยากรณ์พฤติกรรมการบริโภคในครัวเรือน ช่องว่างทางความรู้ดังกล่าวจึงเป็นที่มาและเป็นเป้าหมายหลักที่โครงงานวิทยานิพนธ์นี้มุ่งศึกษาและพัฒนาต่อไป

3. Literature Review (เรียบเรียงจากประเด็นข้างต้น)

การประยุกต์ใช้ปัญญาประดิษฐ์แบบประมวลผลเฉพาะถิ่น (Local/Edge AI) ร่วมกับหน่วยประมวลผลเฉพาะทางประเภท NPU ได้รับความสนใจอย่างต่อเนื่องในงานวิจัยระยะหลัง เนื่องจากช่วยลดความหน่วง ลดต้นทุนด้านแบนด์วิดท์ และรักษาความเป็นส่วนตัวของข้อมูลผู้ใช้เมื่อเทียบกับการประมวลผลบนคลาวด์แบบดั้งเดิม (Cai et al., 2024; Husom et al., 2025)

ในด้านเทคนิคการทำให้แบบจำลองภาษาขนาดใหญ่ทำงานได้บนอุปกรณ์ที่มีทรัพยากรจำกัด Husom et al. (2025) ได้ประเมินแบบจำลอง Quantized LLM จำนวน 28 แบบจำลองบนอุปกรณ์ Raspberry Pi 4 และพบว่าการลดระดับการบีบอัดข้อมูลช่วยเพิ่มประสิทธิภาพเชิงพลังงานได้ แต่ในขณะเดียวกันก็ส่งผลให้ความแม่นยำลดลงในงานที่ต้องการความละเอียดสูง ซึ่งเป็นข้อค้นพบที่มีนัยสำคัญต่อการเลือกระดับการบีบอัดแบบจำลองสำหรับโครงงานนี้ ในทำนองเดียวกัน Cai et al. (2024) ได้เสนอกรอบการทำงานร่วมกันระหว่างอุปกรณ์ Edge และเซิร์ฟเวอร์คลาวด์ (Edge-LLM)

โดยใช้เทคนิคการบีบอัดแบบปรับตัวได้ร่วมกับกลไกแคชและการจัดลำดับงาน
เพื่อลดภาระของหน่วยประมวลผลกราฟิกโดยไม่ลดทอนความแม่นยำ อย่างไรก็ตาม
แนวทางดังกล่าวยังคงอาศัยการเชื่อมต่อกับคลาวด์บางส่วน
จึงมีข้อจำกัดเมื่อนำไปใช้ในบริบทที่ต้องการตัดขาดจากเครือข่ายภายนอกโดยสมบูรณ์ตามที่โครงงานนี้กำหนดไว้

ในมิติของสถาปัตยกรรมฮาร์ดแวร์ Moon et al. (2025) ได้นำเสนอระบบผสมผสานระหว่าง GPU และ NPU (Hybe)
เพื่อแก้ปัญหาความไม่สมดุลด้านการประมวลผลระหว่างขั้นตอน Prefill และ Decode
ของการอนุมานแบบจำลองภาษาที่มีหน้าต่างบริบทขนาดใหญ่ระดับล้านโทเคน โดยอาศัยฮาร์ดแวร์ระดับสูงได้แก่ NVIDIA H100 ร่วมกับ
NPU ที่ผลิตขึ้นเฉพาะด้วยเทคโนโลยี 4 นาโนเมตร ซึ่งแม้จะให้ผลลัพธ์ด้านความเร็วและประสิทธิภาพพลังงานที่โดดเด่น
แต่ด้วยต้นทุนและขนาดของฮาร์ดแวร์ดังกล่าว ทำให้แนวทางนี้ไม่สอดคล้องกับข้อจำกัดของ Edge Server ขนาดเล็กที่ใช้ในที่พักอาศัย
ในทางกลับกัน Yin et al. (2026) ได้นำเสนอแนวทางที่ใกล้เคียงกับบริบทของโครงงานนี้มากกว่า โดยออกแบบโมดูล Sparse Attention
ที่คำนวณเฉพาะโทเคนสำคัญด้วย NPU บนสมาร์ตโฟน
เพื่อลดการพึ่งพาหน่วยประมวลผลกลางและหน่วยประมวลผลกราฟิกให้เหลือน้อยที่สุด
อันเป็นแนวคิดที่สามารถนำมาประยุกต์ใช้กับการออกแบบ NPU-centric Local LLM ของโครงงานนี้ได้
แม้ว่างานวิจัยดังกล่าวจะทดสอบเฉพาะบนอุปกรณ์สมาร์ตโฟน ยังไม่มีการทดสอบบนอุปกรณ์ประเภท Single-Board Computer หรือ Edge
Server ตามที่โครงงานนี้ออกแบบไว้ก็ตาม

เพื่อแสดงให้เห็นถึงความสามารถในการประยุกต์ใช้หลักการ Edge/Local AI ข้ามศาสตร์วิชา งานทบทวนวรรณกรรมของ Oloko-Oba et al.
(2026) ในสาขาวิศวกรรมชีวการแพทย์ได้แสดงให้เห็นว่าแนวคิดการประมวลผลข้อมูลภายในอุปกรณ์เป็นหลัก
และใช้คลาวด์เพียงเพื่อแสดงผลสรุปหรือดำเนินการจัดการวงจรชีวิตของระบบ
สามารถนำไปประยุกต์ใช้ได้ผลดีในบริบทของการติดตามสุขภาพด้วยอุปกรณ์สวมใส่เช่นกัน แม้ว่าจะมีความท้าทายเฉพาะด้าน อาทิ
สัญญาณรบกวนของข้อมูลภาคสนามและความล่าช้าของป้ายกำกับข้อมูล ซึ่งสะท้อนให้เห็นว่ารูปแบบสถาปัตยกรรม Local-first ร่วมกับ
Cloud-assist แบบจำกัดเฉพาะการแสดงผลนั้น เป็นรูปแบบที่ใช้ได้ผลในหลากหลายบริบทการประยุกต์ใช้งาน
ไม่จำกัดเฉพาะสายวิทยาการคอมพิวเตอร์เท่านั้น

นอกเหนือจากมิติของฮาร์ดแวร์และการบีบอัดแบบจำลองแล้ว งานสำรวจของ Zheng et al. (2025) ได้ประมวลภาพรวมของสายงาน edge
LLM ตั้งแต่การออกแบบแบบจำลองไปจนถึงการอนุมานขณะรันไทม์
ซึ่งชี้ให้เห็นว่าการบีบอัดแบบจำลองเพียงอย่างเดียวไม่เพียงพอต่อการรับประกันคุณภาพผลลัพธ์ที่มีโครงสร้าง (structured output)
อันเป็นรูปแบบที่จำเป็นสำหรับงานสกัดข้อมูลของโครงงานนี้ Giedra et al. (2026)
ยืนยันเชิงประจักษ์เพิ่มเติมว่าระดับการบีบอัดแบบจำลองขนาด sub-1B ถึง 8B ส่งผลโดยตรงต่อทั้งความเร็วและความแม่นยำบนอุปกรณ์
NVIDIA Jetson ในขณะที่สายงานการบังคับโครงสร้างผลลัพธ์ Zheng et al. (2024) นำเสนอ SGLang ซึ่งใช้เทคนิค compressed finite
state machine เร่ง throughput ของ grammar-constrained decoding ได้สูงถึง 6.4 เท่าเมื่อเทียบกับระบบอนุมานทั่วไป
แต่ทดสอบบนฮาร์ดแวร์ระดับ data center มิใช่ edge NPU และ Hu et al. (2025) พัฒนา mPLUG-DocOwl2
สำหรับความเข้าใจเอกสารหลายหน้าแบบ OCR-free ที่ลดจำนวน visual token ได้มากกว่า 80% แต่เป็นแบบจำลองขนาดใหญ่
ยังไม่ได้ออกแบบมาเพื่อทำงานร่วมกับ quantized local LLM บน SBC งานทั้งสองฉบับนี้ชี้ให้เห็นว่าการบังคับ schema
ระหว่างการถอดรหัสส่งผลโดยตรงต่อทั้งความเร็วและความถูกต้องของ JSON output
แต่ยังไม่มีงานใดวัดผลกระทบนี้ร่วมกับระดับการบีบอัดแบบจำลองบนอุปกรณ์ edge NPU ทรัพยากรจำกัดพร้อมกัน

ในชั้นปลายน้ำของสถาปัตยกรรม Rivkin et al. (2025) นำเสนอตัวแทน LLM อัตโนมัติสำหรับควบคุมอุปกรณ์ในบ้านอัจฉริยะ (AIoT smart
home) ซึ่งแสดงให้เห็นศักยภาพของ LLM ในการเชื่อมต่อกับระบบ IoT ในครัวเรือน แต่มิได้กล่าวถึงข้อจำกัดด้านฮาร์ดแวร์ระดับ SBC
หรือความแม่นยำของการสกัดข้อมูลเชิงโครงสร้างที่ส่งต่อมาจากชั้นก่อนหน้า Sawalha and Al-Naymat (2025) เสนอแบบจำลอง Adaptive
Holt–Winters สำหรับพยากรณ์ข้อมูลอนุกรมเวลาตามฤดูกาลจากข้อมูล IoT

ซึ่งสามารถประยุกต์ใช้กับการพยากรณ์อัตราการสิ้นเปลืองสินค้าในครัวเรือน (burn rate) ได้ในเชิงหลักการ และ Serepas et al. (2025) นำเสนอการออกแบบ IoT gateway น้ำหนักเบาบนไมโครคอนโทรลเลอร์ ESP32 ที่รองรับโปรโตคอล MQTT สำหรับเชื่อมต่ออุปกรณ์ edge เข้ากับระบบบ้านอัจฉริยะ ซึ่งสอดคล้องโดยตรงกับ stage การเชื่อมต่อ Home Assistant ผ่าน MQTT ในสถาปัตยกรรมของโครงงานนี้ อย่างไรก็ตาม ทั้งสามงานนี้ศึกษาเฉพาะชั้นการเชื่อมต่อและการพยากรณ์ปลายน้ำ
โดยไม่ได้เชื่อมโยงย้อนกลับไปถึงความแม่นยำของการสกัดข้อมูลต้นทางจาก LLM ภายใต้ข้อจำกัดด้าน quantization และ decoding ที่กล่าวถึงข้างต้น

โดยสรุป จากการทบทวนวรรณกรรมทั้ง 12 ฉบับ พบว่างานวิจัยที่ผ่านมาให้ความสำคัญกับนำ NPU และเทคนิคการบีบอัดแบบจำลองมาใช้เพื่อให้การประมวลผลปัญญาประดิษฐ์เกิดขึ้นใกล้แหล่งข้อมูลมากที่สุดอย่างสม่ำเสมอ ทั้งในชั้นฮาร์ดแวร์ ชั้นการบังคับโครงสร้างผลลัพธ์ และชั้นการประยุกต์ใช้งานปลายน้ำ แต่ยังมีความแตกต่างกันในระดับการพึ่งพาคลาวด์และขนาด/ต้นทุนของฮาร์ดแวร์ที่ใช้ทดลองในแต่ละสายงาน อีกทั้งยังไม่พบงานวิจัยฉบับใดที่บูรณาการองค์ประกอบทั้งหมด ตั้งแต่การตรวจจับเอกสารด้วยกล้อง การสกัดข้อความ การประมวลผลด้วย Local LLM จนถึงการเชื่อมต่อกับระบบบ้านอัจฉริยะเพื่อพยากรณ์พฤติกรรมการบริโภคในครัวเรือน ช่องว่างทางความรู้ดังกล่าวจึงเป็นที่มาและเป็นเป้าหมายหลักที่โครงงานวิทยานิพนธ์นี้มุ่งศึกษาและพัฒนาต่อไป

รายการอ้างอิง (References)

Cai, F., Yuan, D., Yang, Z., & Cui, L. (2024). Edge-LLM: A collaborative framework for large language model serving in edge computing. In 2024 IEEE International Conference on Web Services (ICWS) (pp. 799–809). https://doi.org/10.1109/ICWS62655.2024.00099

Husom, E. J., Goknil, A., Astekin, M., Shar, L. K., Kåsen, A., Sen, S., Mithassel, B. A., & Soylu, A. (2025). Sustainable LLM inference for edge AI: Evaluating quantized LLMs for energy efficiency, output accuracy, and inference latency. ACM Transactions on Internet of Things, 6(4), Article 28. https://doi.org/10.1145/3767742

Moon, S., Cha, J., Park, H., & Kim, J.-Y. (2025). Hybe: GPU-NPU hybrid system for efficient LLM inference with million-token context window. In Proceedings of the 52nd Annual International Symposium on Computer Architecture (ISCA 2025) (pp. 808–820). https://doi.org/10.1145/3695053.3731051

Yin, W., Xu, D., Xu, M., Huang, G., Liu, X., Mascolo, C., & Kawsar, F. (2026). ShadowNPU: System and algorithm co-design for NPU-centric on-device LLM inference. In Proceedings of the 24th Annual International Conference on Mobile Systems, Applications and Services (MobiSys 2026) (pp. 294–308). https://doi.org/10.1145/3745756.3809205

Oloko-Oba, M., Esenogho, E., & Aruleba, K. (2026). From biosignals to bedside: A review of real-time edge machine learning for wearable health monitoring. Bioengineering, 13(5), 559. https://doi.org/10.3390/bioengineering13050559

Zheng, Y., Chen, Y., Qian, B., Shi, X., Shu, Y., & Chen, J. (2025). A review on edge large language models: Design, execution, and applications. ACM Computing Surveys, 57(8), Article 209. https://doi.org/10.1145/3719664

Rivkin, D., Hogan, F., Feriani, A., Konar, A., Sigal, A., Liu, X., & Dudek, G. (2025). AIoT smart home via autonomous LLM agents. IEEE Internet of Things Journal, 12(3), 2458-2472. https://doi.org/10.1109/JIOT.2024.3471904

Zheng, L., Yin, L., Xie, Z., Sun, C. L., Huang, J., Yu, C. H., Cao, S., Kozyrakis, C., Stoica, I., Gonzalez, J. E., Barrett, C., & Sheng, Y. (2024). SGLang: Efficient execution of structured language model programs. Advances in Neural Information Processing Systems, 37, 62557-62583. https://doi.org/10.5555/3737916.3739916

Hu, A., Xu, H., Zhang, L., Ye, J., Yan, M., Zhang, J., Jin, Q., Huang, F., & Zhou, J. (2025). mPLUG-DocOwl2: High-resolution compressing for OCR-free multi-page document understanding. In Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers) (pp. 5817-5834). Association for Computational Linguistics. https://doi.org/10.18653/v1/2025.acl-long.291

Giedra, H., MatuzeviČius, D., SledeviČ, T., Shubitidze, G., & Serackis, A. (2026). Benchmarking large language model inference on limited-resource edge systems. Electronics, 15(11), Article 2451. https://doi.org/10.3390/electronics15112451

Sawalha, S., & Al-Naymat, G. (2025). An adaptive Holt-Winters model for seasonal forecasting of Internet of Things (IoT) data streams. IoT, 6(3), Article 39. https://doi.org/10.3390/iot6030039

Serepas, F., Papias, I., Christakis, K., Dimitropoulos, N., & Marinakis, V. (2025). Lightweight embedded IoT gateway for smart homes based on an ESP32 microcontroller. Computers, 14(9), Article 391. https://doi.org/10.3390/computers14090391

ความเห็นของอาจารย์ที่ปรึกษาโครงงาน

_____

_____

ลายเซ็น .....