

การพัฒนาระบบประสาทส่วนกลางอัจฉริยะในที่พักอาศัยเพื่อสกัดและวิเคราะห์ข้อมูลห่วงโซ่อุปทานในครัวเรือนด้วยปัญญาประดิษฐ์ประมวลผลเฉพาะถิ่น

Development of a Localized Residential Intelligence Engine for Household Supply-Chain Analytics Using Edge Computing and Home Network Infrastructure

จัดทำโดย

673380267-4 นายณัชพล เพ็งพล

673380270-5 นายธนบดี เริ่มรักสกุล

อาจารย์ที่ปรึกษา ผศ.บุญทรัพย์ ไวคำ

รายงานฉบับนี้เป็นส่วนหนึ่งของการศึกษาค้นคว้าประกอบวิทยานิพนธ์

สาขาวิชาวิทยาการคอมพิวเตอร์

มหาวิทยาลัยขอนแก่น

ปีการศึกษา 2569

บทคัดย่อ

รายงานฉบับนี้จัดทำขึ้นเพื่อทบทวนและสังเคราะห์วรรณกรรมด้านการอนุมานแบบจำลองภาษาขนาดใหญ่บนอุปกรณ์ประมวลผลเฉพาะถิ่น (on-device LLM inference) อันเป็นองค์ความรู้พื้นฐานสำหรับการพัฒนาระบบประสาทส่วนกลางอัจฉริยะในที่พักอาศัยเพื่อสกัดและวิเคราะห์ข้อมูลห่วงโซ่อุปทานในครัวเรือน โดยมีวัตถุประสงค์เพื่อสรุปสาระสำคัญของงานวิจัยที่เกี่ยวข้องและระบุประเด็นที่จะนำไปใช้ต่อยอดในการพัฒนาโครงงาน การศึกษานี้ดำเนินการโดยทบทวนบทความวิจัยที่ผ่านการตรวจสอบสถานะการจัดทำดัชนีในฐานข้อมูล Scopus จำนวน 12 ฉบับ จัดกลุ่มตามกรอบ Performance Trade-off สามมิติ ได้แก่ quantization/hardware trade-off, grammar-constrained decoding/structured output และบริบทบ้านอัจฉริยะ/IoT ปลายน้ำ พร้อมทั้งวิเคราะห์เปรียบเทียบด้วย Synthesis Matrix ผลการทบทวนวรรณกรรมพบว่างานวิจัยที่ผ่านมามีแนวโน้มศึกษาปัจจัยด้านประสิทธิภาพของ on-device LLM inference แยกออกจากกันเป็นสามมิติ โดยไม่มีงานใดประเมินปฏิสัมพันธ์ร่วมกันของทั้งสามมิตินี้บนอุปกรณ์ single-board computer (SBC) ที่มีทรัพยากรจำกัดจริงในบริบทที่พักอาศัย ช่องว่างทางความรู้ดังกล่าวชี้ให้เห็นถึงโอกาสในการบูรณาการองค์ประกอบทั้งหมด ตั้งแต่การตรวจจับเอกสารด้วยกล้อง การสกัดข้อความ การประมวลผลด้วย Local LLM จนถึงการเชื่อมต่อกับระบบบ้านอัจฉริยะเพื่อพยากรณ์พฤติกรรมการบริโภคในครัวเรือน ผลการทบทวนวรรณกรรมนี้สามารถนำไปใช้เป็นกรอบแนวคิดและแนวทางการออกแบบสถาปัตยกรรมของระบบสำหรับการดำเนินงานวิทยานิพนธ์ในขั้นต่อไป

คำสำคัญ: การประมวลผลเฉพาะถิ่น (Edge/Local AI), แบบจำลองภาษาขนาดใหญ่ (LLM), การบีบอัดแบบจำลอง (Quantization), บ้านอัจฉริยะ (Smart Home), ห่วงโซ่อุปทานครัวเรือน

คำนำ

รายงานฉบับนี้จัดทำขึ้นเพื่อประกอบการศึกษาในหัวข้อวิทยานิพนธ์เรื่อง"การพัฒนาระบบประสาทส่วนกลางอัจฉริยะในที่พักอาศัยเพื่อสกัดและวิเคราะห์ข้อมูลห่วงโซ่อุปทานในครัวเรือนด้วยปัญญาประดิษฐ์ประมวลผลเฉพาะถิ่น" โดยมีจุดมุ่งหมายเพื่อทบทวนและสังเคราะห์ทฤษฎีและงานวิจัยที่เกี่ยวข้องกับการอนุมานแบบจำลองภาษาขนาดใหญ่บนอุปกรณ์ประมวลผลเฉพาะถิ่นอันจะเป็นพื้นฐานสำคัญสำหรับการออกแบบสถาปัตยกรรมและการดำเนินงานวิทยานิพนธ์ในขั้นต่อไป

ผู้จัดทำขอขอบพระคุณอาจารย์ที่ปรึกษาโครงงานที่ได้ให้คำแนะนำและข้อเสนอแนะอันเป็นประโยชน์ต่อการทบทวนวรรณกรรมและการกำหนดกรอบแนวคิดของงานวิจัยตลอดมา หากรายงานฉบับนี้มีข้อบกพร่องประการใด ผู้จัดทำขอน้อมรับไว้เพื่อปรับปรุงแก้ไขในโอกาสต่อไป

คณะผู้จัดทำ

สารบัญ

บทคัดย่อ.....ก
คำนำ.....ข
สารบัญตาราง.....ค
สารบัญภาพ.....ง
บทที่ 1 บทนำ.....1
1.1 ที่มาและความสำคัญ.....1
1.2 จุดประสงค์ของการศึกษา.....2
1.3 ขอบเขตของการศึกษา.....3
1.4 ประโยชน์ที่คาดว่าจะได้รับ.....3
บทที่ 2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง.....4
2.1 งานวิจัยที่เกี่ยวข้อง (5W1H).....4
2.2 ทฤษฎีที่เกี่ยวข้อง.....8
2.3 เปรียบเทียบผลการศึกษา.....9
บทที่ 3 สรุปผลการศึกษา.....22
3.1 สรุปผล.....22
3.2 แนวทางการนำไปใช้.....22
3.3 สถาปัตยกรรมเชิงแนวคิด (Conceptual Architecture).....23
3.4 แผนการดำเนินงาน (Implementation Roadmap).....24
เอกสารอ้างอิง.....25

สารบัญตาราง

ตารางที่ 1 เปรียบเทียบ P1–P3 (quantization/hardware trade-off).....10
ตารางที่ 2 เปรียบเทียบ P4–P5 (quantization/hardware trade-off และ cross-disciplinary motivation).....11
ตารางที่ 3 เปรียบเทียบ P6, P10 (quantization/hardware trade-off เพิ่มเติม).....12
ตารางที่ 4 เปรียบเทียบ P8–P9 (grammar-constrained decoding/structured output).....12
ตารางที่ 5 เปรียบเทียบ P7, P11–P12 (บริบทบ้านอัจฉริยะ/IoT ปลายน้ำ).....13
ตารางที่ 6 Implementation Roadmap.....24

สารบัญภาพ

ภาพที่ 1 สถาปัตยกรรมระบบประสาทส่วนกลางอัจฉริยะในที่พักอาศัย (Local/Edge AI Pipeline).....2
ภาพที่ 2 กระบวนการคัดกรองบทความวิจัย (Ring0 n=57 ⟶ ใช้ในรายงาน n=12).....10
ภาพที่ 3 ช่องว่างทางความรู้ — ปฏิสัมพันธ์ร่วมกันของ 3 มิติที่ยังไม่มีงานวิจัยศึกษา.....16

บทที่ 1 บทนำ

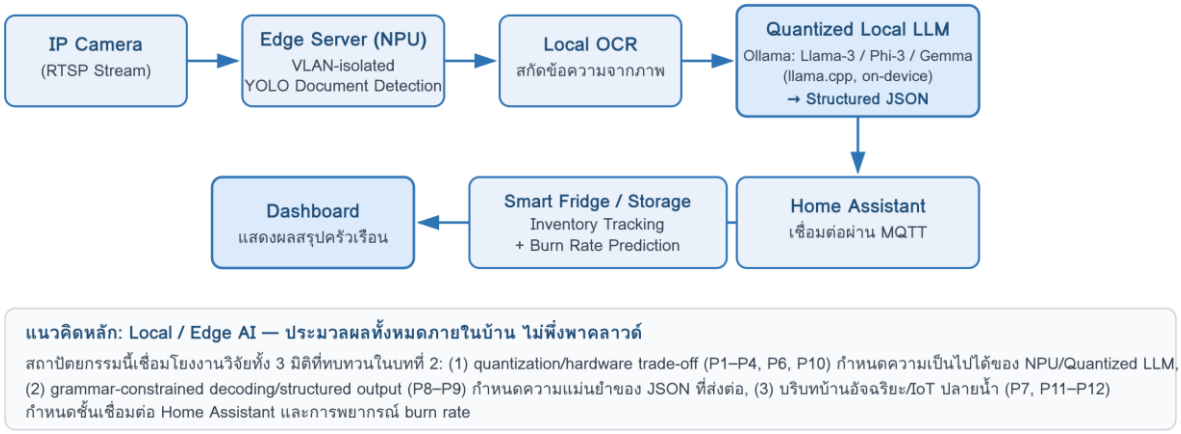
1.1 ที่มาและความสำคัญ

ในยุคที่ปัญญาประดิษฐ์แบบประมวลผลเฉพาะถิ่น (Local/Edge AI) เข้ามามีบทบาทมากขึ้นในชีวิตประจำวัน การนำแบบจำลองภาษาขนาดใหญ่ (Large Language Model, LLM) มาประมวลผลโดยตรงบนอุปกรณ์ในที่พักอาศัย โดยไม่ต้องพึ่งพาการเชื่อมต่อคลาวด์ ได้กลายเป็นแนวทางที่ตอบโจทย์ทั้งด้านความเป็นส่วนตัวของข้อมูล ความหน่วงในการตอบสนอง และต้นทุนการใช้งานระยะยาว โครงงานวิทยานิพนธ์ที่ผู้จัดทำดำเนินการมุ่งพัฒนาระบบประสาทส่วนกลางอัจฉริยะในที่พักอาศัยเพื่อสกัดและวิเคราะห์ข้อมูลห่วงโซ่อุปทานในครัวเรือน โดยอาศัยสถาปัตยกรรมที่เชื่อมโยงตั้งแต่กล้อง IP Camera ตรวจจับเอกสาร (YOLO) การสกัดข้อความด้วย OCR การประมวลผลด้วย Quantized Local LLM เพื่อสร้างโครงสร้างข้อมูล JSON และการเชื่อมต่อเข้ากับระบบบ้านอัจฉริยะ (Home Assistant ผ่าน MQTT) สำหรับพยากรณ์อัตราการสิ้นเปลืองสินค้าในครัวเรือน (burn rate)

จากการทบทวนวรรณกรรมเบื้องต้นที่เกี่ยวข้องกับการอนุมานแบบจำลองภาษาขนาดใหญ่บนอุปกรณ์ประมวลผลเฉพาะถิ่น (on-device LLM inference) พบว่างานวิจัยที่ผ่านมามีแนวโน้มศึกษาปัจจัยด้านประสิทธิภาพแยกออกจากกันเป็นสามมิติหลัก ได้แก่ การบีบอัดแบบจำลองและสถาปัตยกรรมฮาร์ดแวร์ (quantization/hardware trade-off) การบังคับโครงสร้างผลลัพธ์ (grammar-constrained decoding/structured output) และการประยุกต์ใช้งานในบริบทบ้านอัจฉริยะ/IoT ปลายน้ำ โดยยังไม่มีงานวิจัยฉบับใดประเมินปฏิสัมพันธ์ร่วมกันของทั้งสามมิตินี้ บนอุปกรณ์ single-board computer (SBC) ที่มีทรัพยากรจำกัดจริงในบริบทที่พักอาศัย ช่องว่างดังกล่าวส่งผลให้ยังไม่มีแนวทางเชิงปฏิบัติที่ยืนยันได้ว่าการบีบอัดแบบจำลองในระดับที่เหมาะสมกับ Edge Server ต้นทุนต่ำ จะยังคงให้ผลลัพธ์ JSON ที่มีโครงสร้างถูกต้องเพียงพอสำหรับงานสกัดข้อมูลใบเสร็จและฉลากสินค้าในครัวเรือนหรือไม่

Innovation ที่โครงงานนี้นำเสนอ คือการผสานทั้งสามมิติดังกล่าวเข้าด้วยกันในสถาปัตยกรรมเดียวบนอุปกรณ์ระดับ SBC/Edge Server ต้นทุนต่ำ โดยใช้กล้อง IP Camera ตรวจจับเอกสารด้วย YOLO ร่วมกับ OCR สกัดข้อความ แล้วส่งต่อให้ Quantized Local LLM ที่ควบคุมด้วยเทคนิค Grammar-Constrained Decoding ประมวลผลบนหน่วยประมวลผลเฉพาะทาง (NPU-centric) เพื่อแปลงข้อมูลใบเสร็จและฉลากสินค้าให้เป็นโครงสร้าง JSON ที่แม่นยำ ก่อนเชื่อมต่อเข้าสู่ระบบบ้านอัจฉริยะ (Home Assistant ผ่าน MQTT) สำหรับพยากรณ์อัตราการสิ้นเปลืองสินค้าในครัวเรือน (burn rate) จุดที่แตกต่างจากงานวิจัยที่ทบทวนมาคือการออกแบบให้ “ชั้นบีบอัดแบบจำลอง” “ชั้นบังคับโครงสร้างผลลัพธ์” และ

“ชั้นประยุกต์ใช้งานปลายน้ำ” ทำงานประสานกันภายใต้เงื่อนไขฮาร์ดแวร์เดียวกัน แทนที่จะออกแบบและประเมินแยกส่วนดังที่ปรากฏในงานวิจัยที่ทบทวนมา



ภาพที่ 1: สถาปัตยกรรมระบบประสาทส่วนกลางอัจฉริยะในที่พักอาศัย (Local/Edge AI Pipeline)

ก่อนดำเนินการออกแบบและพัฒนาระบบดังกล่าว จึงมีความจำเป็นต้องทบทวนทฤษฎีและงานวิจัยที่เกี่ยวข้องอย่างเป็นระบบ เพื่อสรุปสาระสำคัญ ระบุแนวทางเทคนิคที่มีอยู่ในปัจจุบัน และยืนยันช่องว่างทางความรู้ (research gap) ข้างต้น ที่จะนำไปใช้ต่อยอดในการกำหนดสถาปัตยกรรมเชิงแนวคิดและแผนการดำเนินงานของโครงงานในบทที่ 3 ต่อไป

1.2 จุดประสงค์ของการศึกษา

- เพื่อออกแบบและพัฒนาสถาปัตยกรรมระบบประสาทส่วนกลางอัจฉริยะในที่พักอาศัย ที่บูรณาการชั้นตรวจจับเอกสารด้วยกล้อง (YOLO) ชั้นประมวลผลด้วย NPU-centric Quantized Local LLM ร่วมกับ Grammar-Constrained Decoding และชั้นเชื่อมต่อระบบบ้านอัจฉริยะ (Home Assistant ผ่าน MQTT) สำหรับสกัดและวิเคราะห์ข้อมูลห่วงโซ่อุปทานในครัวเรือน

- เพื่อพัฒนากลไกเลือกระดับการบีบอัดแบบจำลอง (Quantization) และควบคุมโครงสร้างผลลัพธ์ด้วย Grammar-Constrained Decoding ที่เหมาะสมกับ Edge Server ทรัพยากรจำกัดในบริบทที่พักอาศัย โดยอาศัยผลการวิเคราะห์ trade-off ระหว่างความแม่นยำและพลังงานจากงานวิจัยที่เกี่ยวข้อง

- เพื่อสร้างต้นแบบระบบ (Prototype System) ที่สามารถแปลงข้อมูลจากใบเสร็จและฉลากสินค้าให้เป็นโครงสร้าง JSON ที่แม่นยำ และพยากรณ์อัตราการสิ้นเปลืองสินค้า (burn rate) ของครัวเรือนได้

- เพื่อทบทวนและสังเคราะห์ทฤษฎีและงานวิจัยที่เกี่ยวข้องกับการอนุมานแบบจำลองภาษาขนาดใหญ่บนอุปกรณ์ประมวลผลเฉพาะถิ่น (on-device LLM inference) ครอบคลุมสามมิติของกรอบ Performance Trade-off ได้แก่ quantization/hardware trade-off, grammar-constrained decoding/structured output และบริบทบ้านอัจฉริยะ/IoT ปลายน้ำ พร้อมสรุปในรูปแบบ Synthesis Matrix เพื่อระบุจุดที่เห็นตรงกัน จุดที่ขัดแย้งกัน และช่องว่างทางความรู้ (research gap) อันเป็นพื้นฐานสำหรับการดำเนินงานข้างต้น

- เพื่อวางแผนการดำเนินงาน (Implementation Roadmap) เป็นระยะ สำหรับขั้นตอนการพัฒนาต้นแบบ การเก็บข้อมูลนำร่อง (Pilot) และการประเมินผลของวิทยานิพนธ์ในขั้นต่อไป

1.3 ขอบเขตของการศึกษา

การศึกษาครั้งนี้ครอบคลุมบทความวิจัยที่เกี่ยวข้องกับโครงงานจำนวน 12 ฉบับ ซึ่งผ่านการตรวจสอบสถานะการจัดทำดัชนีในฐานข้อมูล Scopus แล้ว โดยจัดกลุ่มตาม 3 มิติของกรอบ Performance Trade-off ที่โครงงานนี้มุ่งศึกษา ได้แก่ (1) quantization/hardware trade-off (2) grammar-constrained decoding/structured output และ (3) บริบทบ้านอัจฉริยะ/IoT ปลายน้ำ โดยมีบทความวิจัยเพิ่มเติมอีก 1 ฉบับ ที่ใช้เป็นหลักฐานสนับสนุนเชิง cross-disciplinary motivation จากสาขาวิศวกรรมชีวการแพทย์ ทั้งนี้การศึกษาจำกัดขอบเขตอยู่ที่การทบทวนวรรณกรรม และการสังเคราะห์องค์ความรู้เพื่อระบุช่องว่างทางความรู้เท่านั้น ยังไม่รวมถึงการทดลองหรือการพัฒนาระบบจริง ซึ่งจะดำเนินการในขั้นตอนถัดไปของวิทยานิพนธ์

1.4 ประโยชน์ที่คาดว่าจะได้รับ

- ได้กรอบแนวคิด (conceptual framework) ที่ชัดเจนสำหรับการออกแบบสถาปัตยกรรมของระบบในขั้นตอนการพัฒนาวิทยานิพนธ์

- ทราบถึงจุดแข็ง ข้อจำกัด และช่องว่างทางความรู้ของงานวิจัยที่เกี่ยวข้อง ซึ่งช่วยลดความซ้ำซ้อนกับงานวิจัยที่มีอยู่แล้ว

- ได้แนวทางเชิงเทคนิคที่สามารถนำไปประยุกต์ใช้หรือปรับปรุงสำหรับการพัฒนาระบบภายใต้ทรัพยากรจำกัดของ Edge Server ในบริบทที่พักอาศัย

- เป็นพื้นฐานสำหรับการเขียนรายงานและบทความทางวิชาการในขั้นตอนถัดไปของการทำวิทยานิพนธ์

บทที่ 2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 งานวิจัยที่เกี่ยวข้อง (5W1H)

เพื่อให้เห็นภาพรวมของงานวิจัยที่เกี่ยวข้องทั้ง 12 ฉบับอย่างเป็นระบบ ผู้จัดทำได้สรุปสาระสำคัญของกลุ่มงานวิจัยตามหลักการตั้งคำถาม 5W1H ดังนี้

- Who (ใครเป็นผู้ศึกษา): กลุ่มนักวิจัยด้าน edge computing, computer architecture และ natural language processing จากสถาบันและวารสาร/การประชุมวิชาการที่ผ่านการทำดัชนีในฐานข้อมูล Scopus เช่น IEEE ICWS, ACM Transactions on Internet of Things, ISCA, ACM MobiSys, ACM Computing Surveys และวารสาร Bioengineering, Electronics, IoT, Computers

- What (ศึกษาอะไร): ประสิทธิภาพของการอนุมานแบบจำลองภาษาขนาดใหญ่ (LLM inference) บนอุปกรณ์ที่มีทรัพยากรจำกัด ครอบคลุม 3 มิติ ได้แก่ การบีบอัดแบบจำลองและสถาปัตยกรรมฮาร์ดแวร์ (quantization/hardware), การบังคับโครงสร้างผลลัพธ์ (grammar-constrained decoding/structured output) และการประยุกต์ใช้งานในบริบทบ้านอัจฉริยะ/IoT ปลายน้ำ

- Where (ศึกษาที่ไหน/บนแพลตฟอร์มใด): ครอบคลุมแพลตฟอร์มฮาร์ดแวร์หลากหลายระดับ ตั้งแต่อุปกรณ์ edge ทั่วไป สมาร์ตโฟน Single-Board Computer (เช่น Raspberry Pi 4, NVIDIA Jetson Orin Nano) ไมโครคอนโทรลเลอร์ (ESP32) ไปจนถึงฮาร์ดแวร์ระดับเซิร์ฟเวอร์/data center (NVIDIA H100)

- When (ช่วงเวลาของงานวิจัย): งานวิจัยที่ทบทวนตีพิมพ์ในช่วงปี ค.ศ. 2024–2026 สะท้อนถึงความก้าวหน้าและความสนใจของวงการวิชาการต่อประเด็น on-device LLM inference ในช่วงที่ผ่านมาอย่างต่อเนื่อง

- Why (เหตุใดจึงศึกษาประเด็นนี้): เนื่องจากการประมวลผล LLM บนคลาวด์แบบดั้งเดิมมีข้อจำกัดด้านความเป็นส่วนตัวของข้อมูล ความหน่วง และต้นทุนการใช้งานระยะยาว การประมวลผลแบบเฉพาะถิ่น

(on-device) จึงเป็นแนวทางที่ตอบโจทย์การใช้งานจริงในบริบทที่ต้องรักษาความเป็นส่วนตัวของข้อมูลครัวเรือน

- How (ศึกษาด้วยวิธีใด): ใช้ทั้งวิธีการทดลองเชิงประจักษ์ (benchmark การวัด accuracy, latency, throughput, พลังงาน) การนำเสนอสถาปัตยกรรม/อัลกอริทึมใหม่ และการทบทวนวรรณกรรมเชิงระบบ (systematic/narrative review) เพื่อสังเคราะห์องค์ความรู้ในสายงานที่เกี่ยวข้อง

เพื่อให้เห็นภาพรวมของงานวิจัยที่เกี่ยวข้องทั้ง 12 ฉบับในเชิงลึกเป็นรายฉบับ นอกเหนือจากภาพรวมตามหลัก 5W1H ข้างต้น หัวข้อย่อยต่อไปนี้สรุปสาระสำคัญของงานวิจัยแต่ละฉบับ พร้อมระบุจุดที่จะนำไปประยุกต์ใช้หรือเป็นข้อจำกัดที่โครงงานนี้ต้องพิจารณาต่อไป

2.1.1 กรอบการทำงานร่วมกันระหว่าง Edge และคลาวด์สำหรับการให้บริการ LLM (Cai et al., 2024)

งานวิจัยนี้เสนอกรอบการทำงาน Edge-LLM ซึ่งให้อุปกรณ์ Edge ทั่วไปทำงานร่วมกับเซิร์ฟเวอร์คลาวด์แบบ Hybrid โดยใช้เทคนิค Adaptive Quantization ร่วมกับกลไกแคช (FM Cache) และการจัดลำดับงานแบบ Value-Density-First (VDF) Scheduling เพื่อลดภาระของหน่วยประมวลผลกราฟิกโดยไม่ลดทอนความแม่นยำ อย่างไรก็ตาม แนวทางนี้ยังคงต้องพึ่งพาการเชื่อมต่อคลาวด์บางส่วน จึงมีข้อจำกัดเมื่อนำไปใช้ในบริบทที่ต้องตัดขาดจากเครือข่ายภายนอกโดยสมบูรณ์ตามที่โครงงานนี้กำหนดไว้

2.1.2 การประเมินความยั่งยืนของ Quantized LLM บนอุปกรณ์ Edge (Husom et al., 2025)

คณะผู้วิจัยประเมินแบบจำลอง Quantized LLM จำนวน 28 แบบจำลองจาก Ollama บน Raspberry Pi 4 (RAM 4GB) ที่ประมวลผลด้วย CPU เพียงอย่างเดียว โดยวัดพลังงานจริงด้วยอุปกรณ์ Joulescope ครอบคลุมทั้งด้าน Energy Efficiency ความแม่นยำ และความหน่วงในการอนุมาน ผลการทดลองพบว่าการบีบอัดแบบจำลองที่มากขึ้นช่วยเพิ่มประสิทธิภาพเชิงพลังงาน แต่ส่งผลให้ความแม่นยำลดลงในงานที่ต้องการความละเอียดสูง ซึ่งเป็นข้อค้นพบสำคัญต่อการเลือกระดับการบีบอัดของโครงงานนี้

2.1.3 สถาปัตยกรรม GPU-NPU แบบผสมสำหรับการอนุมานบริบทขนาดใหญ่ (Moon et al., 2025)

งานวิจัยนี้นำเสนอ Hybe ระบบผสมผสานระหว่าง GPU และ NPU เพื่อแก้ปัญหาความไม่สมดุลด้านการประมวลผลระหว่างขั้นตอน Prefill และ Decode ของการอนุมานแบบจำลองภาษาที่มีหน้าต่างบริบทระดับล้านโทเคน โดยอาศัยฮาร์ดแวร์ระดับสูง NVIDIA H100 ร่วมกับ NPU ที่ผลิตขึ้นเฉพาะด้วยเทคโนโลยี 4 นาโนเมตร แม้ให้ผลลัพธ์ด้านความเร็วและประสิทธิภาพพลังงานที่โดดเด่น แต่ด้วยต้นทุนและ

ขนาดของฮาร์ดแวร์ดังกล่าว ทำให้แนวทางนี้ไม่สอดคล้องกับข้อจำกัดของ Edge Server ขนาดเล็กในที่พักอาศัย

2.1.4 ShadowNPU: การอนุมาน LLM บนอุปกรณ์ที่เน้น NPU เป็นศูนย์กลาง (Yin et al., 2026)

ทีมวิจัยออกแบบโมดูล Sparse Attention (ShadowAttn) ที่คำนวณเฉพาะโทเคนสำคัญด้วย NPU-based Pilot Compute บนหน่วยประมวลผล NPU ของสมาร์ตโฟน เพื่อลดการพึ่งพาหน่วยประมวลผลกลางและหน่วยประมวลผลกราฟิกให้เหลือน้อยที่สุด แนวคิดนี้สามารถนำมาประยุกต์ใช้กับการออกแบบ NPU-centric Local LLM ของโครงงานนี้ได้โดยตรง แม้ว่างานวิจัยดังกล่าว จะทดสอบเฉพาะบนอุปกรณ์สมาร์ตโฟน ยังไม่มีการทดสอบบนอุปกรณ์ประเภท Single-Board Computer หรือ Edge Server

2.1.5 การประมวลผล Edge ML สำหรับอุปกรณ์สวมใส่ทางการแพทย์ (Oloko-Oba et al., 2026)

งานทบทวนวรรณกรรมในสาขาวิศวกรรมชีวการแพทย์นี้แสดงให้เห็นว่าแนวคิดการประมวลผลข้อมูลภายในอุปกรณ์เป็นหลัก และใช้คลาวด์เพียงเพื่อแสดงผลสรุปหรือจัดการวงจรชีวิตของระบบ สามารถนำไปประยุกต์ใช้ได้ผลดีในบริบทการติดตามสุขภาพด้วยอุปกรณ์สวมใส่ แม้จะมีความท้าทายเฉพาะด้าน เช่น สัญญาณรบกวนของข้อมูลภาคสนามและความล่าช้าของป้ายกำกับข้อมูล งานนี้ถูกนำมาใช้เป็นหลักฐานสนับสนุนเชิง cross-disciplinary motivation ที่ยืนยันว่าสถาปัตยกรรม Local-first ร่วมกับ Cloud-assist แบบจำกัดใช้ได้ผลในหลากหลายบริบท

2.1.6 งานสำรวจภาพรวมของสายงาน Edge LLM (Zheng et al., 2025)

บทความสำรวจนี้ประมวลภาพรวมของสายงาน edge LLM อย่างเป็นระบบ ตั้งแต่การออกแบบแบบจำลองที่ประหยัดทรัพยากร ไปจนถึงการเพิ่มประสิทธิภาพการอนุมานขณะรันไทม์ ครอบคลุมแพลตฟอร์มฮาร์ดแวร์หลากหลายระดับตั้งแต่ mobile ถึง SBC โดยชี้ให้เห็นว่าการบีบอัดแบบจำลองเพียงอย่างเดียวไม่เพียงพอต่อการรับประกันคุณภาพผลลัพธ์ที่มีโครงสร้าง (structured output) อย่างไรก็ตาม งานนี้เป็นการสังเคราะห์ตัวชี้วัดจากงานวิจัยจำนวนมาก ไม่มีการทดลองเชิงประจักษ์ของตัวเอง

2.1.7 การวัดผล Trade-off ของ LLM บนอุปกรณ์ Edge ทรัพยากรจำกัด (Giedra et al., 2026)

คณะผู้วิจัยทำการ Benchmark เชิงประจักษ์กับแบบจำลอง Quantized จำนวน 12 แบบจำลอง (ขนาด sub-1B ถึง 8B) บน NVIDIA Jetson Orin Nano Super (8GB) โดยวัดความแม่นยำด้วย lm-eval ร่วมกับประสิทธิภาพเชิงพลังงานและ throughput ผลการทดลองยืนยันเชิงประจักษ์ว่าระดับการบีบอัดแบบจำลองส่งผลโดยตรงต่อทั้งความเร็วและความแม่นยำบนอุปกรณ์ edge จริง อย่างไรก็ตาม การทดสอบ

ใช้ Task ทั่วไป (IFEval, GSM8K, TruthfulQA) ไม่ได้ทดสอบ grammar-constrained decoding หรือความแม่นยำของ JSON output โดยตรง

2.1.8 SGLang: การเร่งความเร็ว Structured Decoding (Zheng et al., 2024)

งานวิจัยนี้นำเสนอ SGLang ซึ่งใช้เทคนิค RadixAttention (การใช้ซ้ำ KV Cache) ร่วมกับ Compressed Finite State Machine เพื่อเร่งการถอดรหัสแบบมีโครงสร้าง (grammar-constrained decoding) ให้มี Throughput เพิ่มขึ้นถึง 6.4 เท่า เมื่อเทียบกับระบบอนุมานทั่วไป พร้อมทั้งรักษาความถูกต้องของผลลัพธ์แบบ JSON/structured output ได้สูง อย่างไรก็ตาม การทดสอบดำเนินการบนฮาร์ดแวร์ระดับ data center มิใช่ edge NPU ทรัพยากรจำกัดตามบริบทของโครงงานนี้

2.1.9 mPLUG-DocOwl2: ความเข้าใจเอกสารหลายหน้าแบบ OCR-free (Hu et al., 2025)

ทีมวิจัยพัฒนา mPLUG-DocOwl2 ซึ่งใช้เทคนิค High-resolution DocCompressor ลดจำนวน Visual Token ได้มากกว่า 80% สำหรับงานความเข้าใจเอกสารหลายหน้าแบบ OCR-free โดยมุ่งเน้นความแม่นยำของความเข้าใจเอกสารและความหน่วงของ Token แรก อย่างไรก็ตาม เป็นแบบจำลองภาษาแบบหลายรูปแบบขนาดใหญ่ระดับ Research-scale ที่ยังไม่ได้ปรับให้ทำงานร่วมกับ Quantized Local LLM บน SBC หรือ Pipeline ที่แยกขั้นตอน OCR ต่างหากตามที่โครงงานนี้ออกแบบไว้

2.1.10 ตัวแทน LLM อัตโนมัติสำหรับควบคุมบ้านอัจฉริยะ (Rivkin et al., 2025)

งานวิจัยนี้นำเสนอตัวแทน LLM อัตโนมัติสำหรับวางแผนและควบคุมอุปกรณ์ในบ้านอัจฉริยะ (AIoT Smart Home) โดยวัดผลจากอัตราความสำเร็จของงานควบคุมอุปกรณ์ ซึ่งแสดงให้เห็นศักยภาพของ LLM ในการเชื่อมต่อกับระบบ IoT ในครัวเรือน อย่างไรก็ตาม งานนี้มิได้กล่าวถึงข้อจำกัดด้านฮาร์ดแวร์ระดับ SBC หรือความแม่นยำของการสกัดข้อมูลเชิงโครงสร้างที่ส่งต่อมาจากขั้นก่อนหน้า

2.1.11 แบบจำลองพยากรณ์อนุกรมเวลาสำหรับข้อมูล IoT (Sawalha & Al-Naymat, 2025)

งานวิจัยนี้เสนอแบบจำลอง Adaptive Holt-Winters (AHW) ซึ่งผสาน Exponential Smoothing สองชุดเข้าด้วยกัน สำหรับพยากรณ์ข้อมูลอนุกรมเวลาที่มีรูปแบบตามฤดูกาลจากข้อมูล IoT โดยไม่ระบุฮาร์ดแวร์เฉพาะเนื่องจากเป็นแบบจำลองเชิงสถิติ เทคนิคนี้สามารถนำมาประยุกต์ใช้กับการพยากรณ์อัตราการสิ้นเปลืองสินค้าในครัวเรือน (burn rate) ได้ในเชิงหลักการ แม้จะไม่เกี่ยวข้องกับ LLM หรือความแม่นยำของการสกัดข้อมูลต้นทางก็ตาม

2.1.12 IoT Gateway น้ำหนักเบาบน ESP32 สำหรับบ้านอัจฉริยะ (Serepas et al., 2025)

คณะผู้วิจัยนำเสนอการออกแบบ IoT Gateway น้ำหนักเบาบนไมโครคอนโทรลเลอร์ ESP32 (MCU-class) ที่รองรับโปรโตคอล MQTT และ REST API โดยมุ่งเน้นการใช้ทรัพยากร (resource footprint) ของ Gateway บน MCU ต้นทุนต่ำ ซึ่งสอดคล้องโดยตรงกับ Stage การเชื่อมต่อ Home Assistant ผ่าน MQTT ในสถาปัตยกรรมของโครงงานนี้ อย่างไรก็ตาม งานนี้ศึกษาเฉพาะชั้นเชื่อมต่อ (connectivity layer) เท่านั้น ไม่เกี่ยวข้องกับความแม่นยำของการสกัดข้อมูลจาก LLM ต้นทาง

2.2 ทฤษฎีที่เกี่ยวข้อง

แนวคิดและทฤษฎีหลักในหัวข้อนี้สังเคราะห์ขึ้นจากงานวิจัยทั้ง 12 ฉบับที่ทบทวนในหัวข้อ 2.1 เท่านั้น เพื่อให้ทฤษฎีพื้นฐานมีความสอดคล้องและตรวจสอบแหล่งที่มาได้ชัดเจน

แนวคิด Edge/Local AI คือการประมวลผลปัญญาประดิษฐ์ให้เกิดขึ้นใกล้แหล่งข้อมูลมากที่สุด แทนที่จะส่งข้อมูลไปประมวลผลบนคลาวด์ ซึ่ง Cai et al. (2024) และ Husom et al. (2025) ต่างชี้ตรงกันว่าแนวทางนี้ช่วยลดความหน่วง ลดต้นทุนแบนด์วิดท์ และรักษาความเป็นส่วนตัวของข้อมูลเมื่อเทียบกับการประมวลผลบนคลาวด์แบบดั้งเดิม เทคนิคหลักที่ทำให้แบบจำลองภาษาขนาดใหญ่ทำงานได้บนอุปกรณ์ทรัพยากรจำกัดคือ Model Quantization ซึ่งเป็นการลดความละเอียดของตัวเลข (precision) ที่ใช้แทนพารามิเตอร์ของแบบจำลอง โดย Husom et al. (2025) แสดงให้เห็นเชิงประจักษ์ผ่านการประเมินแบบจำลอง Quantized LLM จำนวน 28 แบบจำลองว่าการลดระดับการบีบอัดข้อมูลมีความสัมพันธ์แบบ trade-off ระหว่างประสิทธิภาพเชิงพลังงานกับความแม่นยำของผลลัพธ์อย่างชัดเจน

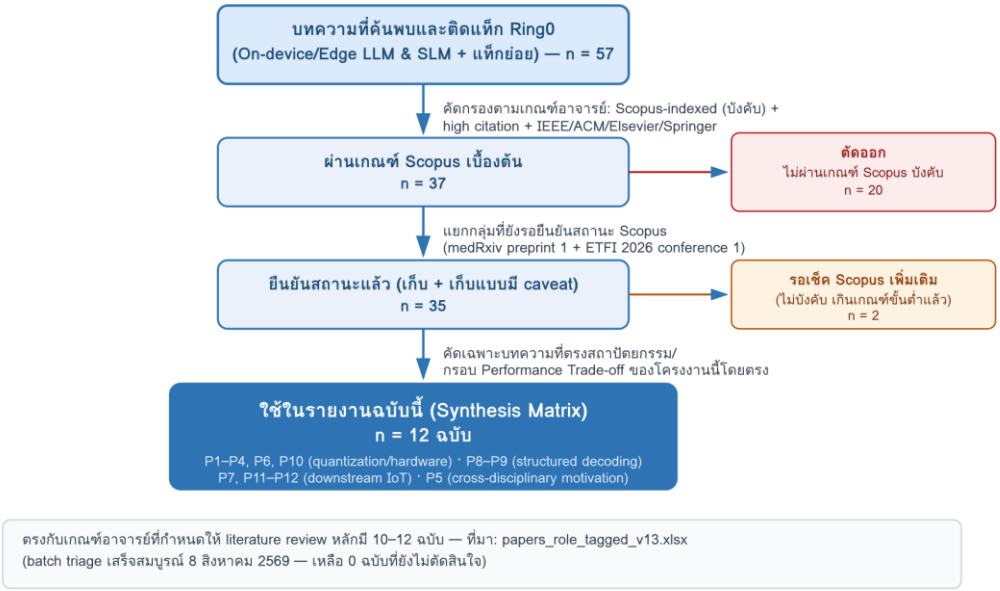
ในด้านสถาปัตยกรรมฮาร์ดแวร์ NPU-centric Architecture คือการออกแบบให้หน่วยประมวลผลเฉพาะทาง (Neural Processing Unit) เป็นแกนหลักในการอนุมานแบบจำลองภาษาเพื่อลดภาระของหน่วยประมวลผลกลางและหน่วยประมวลผลกราฟิก ดังที่ Yin et al. (2026) ออกแบบโมดูล Sparse Attention ที่คำนวณเฉพาะโทเคนสำคัญด้วย NPU บนสมาร์ตโฟน และ Moon et al. (2025) นำเสนอสถาปัตยกรรมผสมผสาน GPU-NPU (Hybe) สำหรับหน้าต่างบริบทขนาดล้านโทเคน อย่างไรก็ตาม Giedra et al. (2026) ยืนยันด้วยการวัดพลังงานจริงบนอุปกรณ์ NVIDIA Jetson Orin Nano Super (8GB) ว่าระดับการบีบอัดแบบจำลองขนาด sub-1B ถึง 8B พารามิเตอร์ส่งผลโดยตรงต่อทั้งความเร็วและความแม่นยำ ซึ่งเป็นข้อมูลเชิงปริมาณที่จำเป็นต่อการเลือกระดับ quantization ให้เหมาะกับ Edge Server ในที่พักอาศัย

อีกมิติหนึ่งที่จำเป็นสำหรับงานสกัดข้อมูลคือ Grammar-Constrained Decoding หรือ Structured Output ซึ่งเป็นเทคนิคการบังคับให้ผลลัพธ์ของแบบจำลองภาษาเป็นไปตามโครงสร้าง (schema) ที่กำหนดไว้ล่วงหน้า เช่น รูปแบบ JSON โดย Zheng et al. (2024) นำเสนอ SGLang ที่ใช้เทคนิค compressed finite state machine เร่ง throughput ของการถอดรหัสได้สูงถึง 6.4 เท่า ในขณะที่ Hu et al. (2025) พัฒนา mPLUG-DocOwl2 ซึ่งลดจำนวน visual token ในการทำความเข้าใจเอกสารหลายหน้าแบบ OCR-free ได้มากกว่า 80% ทั้งสองงานชี้ให้เห็นตรงกันว่าการบังคับ schema ระหว่างการถอดรหัสส่งผลโดยตรงต่อทั้งความเร็วและความถูกต้องของ JSON output ซึ่งจำเป็นสำหรับงานสกัดข้อมูลเชิงโครงสร้างของโครงงานนี้

ในชั้นการประยุกต์ใช้งานปลายน้ำ Time-Series Forecasting ด้วยแบบจำลอง Adaptive Holt-Winters ตามแนวทางของ Sawalha and Al-Naymat (2025) เป็นเทคนิคการพยากรณ์ข้อมูลอนุกรมเวลาที่มีรูปแบบตามฤดูกาลจากข้อมูล IoT ซึ่งสามารถนำมาประยุกต์ใช้กับการพยากรณ์อัตราการสิ้นเปลืองสินค้าในครัวเรือน (burn rate) ได้ ส่วนการเชื่อมต่ออุปกรณ์ edge เข้ากับระบบบ้านอัจฉริยะนั้น Serepas et al. (2025) นำเสนอสถาปัตยกรรม IoT Gateway น้ำหนักเบาบนไมโครคอนโทรลเลอร์ ESP32 ที่รองรับโปรโตคอล MQTT และ Rivkin et al. (2025) แสดงให้เห็นว่าตัวแทน LLM อัตโนมัติสามารถเชื่อมต่อกับระบบ IoT ในบ้านอัจฉริยะได้ ซึ่งทั้งสามงานนี้ยืนยันตรงกันว่าชั้นเชื่อมต่อปลายน้ำของสถาปัตยกรรมระบบควรมีน้ำหนักเบาและไม่พึ่งพาทรัพยากรคำนวณส่วนกลาง

2.3 เปรียบเทียบผลการศึกษา

จากบทความวิจัยที่เกี่ยวข้องกับโครงงานจำนวน 12 ฉบับ ซึ่งผ่านการตรวจสอบสถานะการจัดทำดัชนีในฐานข้อมูล Scopus แล้ว จัดกลุ่มตาม 3 มิติของกรอบ Performance Trade-off ที่โครงงานนี้มุ่งศึกษา ได้แก่ (1) quantization/hardware trade-off (P1–P4, P6, P10) (2) grammar-constrained decoding/structured output (P8–P9) และ (3) บริบทบ้านอัจฉริยะ/IoT ปลายน้ำ (P7, P11–P12) ส่วน P5 ใช้เป็นหลักฐานสนับสนุนเชิง cross-disciplinary motivation มีรายละเอียดดังนี้



ภาพที่ 2: กระบวนการคัดกรองบทความวิจัย (Ring0 n=57 ⟶ ใช้ในรายงาน n=12)

2.3.1 Synthesis Matrix (ตารางสังเคราะห์)

ตารางที่ 1: P1 – P3 (quantization/hardware trade-off)

ประเด็นเปรียบเทียบ	P1 (Cai et al., 2024)	P2 (Husom et al., 2025)	P3 (Moon et al., 2025)
แพลตฟอร์มฮาร์ดแวร์ที่ใช้	อุปกรณ์ Edge ทั่วไปร่วมกับเซิร์ฟเวอร์คลาวด์ (Cloud-Edge Collaboration)	Raspberry Pi 4 (RAM 4 GB) — ประมวลผลด้วย CPU เพียงอย่างเดียว	NVIDIA H100 GPU ร่วมกับ NPU ที่ออกแบบเฉพาะด้วยเทคโนโลยี 4 นาโนเมตร
แนวทาง/เทคนิคหลัก	Adaptive Quantization, FM Cache, Value-Density-First (VDF) Scheduling	ประเมิน Quantized LLM 28 แบบจำลองจาก Ollama บน 5 ชุดข้อมูลมาตรฐาน วัดพลังงานจริงด้วย Joulescope	สถาปัตยกรรมผสมผสาน GPU-NPU, Fine-grained KV Transmission, Pipelining ตามลำดับขั้น
ตัวชี้วัดหลักที่มุ่งเน้น	ลดภาระ GPU โดยไม่ลดทอนความแม่นยำ	Energy Efficiency, ความแม่นยำ, ความหน่วงในการอนุมาน	Speedup และประสิทธิภาพเชิงพลังงานสำหรับ context ขนาดล้านโทเคน
ระดับการพึ่งพาคลาวด์	พึ่งพาบางส่วน (Hybrid Cloud-Edge)	ประมวลผลภายในเครื่องทั้งหมด (Fully Local)	On-premises แต่อาศัยฮาร์ดแวร์ระดับสูงคล้ายศูนย์ข้อมูล

ประเด็นเปรียบเทียบ	P1 (Cai et al., 2024)	P2 (Husom et al., 2025)	P3 (Moon et al., 2025)
ข้อจำกัด/ช่องว่างที่พบ	ยังต้องพึ่งพาเครือข่ายภายนอกบางส่วน ไม่เหมาะกับบริบทตัดขาดอินเทอร์เน็ตโดยสมบูรณ์	ความแม่นยำลดลงเมื่อบีบอัดต่ำ โดยเฉพาะงานที่ต้องการความละเอียดสูง	ออกแบบสำหรับฮาร์ดแวร์ระดับเซิร์ฟเวอร์ต้นทุนสูง ไม่สอดคล้องกับ Edge Server ในที่พักอาศัย
สิ่งที่จะนำไปประยุกต์ใช้	ใช้เป็นกรณีเทียบเคียงด้าน Hybrid Cloud-Edge เพื่อยืนยันเหตุผลที่โครงงานเลือกสถาปัตยกรรม Fully On-device แทน ไม่ได้นำเทคนิคมาปรับใช้โดยตรง	นำวิธีประเมิน Quantized LLM หลายรุ่นบนอุปกรณ์ทรัพยากรจำกัดมาใช้เป็นแนวทางออกแบบการทดลองในระยะที่ 5 ของ Roadmap (เก็บข้อมูลนำร่อง Pilot 1-2)	ใช้เป็นกรณีเทียบเคียงด้านข้อจำกัดฮาร์ดแวร์ ยืนยันว่าสถาปัตยกรรมระดับเซิร์ฟเวอร์ต้นทุนสูงไม่เหมาะกับ Edge Server ในที่พักอาศัย จึงไม่นำมาใช้โดยตรง

ตารางที่ 2: P4 – P5 (quantization/hardware trade-off และ cross-disciplinary motivation)

ประเด็นเปรียบเทียบ	P4 (Yin et al., 2026)	P5 (Oloko-Oba et al., 2026)
แพลตฟอร์มฮาร์ดแวร์ที่ใช้	หน่วยประมวลผล NPU บนสมาร์ตโฟน (Mobile NPU)	อุปกรณ์สวมใส่ (Wearable) ร่วมกับสมาร์ตโฟนที่จับคู่
แนวทาง/เทคนิคหลัก	Sparse Attention (shadowAttn) คำนวณเฉพาะโทเคนสำคัญด้วย NPU-based Pilot Compute	การทบทวนวรรณกรรมเชิงบรรยาย (Narrative Review) ครอบคลุมตั้งแต่การรับสัญญาณจนถึงกลุ่มแบบจำลองที่เหมาะกับการอนุมานบนอุปกรณ์
ตัวชี้วัดหลักที่มุ่งเน้น	ความแม่นยำและประสิทธิภาพของการคำนวณ Attention บน NPU ภายใต้ทรัพยากร CPU/GPU จำกัด	ความน่าเชื่อถือทางคลินิกและความสามารถประมวลผลตามเวลาจริง
ระดับการพึ่งพาคลาวด์	Fully On-device	ประมวลผลภายในอุปกรณ์เป็นหลัก ใช้คลาวด์เฉพาะแสดงผลสรุปบนแดชบอร์ด
ข้อจำกัด/ช่องว่างที่พบ	ทดสอบเฉพาะบนสมาร์ตโฟน ยังไม่มีการทดสอบบน SBC หรือ Edge Server ในบ้านพักอาศัย	ข้อมูลภาคสนามมีสัญญาณรบกวนสูง เป็นบริบทด้านการแพทย์ ไม่ใช่สายคอมพิวเตอร์
สิ่งที่จะนำไปประยุกต์ใช้	นำหลักการแบ่งงานตามความอ่อนไหวต่อการควอนไทซ์มาใช้กำหนดว่าเลเยอร์ใดของ Local LLM ควรรันบน NPU แบบ INT8 เต็มรูปแบบ (รายละเอียดในหัวข้อ 2.3.6.1)	ใช้เป็นหลักฐานสนับสนุนข้ามศาสตร์ (cross-disciplinary motivation) ยืนยันว่าสถาปัตยกรรม Local-first ร่วม Cloud-assist

ประเด็นเปรียบเทียบ	P4 (Yin et al., 2026)	P5 (Oloko-Oba et al., 2026)
		แบบจำกัดใช้ได้ผลในหลากหลายบริบท ไม่ได้นำเทคนิคมาปรับใช้โดยตรง

ตารางที่ 3: P6, P10 (quantization/hardware trade-off เพิ่มเติม)

ประเด็นเปรียบเทียบ	P6 (Zheng et al., 2025)	P10 (Giedra et al., 2026)
แพลตฟอร์มฮาร์ดแวร์ที่ใช้	Survey ครอบคลุมอุปกรณ์ edge หลากหลายระดับ (mobile ถึง SBC)	NVIDIA Jetson Orin Nano Super (8GB) — SBC ระดับ embedded GPU
แนวทาง/เทคนิคหลัก	ทบทวนวรรณกรรมเชิงระบบ (systematic review) ตั้งแต่ resource-efficient model design จนถึง runtime inference optimization	Benchmark เชิงประจักษ์ 12 แบบจำลอง quantized (sub-1B ถึง 8B) วัด accuracy (lm-eval) และ efficiency (power/throughput)
ตัวชี้วัดหลักที่มุ่งเน้น	สังเคราะห์ตัวชี้วัดจากงานวิจัยจำนวนมาก ไม่มีการทดลองเชิงประจักษ์ของตัวเอง	Accuracy–efficiency trade-off (tok/J, throughput, power)
ระดับการพึ่งพาคลาวด์	ไม่ระบุเฉพาะเจาะจง (ครอบคลุมทั้ง on-device และ hybrid cloud-edge)	Fully On-device
ข้อจำกัด/ช่องว่างที่พบ	เป็น survey กว้าง ไม่มีข้อมูลเชิงปริมาณของตัวเองยืนยัน trade-off ระหว่าง quantization กับ structured/JSON output	ใช้ task ทั่วไป (IFEval, GSM8K, TruthfulQA) ไม่ได้ทดสอบ grammar-constrained decoding หรือความแม่นยำของ JSON output
สิ่งที่จะนำไปประยุกต์ใช้	ใช้ยืนยันกรอบแนวคิดว่าการบีบอัดแบบจำลองเพียงอย่างเดียวไม่พอสำหรับ structured output จึงต้องผนวกกับ grammar-constrained decoding ตามที่โครงงานออกแบบไว้	นำระเบียบวิธีวัด Trade-off แบบคู่ (แยกวัด accuracy กับพลังงาน) มาใช้เป็นวิธีประเมินผลในระยะที่ 7 ของ Roadmap (รายละเอียดในหัวข้อ 2.3.6.3)

ตารางที่ 4: P8 – P9 (grammar-constrained decoding / structured output)

ประเด็นเปรียบเทียบ	P8 (Zheng et al., 2024)	P9 (Hu et al., 2025)
แพลตฟอร์มฮาร์ดแวร์ที่ใช้	GPU ระดับ data center (ไม่ใช่ edge/SBC)	GPU ขนาดใหญ่ (multimodal LLM ระดับ research-scale)

ประเด็นเปรียบเทียบ	P8 (Zheng et al., 2024)	P9 (Hu et al., 2025)
แนวทาง/เทคนิคหลัก	RadixAttention (reuse KV cache) + compressed finite state machine เร่งการถอดรหัสแบบมีโครงสร้าง	High-resolution DocCompressor ลดจำนวน visual token กว่า 80% สำหรับความเข้าใจเอกสารหลายหน้าแบบ OCR-free
ตัวชี้วัดหลักที่มุ่งเน้น	Throughput (เพิ่มขึ้นถึง 6.4 เท่า) และความถูกต้องของ JSON/structured output	ความแม่นยำความเข้าใจเอกสารหลายหน้า และ latency ของ token แรก
ระดับการพึ่งพาคลาวด์	ออกแบบสำหรับ server-scale ไม่ใช่ edge	ไม่ระบุชัด (แบบจำลองขนาดใหญ่ ยังไม่ปรับให้ทำงานบน edge)
ข้อจำกัด/ช่องว่างที่พบ	ไม่ได้ทดสอบบนอุปกรณ์ edge/NPU ทรัพยากรจำกัด	ยังไม่ได้ทดสอบร่วมกับ quantized local LLM บน SBC หรือ pipeline ที่แยก OCR ต่างหาก
สิ่งที่จะนำไปประยุกต์ใช้	นำหลักการกำหนดโทเคนแน่นอนล่วงหน้าจาก schema (jump-forward decoding) มาออกแบบ Grammar-Constrained Decoding ของ JSON output (รายละเอียดในหัวข้อ 2.3.6.2)	ใช้เป็นหลักฐานว่าการลดภาระข้อมูลภาพช่วยเพิ่มความเร็วได้จริง แต่โครงงานเลือกแยกขั้นตอน OCR ออกจาก LLM ต่างหาก แทนแนวทาง OCR-free ของงานนี้

ตารางที่ 5: P7, P11 – P12 (บริบทบ้านอัจฉริยะ/IoT ปลายน้ำ)

ประเด็นเปรียบเทียบ	P7 (Rivkin et al., 2025)	P11 (Sawalha & Al-Naymat, 2025)	P12 (Serepas et al., 2025)
แพลตฟอร์มฮาร์ดแวร์ที่ใช้	อุปกรณ์บ้านอัจฉริยะทั่วไป (ไม่ระบุ SBC เฉพาะ)	ไม่ระบุฮาร์ดแวร์เฉพาะ (แบบจำลองพยากรณ์เชิงสถิติ)	ไมโครคอนโทรลเลอร์ ESP32 (MCU-class)
แนวทาง/เทคนิคหลัก	ตัวแทน LLM อัตโนมัติสำหรับวางแผนและควบคุมอุปกรณ์ในบ้านอัจฉริยะ	Adaptive Holt–Winters (AHW) ผสาน exponential smoothing สองชุด	IoT gateway น้ำหนักเบา รองรับ MQTT และ REST API
ตัวชี้วัดหลักที่มุ่งเน้น	อัตราความสำเร็จของ task การควบคุมอุปกรณ์	ความแม่นยำการพยากรณ์อนุกรมเวลาตามฤดูกาล	การใช้ทรัพยากร (resource footprint) ของ gateway บน MCU ต้นทุนต่ำ
ระดับการพึ่งพาคลาวด์	ไม่ระบุชัด (อาจพึ่งพา cloud API)	ไม่เกี่ยวข้อง (เป็นแบบจำลองพยากรณ์)	Local control ร่วมกับ cloud analytics ผ่าน gateway

ประเด็นเปรียบเทียบ	P7 (Rivkin et al., 2025)	P11 (Sawalha & Al-Naymat, 2025)	P12 (Serepas et al., 2025)
ข้อจำกัด/ช่องว่างที่พบ	ไม่กล่าวถึงข้อจำกัดฮาร์ดแวร์ระดับ SBC หรือความแม่นยำของการสกัดข้อมูลเชิงโครงสร้าง	ไม่เกี่ยวข้องกับ LLM หรือการสกัดข้อมูลต้นทาง เป็นเทคนิคพยากรณ์ปลายน้ำที่อาจปรับใช้กับ burn rate prediction	เป็นเพียงชั้นเชื่อมต่อ (connectivity layer) ไม่เกี่ยวข้องกับความแม่นยำของการสกัดข้อมูลจาก LLM ต้นทาง
สิ่งที่จะนำไปประยุกต์ใช้	ใช้เป็นหลักฐานยืนยันศักยภาพของ LLM ในการเชื่อมต่อควบคุมอุปกรณ์บ้านอัจฉริยะ แต่โครงงานเน้นการพยากรณ์ burn rate มากกว่าการควบคุมอุปกรณ์โดยตรง	นำแบบจำลอง Adaptive Holt-Winters มาปรับใช้พยากรณ์อัตราการสิ้นเปลืองสินค้า (burn rate) จากข้อมูลปริมาณคงเหลือรายวัน (ดูหัวข้อ 3.2 และระยะที่ 4 ของ Roadmap)	นำสถาปัตยกรรม IoT gateway บน ESP32 รองรับ MQTT มาปรับใช้เป็นชั้นเชื่อมต่อ Home Assistant โดยกำหนด MQTT topic แยกตามรายการสินค้า (ดูหัวข้อ 3.2)

2.3.2 จุดที่เห็นตรงกัน (Consensus)

งานวิจัยทั้ง 12 ฉบับเห็นตรงกันในหลักการว่า การนำหน่วยประมวลผลเฉพาะทาง (NPU) หรือเทคนิคการบีบอัดแบบจำลอง (Quantization) มาใช้ร่วมกับการประมวลผลใกล้แหล่งข้อมูล (Edge/On-device) เป็นแนวทางที่จำเป็นต่อการทำให้ระบบปัญญาประดิษฐ์ทำงานได้จริงภายใต้ทรัพยากรที่จำกัด โดยงานวิจัยของ Husom et al. (2025) (ประเมินแบบจำลอง Quantized LLM ถึง 28 รุ่นบน Raspberry Pi 4), Yin et al. (2026) และ Oloko-Oba et al. (2026) ต่างมุ่งลดการพึ่งพาคลาวด์ให้เหลือน้อยที่สุดหรือไม่มีเลย เพื่อรักษาความเป็นส่วนตัวของข้อมูลผู้ใช้ ซึ่งสอดคล้องโดยตรงกับหลักการออกแบบสถาปัตยกรรม Local AI ของโครงงานนี้ ทิศทางเดียวกันนี้ยังปรากฏในงานสำรวจภาพรวมของ Zheng et al. (2025) ซึ่งยืนยันว่าสายงานวิจัย edge LLM ทั้งสายกำลังมุ่งไปทาง on-device inference เป็นหลัก และสอดคล้องกับผลวัดเชิงประจักษ์ของ Giedra et al. (2026) ที่ยืนยันว่าการรันแบบจำลอง quantized บนอุปกรณ์ edge จริงอย่าง NVIDIA Jetson (ครอบคลุมโมเดล 12 แบบขนาด sub-1B ถึง 8B พารามิเตอร์) ให้ผลลัพธ์ที่ใช้งานได้จริง หลักการเดียวกันยังปรากฏสม่ำเสมอในงานวิจัยชั้นปลายน้ำของสถาปัตยกรรม กล่าวคือ Rivkin et al. (2025), Sawalha and Al-Naymat (2025) และ Serepas et al. (2025) ต่างออกแบบให้การเชื่อมต่อและประมวลผลข้อมูล IoT ในครัวเรือนเกิดขึ้นแบบเบา (lightweight) และไม่พึ่งพาทรัพยากรคำนวณส่วนกลางเช่นเดียวกัน แม้แต่ในสายงานการบังคับโครงสร้างผลลัพธ์ Zheng et al. (2024) (เพิ่ม throughput ได้สูงสุด 6.4 เท่า) และ Hu et al. (2025) (ลดจำนวน visual token ได้มากกว่า 80%) ก็มีเป้าหมายร่วมกันคือการลดภาระการประมวลผลของแบบจำลองภาษาโดยไม่ลดทอนคุณภาพผลลัพธ์ ซึ่งเป็นหลักการเดียวกับที่พบในงานกลุ่ม quantization/hardware ข้างต้น

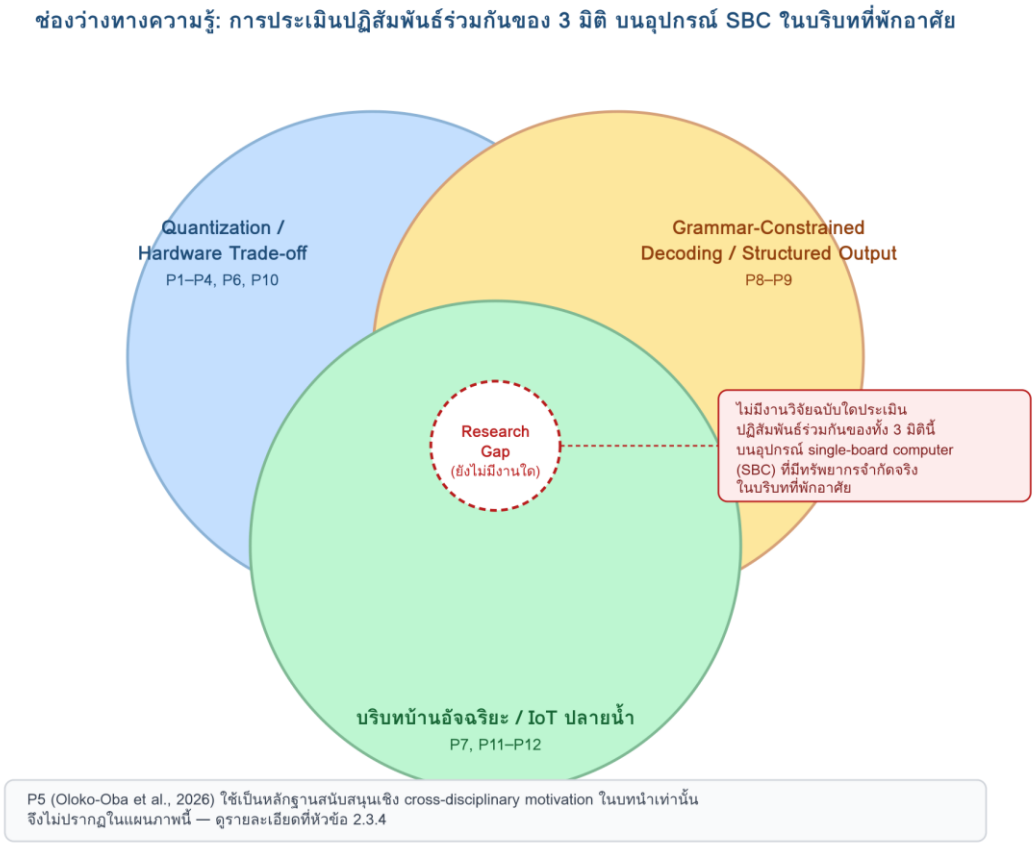
2.3.3 จุดที่ขัดแย้ง/ต่างกัน (Disagreement)

แม้จะเห็นพ้องในหลักการ แต่แต่ละงานวิจัยมีเป้าหมาย ระดับการพึ่งพาคลาวด์ และระดับฮาร์ดแวร์ที่แตกต่างกันอย่างมีนัยสำคัญ กล่าวคือ Cai et al. (2024) ยังคงอาศัยการทำงานร่วมกันระหว่างอุปกรณ์ Edge และเซิร์ฟเวอร์คลาวด์บางส่วน (Hybrid) ในขณะที่ Husom et al. (2025), Yin et al. (2026) และ Oloko-Oba et al. (2026) เลือกประมวลผลภายในอุปกรณ์ทั้งหมด นอกจากนี้ Moon et al. (2025) มุ่งแก้ปัญหาหน้าต่างบริบทขนาดใหญ่ระดับล้านโทเคน ด้วยฮาร์ดแวร์ระดับเซิร์ฟเวอร์ (NVIDIA H100 ร่วมกับ NPU ที่ผลิตขึ้นเฉพาะด้วยเทคโนโลยี 4 นาโนเมตร) ซึ่งมีต้นทุนและขนาดสูงกว่าฮาร์ดแวร์ระดับ Raspberry Pi 4 (RAM 4GB) หรือสมาร์ตโฟนที่ใช้ในงานวิจัยอื่น ๆ อย่างมีนัยสำคัญ แสดงให้เห็นว่าผลการทดลองเรื่องความเร็วและประสิทธิภาพพลังงานจากงานวิจัยที่ใช้ฮาร์ดแวร์ระดับสูงอาจไม่สามารถถ่ายโอนไปใช้กับ Edge Server ขนาดเล็กในบริบทที่พักอาศัยได้โดยตรง ความแตกต่างด้านระดับฮาร์ดแวร์นี้ปรากฏชัดยิ่งขึ้นเมื่อพิจารณาสายงานการบังคับโครงสร้างผลลัพธ์ กล่าวคือ Zheng et al. (2024) ทดสอบเทคนิคเร่งความเร็ว grammar-constrained decoding บนฮาร์ดแวร์ระดับ data center และ Hu et al. (2025) ใช้แบบจำลองขนาดใหญ่ ยังไม่ได้ปรับให้ทำงานร่วมกับ quantized LLM บน SBC ในขณะที่ Giedra et al. (2026) วัดผล trade-off ระหว่างความแม่นยำและพลังงานบนอุปกรณ์ edge จริงโดยตรง (NVIDIA Jetson Orin Nano Super, 12 โมเดล) แสดงให้เห็นว่าแม้แต่ภายในสายงานเดียวกันก็ยังมีช่องว่างระหว่างงานที่ทดสอบบนฮาร์ดแวร์สมรรถนะสูงกับงานที่ทดสอบบนฮาร์ดแวร์ทรัพยากรจำกัดจริง ในทำนองเดียวกัน งานวิจัยชั้นปลายน้ำอย่าง Rivkin et al. (2025), Sawalha and Al-Naymat (2025) และ Serepas et al. (2025) ก็มิได้กล่าวถึงข้อจำกัดด้านฮาร์ดแวร์ SBC หรือคุณภาพของผลลัพธ์เชิงโครงสร้างที่ส่งต่อมาจากชั้นการประมวลผล LLM เลย — สะท้อนว่าแต่ละสายงาน ฮาร์ดแวร์/quantization, structured decoding, และการประยุกต์ใช้งานปลายน้ำ — ยังคงพัฒนาแยกกันโดยไม่มีงานใดเชื่อมโยงทั้งสามระดับเข้าด้วยกันภายใต้เงื่อนไขฮาร์ดแวร์เดียวกัน

2.3.4 ช่องว่างทางความรู้ (Research Gap)

งานวิจัยด้านการอนุมานแบบจำลองภาษาบนอุปกรณ์ประมวลผลเฉพาะถิ่น (on-device LLM inference) ในช่วงที่ผ่านมา มีแนวโน้มศึกษาปัจจัยด้านประสิทธิภาพแยกออกจากกันเป็นสามมิติหลัก แทนที่จะประเมินปฏิสัมพันธ์ร่วมกันภายใต้ทรัพยากรจำกัดจริงของอุปกรณ์ single-board computer (SBC) ในมิติแรก งานวิจัยกลุ่มที่มุ่งเน้นการบีบอัดแบบจำลอง (quantization) และสถาปัตยกรรมฮาร์ดแวร์

เร่งความเร็วมีจำนวนมากและมีความก้าวหน้าอย่างต่อเนื่อง แต่งานวิจัยกลุ่มนี้ทั้งหมดวัดผลกระทบของ quantization ต่อความแม่นยำเชิง benchmark ทั่วไป มิได้เชื่อมโยงกับความแม่นยำของผลลัพธ์ที่มีโครงสร้าง (structured output) ซึ่งเป็นรูปแบบผลลัพธ์ที่จำเป็นสำหรับงานสกัดข้อมูล ในมิติที่สอง งานวิจัยด้านการบังคับโครงสร้างผลลัพธ์ของแบบจำลองภาษาก็เป็นสายงานที่พัฒนาแยกต่างหากเช่นกัน ชี้ให้เห็นว่าการบังคับ schema ระหว่างการถอดรหัสส่งผลโดยตรงต่อทั้งความเร็วและความถูกต้องของ JSON output แต่ยังไม่มีงานใดวัดผลกระทบนี้ร่วมกับระดับการบีบอัดแบบจำลองบนอุปกรณ์ edge NPU ทรัพยากรจำกัดพร้อมกัน ในมิติที่สาม บริบทของการประยุกต์ใช้งานจริงในครัวเรือนก็เป็นสายงานที่พัฒนาคู่ขนานกันไปเช่นกัน โดยศึกษาเฉพาะชั้นการเชื่อมต่อและการพยากรณ์ปลายน้ำ โดยไม่ได้เชื่อมโยงย้อนกลับไปถึงความแม่นยำของการสกัดข้อมูลต้นทางจาก LLM ภายใต้ข้อจำกัดด้าน quantization และ decoding ที่กล่าวถึงในมิติแรกและมิติที่สอง



ภาพที่ 3: ช่องว่างทางความรู้ — ปฏิสัมพันธ์ร่วมกันของ 3 มิติที่ยังไม่มีงานวิจัยศึกษา

ช่องว่างทางความรู้ทั้งสามมิติข้างต้นสะท้อนว่างานวิจัยที่ผ่านมายังไม่มีฉบับใดประเมินปฏิสัมพันธ์ร่วมกันของ quantization, structured-output decoding และบริบทบ้านอัจฉริยะบนอุปกรณ์ SBC ทรัพยากรจำกัดในบริบทที่พักอาศัยจริง หัวข้อ 2.3.6 ต่อไปนี้จึงขยายความเฉพาะสามงานวิจัยที่ใกล้เคียงกับ

สถาปัตยกรรมของโครงงานที่สุด (Yin et al., 2026; Zheng et al., 2024; Giedra et al., 2026) เพื่อดึงสูตร พารามิเตอร์ และแนวทางเชิงเทคนิคที่จะนำไปปรับใช้ในการอุดช่องว่างดังกล่าว

2.3.5 Literature Review (เรียบเรียงจากประเด็นข้างต้น)

การประยุกต์ใช้ปัญญาประดิษฐ์แบบประมวลผลเฉพาะถิ่น (Local/Edge AI) ร่วมกับหน่วยประมวลผลเฉพาะทางประเภท NPU ได้รับความสนใจอย่างต่อเนื่องในงานวิจัยระยะหลัง เนื่องจากช่วยลดความหน่วง ลดต้นทุนด้านแบนด์วิดท์ และรักษาความเป็นส่วนตัวของข้อมูลผู้ใช้เมื่อเทียบกับการประมวลผลบนคลาวด์แบบดั้งเดิม (Cai et al., 2024; Husom et al., 2025)

ในด้านเทคนิคการทำให้แบบจำลองภาษาขนาดใหญ่ทำงานได้บนอุปกรณ์ที่มีทรัพยากรจำกัด Husom et al. (2025) ได้ประเมินแบบจำลอง Quantized LLM จำนวน 28 แบบจำลองบนอุปกรณ์ Raspberry Pi 4 และพบว่าการลดระดับการบีบอัดข้อมูลช่วยเพิ่มประสิทธิภาพเชิงพลังงานได้ แต่ในขณะเดียวกันก็ส่งผลให้ความแม่นยำลดลงในงานที่ต้องการความละเอียดสูง ซึ่งเป็นข้อค้นพบที่มีนัยสำคัญต่อการเลือกระดับการบีบอัดแบบจำลองสำหรับโครงงานนี้ ในทำนองเดียวกัน Cai et al. (2024) ได้เสนอกรอบการทำงานร่วมกันระหว่างอุปกรณ์ Edge และเซิร์ฟเวอร์คลาวด์ (Edge-LLM) โดยใช้เทคนิคการบีบอัดแบบปรับตัวได้ร่วมกับกลไกแคชและการจัดลำดับงาน เพื่อลดภาระของหน่วยประมวลผลกราฟิกโดยไม่ลดทอนความแม่นยำ อย่างไรก็ตาม แนวทางดังกล่าวยังคงอาศัยการเชื่อมต่อกับคลาวด์บางส่วน จึงมีข้อจำกัดเมื่อนำไปใช้ในบริบทที่ต้องการตัดขาดจากเครือข่ายภายนอกโดยสมบูรณ์ตามที่โครงงานนี้กำหนดไว้

ในมิติของสถาปัตยกรรมฮาร์ดแวร์ Moon et al. (2025) ได้นำเสนอระบบผสมผสานระหว่าง GPU และ NPU (Hybe) เพื่อแก้ปัญหาความไม่สมดุลด้านการประมวลผลระหว่างขั้นตอน Prefill และ Decode ของการอนุมานแบบจำลองภาษาที่มีหน้าต่างบริบทขนาดใหญ่ระดับล้านโทเคน โดยอาศัยฮาร์ดแวร์ระดับสูง ได้แก่ NVIDIA H100 ร่วมกับ NPU ที่ผลิตขึ้นเฉพาะด้วยเทคโนโลยี 4 นาโนเมตร ซึ่งแม้จะให้ผลลัพธ์ด้านความเร็วและประสิทธิภาพพลังงานที่โดดเด่น แต่ด้วยต้นทุนและขนาดของฮาร์ดแวร์ดังกล่าว ทำให้แนวทางนี้ไม่สอดคล้องกับข้อจำกัดของ Edge Server ขนาดเล็กที่ใช้ในที่พักอาศัย ในทางกลับกัน Yin et al. (2026) ได้นำเสนอแนวทางที่ใกล้เคียงกับบริบทของโครงงานนี้มากกว่า โดยออกแบบโมดูล Sparse Attention ที่คำนวณเฉพาะโทเคนสำคัญด้วย NPU บนสมาร์ตโฟน เพื่อลดการพึ่งพาหน่วยประมวลผลกลางและหน่วยประมวลผลกราฟิกให้เหลือน้อยที่สุด อันเป็นแนวคิดที่สามารถนำมาประยุกต์ใช้กับการออกแบบ NPU-centric Local LLM ของโครงงานนี้ได้ แม้ว่างานวิจัยดังกล่าวจะทดสอบเฉพาะบนอุปกรณ์สมาร์ตโฟน ยังไม่มีการทดสอบบนอุปกรณ์ประเภท Single-Board Computer หรือ Edge Server ตามที่โครงงานนี้ออกแบบไว้ก็ตาม

เพื่อแสดงให้เห็นถึงความสามารถในการประยุกต์ใช้หลักการ Edge/Local AI ข้ามศาสตร์วิชา งานทบทวนวรรณกรรมของ Oloko-Oba et al. (2026) ในสาขาวิศวกรรมชีวการแพทย์ได้แสดงให้เห็นว่าแนวคิดการประมวลผลข้อมูลภายในอุปกรณ์เป็นหลัก และใช้คลาวด์เพียงเพื่อแสดงผลสรุปหรือดำเนินการจัดการวงจรชีวิตของระบบ สามารถนำไปประยุกต์ใช้ได้ผลดีในบริบทของการติดตามสุขภาพด้วยอุปกรณ์สวมใส่เช่นกัน แม้ว่าจะมีความท้าทายเฉพาะด้าน อาทิ สัญญาณรบกวนของข้อมูลภาคสนามและความล่าช้าของป้ายกำกับข้อมูล ซึ่งสะท้อนให้เห็นว่ารูปแบบสถาปัตยกรรม Local-first ร่วมกับ Cloud-assist แบบจำกัดเฉพาะการแสดงผลนั้น เป็นรูปแบบที่ใช้ได้ผลในหลากหลายบริบทการประยุกต์ใช้งาน ไม่จำกัดเฉพาะสายวิทยาการคอมพิวเตอร์เท่านั้น

นอกเหนือจากมิติของฮาร์ดแวร์และการบีบอัดแบบจำลองแล้ว งานสำรวจของ Zheng et al. (2025) ได้ประมวลภาพรวมของสายงาน edge LLM ตั้งแต่การออกแบบแบบจำลองไปจนถึงการอนุมานขณะรันไทม์ ซึ่งชี้ให้เห็นว่าการบีบอัดแบบจำลองเพียงอย่างเดียวไม่เพียงพอต่อการรับประกันคุณภาพผลลัพธ์ที่มีโครงสร้าง (structured output) อันเป็นรูปแบบที่จำเป็นสำหรับงานสกัดข้อมูลของโครงงานนี้ Giedra et al. (2026) ยืนยันเชิงประจักษ์เพิ่มเติมว่าระดับการบีบอัดแบบจำลองขนาด sub-1B ถึง 8B ส่งผลโดยตรงต่อทั้งความเร็วและความแม่นยำบนอุปกรณ์ NVIDIA Jetson ในขณะที่สายงานการบังคับโครงสร้างผลลัพธ์ Zheng et al. (2024) นำเสนอ SGLang ซึ่งใช้เทคนิค compressed finite state machine เร่ง throughput ของ grammar-constrained decoding ได้สูงถึง 6.4 เท่าเมื่อเทียบกับระบบอนุมานทั่วไป แต่ทดสอบบนฮาร์ดแวร์ระดับ data center มิใช่ edge NPU และ Hu et al. (2025) พัฒนา mPLUG-DocOwl2 สำหรับความเข้าใจเอกสารหลายหน้าแบบ OCR-free ที่ลดจำนวน visual token ได้มากกว่า 80% แต่เป็นแบบจำลองขนาดใหญ่ ยังไม่ได้ออกแบบมาเพื่อทำงานร่วมกับ quantized local LLM บน SBC งานทั้งสองฉบับนี้ชี้ให้เห็นว่าการบังคับ schema ระหว่างการถอดรหัสส่งผลโดยตรงต่อทั้งความเร็วและความถูกต้องของ JSON output แต่ยังไม่มีงานใดวัดผลกระทบนี้ร่วมกับระดับการบีบอัดแบบจำลองบนอุปกรณ์ edge NPU ทรัพยากรจำกัดพร้อมกัน

ในชั้นปลายน้ำของสถาปัตยกรรม Rivkin et al. (2025) นำเสนอตัวแทน LLM อัตโนมัติสำหรับควบคุมอุปกรณ์ในบ้านอัจฉริยะ (AIoT smart home) ซึ่งแสดงให้เห็นศักยภาพของ LLM ในการเชื่อมต่อกับระบบ IoT ในครัวเรือน แต่มิได้กล่าวถึงข้อจำกัดด้านฮาร์ดแวร์ระดับ SBC หรือความแม่นยำของการสกัดข้อมูลเชิงโครงสร้างที่ส่งต่อมาจากชั้นก่อนหน้า Sawalha and Al-Naymat (2025) เสนอแบบจำลอง Adaptive Holt–Winters สำหรับพยากรณ์ข้อมูลอนุกรมเวลาตามฤดูกาลจากข้อมูล IoT ซึ่งสามารถประยุกต์ใช้กับการพยากรณ์อัตราการสิ้นเปลืองสินค้าในครัวเรือน (burn rate) ได้ในเชิงหลักการ และ Serepas et al. (2025) นำเสนอการออกแบบ IoT gateway น้ำหนักเบาบนไมโครคอนโทรลเลอร์ ESP32 ที่รองรับโปรโตคอล MQTT สำหรับเชื่อมต่ออุปกรณ์ edge เข้ากับระบบบ้านอัจฉริยะ ซึ่งสอดคล้องโดยตรง

กับ stage การเชื่อมต่อ Home Assistant ผ่าน MQTT ในสถาปัตยกรรมของโครงงานนี้ อย่างไรก็ตาม ทั้งสามงานนี้ศึกษาเฉพาะชั้นการเชื่อมต่อและการพยากรณ์ปลายน้ำ โดยไม่ได้เชื่อมโยงย้อนกลับไปถึงความแม่นยำของการสกัดข้อมูลต้นทางจาก LLM ภายใต้ข้อจำกัดด้าน quantization และ decoding ที่กล่าวถึงข้างต้น

โดยสรุป จากการทบทวนวรรณกรรมทั้ง 12 ฉบับ พบว่างานวิจัยที่ผ่านมาให้ความสำคัญกับการนำ NPU และเทคนิคการบีบอัดแบบจำลองมาใช้เพื่อให้การประมวลผลปัญญาประดิษฐ์เกิดขึ้นใกล้แหล่งข้อมูลมากที่สุดอย่างสม่ำเสมอ ทั้งในชั้นฮาร์ดแวร์ ชั้นการบังคับโครงสร้างผลลัพธ์ และชั้นการประยุกต์ใช้งานปลายน้ำ แต่ยังมีความแตกต่างกันในระดับการพึ่งพาคลาวด์และขนาด/ต้นทุนของฮาร์ดแวร์ที่ใช้ทดลองในแต่ละสายงาน อีกทั้งยังไม่พบงานวิจัยฉบับใดที่บูรณาการองค์ประกอบทั้งหมด ตั้งแต่การตรวจจับเอกสารด้วยกล้อง การสกัดข้อความ การประมวลผลด้วย Local LLM จนถึงการเชื่อมต่อกับระบบบ้านอัจฉริยะเพื่อพยากรณ์พฤติกรรมการบริโภคในครัวเรือน ช่องว่างทางความรู้ดังกล่าวจึงเป็นที่มาและเป็นเป้าหมายหลักที่โครงงานวิทยานิพนธ์นี้มุ่งศึกษาและพัฒนาต่อไป

2.3.6 การขยายความงานวิจัยหลัก

หัวข้อนี้ขยายความเฉพาะสามงานวิจัยที่เกี่ยวข้องโดยตรงที่สุดกับสถาปัตยกรรมของโครงงาน คือ Yin et al. (2026) (NPU-centric sparse attention), Zheng et al. (2024) (SGLang grammar-constrained decoding) และ Giedra et al. (2026) (quantization benchmark บนอุปกรณ์ edge จริง) โดยเน้นสูตร อัลกอริทึม และพารามิเตอร์เชิงปริมาณที่จะนำไปปรับใช้หรือดัดแปลงในโครงงานโดยตรง

2.3.6.1 Yin et al. (2026) — ShadowNPU: Dynamic Sparse Attention บน NPU

Yin et al. (2026) พบว่าตัวดำเนินการ attention ในเฟรมเวิร์ก on-device LLM ชั้นนำ (llm.npu, HeteroLLM, llama.cpp, mlc-llm) มักถูกปัดตกไปประมวลผลบน CPU/GPU แทน NPU เพราะความอ่อนไหวต่อการควอนไทซ์ เมื่อบังคับให้ attention รันบน NPU แบบ INT8 พบว่าความแม่นยำลดลงเฉลี่ยถึง 18 percentage point บนโมเดลขนาดเล็กระดับมือถือ (เช่น PhoneLM-0.5B ลดลง 14.7 pp บน ArxivSum dataset)

ทีมวิจัยแก้ปัญหานี้ด้วย shadowAttn ซึ่งแยกการคำนวณ attention เป็นสองขั้น ขั้นประเมินความสำคัญ (Estimation stage) คำนวณ attention score เต็มรูปแบบ

$$attentionScores = softmax(mask(Q \cdot K / \sqrt{d_k}))$$

แล้วเลือกเฉพาะ top-k ตำแหน่งที่มีคะแนนสูงสุด ขั้นนี้ถูกผลักไปให้ NPU คำนวณแบบ INT8 เพราะการหาตำแหน่ง (ranking) ทนต่อความคลาดเคลื่อนจากการควอนไทซ์ได้ดีกว่าการคำนวณค่าจริง (recall ของการทำนายตำแหน่งสำคัญสูงกว่า 99% แทบทุก sparsity ratio ที่ทดสอบ 20-80%) ส่วนขั้นคำนวณจริง (Attention stage) เฉพาะ token ที่ถูกเลือกจากขั้นแรกเท่านั้นที่ถูกคำนวณแบบ float บน CPU/GPU

$$O = softmax(mask(Q \cdot K / \sqrt{d_k})) \cdot V$$

จุดสำคัญคือสัดส่วนความเบาบาง (sparsity ratio) ต้องกำหนดแยกตามหัว (head) และชั้น (layer) ไม่ใช่ค่าคงที่เดียวทั้งโมเดล โดยวัดความสำคัญของหัว i ในชั้น j จาก delta-loss เมื่อปิดหัวนั้น

$$headImp_i = loss(head_i = 0, C) - loss(C) \qquad layerImp_j = loss(layer_j = 0, C) - loss(C)$$

แล้วจัดสรรสัดส่วนความเบาบางของหัว i จากอัตราส่วนเฉลี่ยทั้งระบบ r และจำนวนหัวทั้งหมด N

$$sparsity_i = r \cdot N \cdot clamp(headImp_i \cdot layerImp_j) / \Sigma\, clamp(headImp_i \cdot layerImp_j)\ ,\ 1 \le i \le N$$

ผลลัพธ์ shadowAttn ลดการพึ่งพา CPU/GPU จนเหลือใช้เพียง 1 core แต่ยังให้ speedup ของโมดูล attention สูงสุด 6.9 เท่า, speedup แบบ end-to-end สูงสุด 4.5 เท่า และลดพลังงานสูงสุด 7.7 เท่า โดยความแม่นยำลดลงเฉลี่ยเพียง 0.4 percentage point

สิ่งที่โครงงานนำไปปรับใช้: โครงงานจะไม่ทำ dynamic sparse attention เต็มรูปแบบเพราะซับซ้อนเกินขอบเขตวิทยานิพนธ์ระดับปริญญาตรี แต่จะยืมหลักการแบ่งงานตามความอ่อนไหวต่อการควอนไทซ์มาใช้ในการเลือกว่าเลเยอร์ไหนของ Local LLM ควรรันบน NPU แบบ INT8 เต็มรูปแบบ และเลเยอร์ไหน (เช่น ส่วนที่ทำ grammar-constrained decoding ซึ่งต้องการค่าความน่าจะเป็น/logit ที่แม่นยำ) ควรสำรองให้ CPU ช่วยคำนวณบางส่วน แทนการบังคับทุกเลเยอร์ลง NPU แบบเดียวกันหมด ซึ่งถือเป็นการทำ Trade-off Analysis และ Design Justification ระหว่างความเร็ว (NPU) กับความแม่นยำของ token สำคัญ (float fallback) สอดคล้องกับกรอบ Performance Trade-off มิติที่ 1 ของรายงานนี้

2.3.6.2 Zheng et al. (2024) — SGLang: RadixAttention และ Compressed Finite State Machine

Zheng et al. (2024) พบว่าการถอดรหัสแบบมีโครงสร้าง (constrained decoding เพื่อบังคับ output ให้ตรงกับ regex/JSON schema) มักช้าเพราะต้องถอดรหัสทีละโทเคน (token-by-token) แม้ว่าหลายส่วนของโครงสร้างผลลัพธ์ (เช่นเครื่องหมาย { , " : " , key ที่ตายตัวใน schema) จะคาดเดาได้แน่นอนอยู่แล้วโดยไม่ต้องให้โมเดลคำนวณ เทคนิคหลักสองส่วนคือ (1) RadixAttention จัดเก็บ KV cache ของทุก

request ไว้ใน radix tree แบบ LRU แทนการทิ้งทันทีหลังประมวลผลเสร็จ ทำให้ prefix ที่ใช้ร่วมกัน (เช่น system prompt, few-shot example หรือส่วนต้นของ schema เดิม) ถูกนำมาใช้ซ้ำได้โดยไม่ต้องคำนวณใหม่ และ (2) Compressed Finite State Machine จาก regex ของ schema ร่วมกับ Jump-forward decoding ซึ่งวิเคราะห์ FSM ของ schema ล่วงหน้า เมื่อพบว่าลำดับโทเคนถัดไปถูกกำหนดไว้แน่นอนเพียงทางเดียว ระบบจะข้ามการถอดรหัสทีละโทเคน แล้วยัดชุดโทเคนที่แน่นอนนั้นเข้าไปในคำตอบทันที โดย RadixAttention ช่วยให้การยกเลิก request เดิมแล้วสร้าง request ใหม่ต่อจากจุดกระโดดทำได้เบา เพราะ KV cache ของส่วนก่อนหน้าถูกใช้ซ้ำอยู่แล้ว

ผลการทดลอง เมื่อเทียบกับระบบ constrained decoding อื่น (เช่น Outlines+vLLM) เฉพาะงาน structured/JSON decoding เทคนิค jump-forward ลด latency ได้ถึง 2 เท่า และเพิ่ม throughput ได้ถึง 2.5 เท่า ส่วนภาพรวมทั้งระบบ SGLang ให้ throughput สูงสุดถึง 6.4 เท่า และลด latency ได้ถึง 3.7 เท่าเมื่อเทียบกับ state-of-the-art อื่น ๆ

สิ่งที่โครงงานนำไปปรับใช้: โครงงานจะไม่พอร์ต RadixAttention เต็มรูปแบบเพราะออกแบบมาสำหรับ multi-request server ขนาดใหญ่ ไม่ตรงกับบริบท single-host ในบ้าน แต่จะยืมหลักการกำหนดโทเคนที่แน่นอนล่วงหน้าจาก schema แล้วข้ามการคำนวณของโมเดล มาใช้ในการออกแบบ Grammar-Constrained Decoding ของ Quantized Local LLM คือกำหนด JSON schema ตายตัวสำหรับใบเสร็จ/ฉลากสินค้า (เช่น key คงที่ "item": , "price": , "date":) ให้ตัวถอดรหัสข้ามการคำนวณ logit ของ key เหล่านี้ไปเลย และให้โมเดลใช้การคำนวณเต็มรูปแบบเฉพาะกับค่า (value) ที่อ่านมาจากภาพเท่านั้น ซึ่งเป็นการทำ Performance Tuning ที่ลดภาระของ NPU/CPU บน Edge Server ต้นทุนต่ำ โดยไม่ลดทอนความแม่นยำของ schema

2.3.6.3 Giedra et al. (2026) — วิธีวัด Trade-off แบบคู่ (Dual Power Measurement) บน Edge จริง

จุดเด่นของ Giedra et al. (2026) ที่งานวิจัยอื่นในกลุ่ม quantization/hardware ไม่มี คือระเบียบวิธีวัดผลแบบคู่ วัดความแม่นยำเชิงเนื้อหา (generation-based accuracy ด้วย lm-eval บนชุดงาน IFEval, GSM8K, TruthfulQA) บนเครื่อง desktop ที่มีทรัพยากรมากพอจะรันได้เร็ว แล้วแยกวัดประสิทธิภาพเชิงพลังงานจริง (throughput, power, energy) บนอุปกรณ์ edge จริงคือ NVIDIA Jetson Orin Nano Super (8GB) ต่างหาก จากนั้นจึงนำผลทั้งสองมาจับคู่ที่ระดับ model-configuration (แต่ละแบบจำลอง คูณ แต่ละระดับการควอนไทซ์) เพื่อสร้างเส้น trade-off ระหว่างความแม่นยำกับพลังงาน ครอบคลุมโมเดล 12 แบบขนาด sub-1B ถึง 8B พารามิเตอร์ จุดที่ต่างจากงานวัด Jetson อื่น ๆ ก่อนหน้า

คือ ไม่พึ่งพา telemetry ภายในของบอร์ดเพียงอย่างเดียว แต่ใช้การวัดพลังงานจากอุปกรณ์วัดภายนอกคู่กัน ทำให้ผลเชิงพลังงานน่าเชื่อถือกว่าการอ่านค่าจากซอฟต์แวร์ฝังตัวเพียงทางเดียว

สิ่งที่โครงงานนำไปปรับใช้: โครงงานจะนำรูปแบบการทดลองแบบคู่นี้มาใช้เป็นระเบียบวิธีในระยะที่ 7 (การประเมินผล) ของ Implementation Roadmap โดยตรง คือ (1) วัดความแม่นยำของ JSON output ที่สกัดได้จากใบเสร็จ/ฉลากจริง (ไม่ใช่ benchmark ทั่วไปแบบ IFEval/GSM8K) แยกจาก (2) การวัด CPU/Memory/Power บน SBC/Edge Server จริงที่ใช้ในบ้าน แล้วจับคู่ผลทั้งสองที่ระดับชุดค่าคอนฟิกเดียวกัน (ระดับ quantization คูณ การเปิด/ปิด grammar-constrained decoding) เพื่อให้ได้กราฟ trade-off ที่ใช้ตัดสินใจเลือกระดับการบีบอัดที่เหมาะสมกับ Edge Server ในบ้านจริง ถือเป็นการทำ Trade-off Analysis ที่ตรงกับวัตถุประสงค์ข้อ 2 ของรายงานนี้ (การกำหนดระดับการบีบอัดที่เหมาะสม)

บทที่ 3 สรุปผลการศึกษา

3.1 สรุปผล

การทบทวนวรรณกรรมทั้ง 12 ฉบับในรายงานฉบับนี้ พบว่างานวิจัยด้านการอนุมานแบบจำลองภาษาบนอุปกรณ์ประมวลผลเฉพาะถิ่น (on-device LLM inference) มีความก้าวหน้าอย่างต่อเนื่องในสามมิติหลัก ได้แก่ quantization/hardware trade-off, grammar-constrained decoding/structured output และการประยุกต์ใช้งานในบริบทบ้านอัจฉริยะ/IoT ปลายน้ำ ทว่าทั้งสามมิตินี้ยังคงถูกศึกษาแยกจากกัน โดยไม่มีงานวิจัยฉบับใดประเมินปฏิสัมพันธ์ร่วมกันของทั้งสามมิติ บนอุปกรณ์ single-board computer (SBC) ที่มีทรัพยากรจำกัดจริงในบริบทที่พักอาศัย ช่องว่างทางความรู้นี้จึงเป็นโอกาสสำคัญสำหรับโครงงานวิทยานิพนธ์ในการบูรณาการองค์ประกอบทั้งหมด ตั้งแต่การตรวจจับเอกสารด้วยกล้อง การสกัดข้อความ การประมวลผลด้วย Local LLM จนถึงการเชื่อมต่อกับระบบบ้านอัจฉริยะเพื่อพยากรณ์พฤติกรรมการบริโภคในครัวเรือน

3.2 แนวทางการนำไปใช้

- นำกรอบ Performance Trade-off ทั้ง 3 มิติ (quantization/hardware, structured decoding, downstream IoT) มาใช้เป็นกรอบการออกแบบและประเมินสถาปัตยกรรมของระบบ
- อ้างอิงหลักการแบ่งงานตามความอ่อนไหวต่อการควอนไทซ์ (quantization sensitivity) ของ Yin et al. (2026) มากำหนดว่าเลเยอร์ใดของ Local LLM ควรรันบน NPU แบบ INT8 เต็มรูปแบบ และเลเยอร์ใด (เช่น decoding head ที่ต้องการค่า logit แม่นยำ) ควรสำรองให้ CPU ช่วยคำนวณบางส่วน ร่วมกับผลการวัด trade-off ระหว่างความแม่นยำและพลังงานของ Giedra et al. (2026) บนโมเดลขนาด sub-1B ถึง 8B พารามิเตอร์ เพื่อเลือกระดับการบีบอัดแบบจำลองที่เหมาะสมกับ Edge Server ขนาดหน่วยความจำ 8GB ในบริบทที่พักอาศัย

- ประยุกต์ใช้หลักการกำหนดโทเคนที่แน่นอนล่วงหน้าจาก schema แล้วข้ามการคำนวณของโมเดล (jump-forward decoding) ของ Zheng et al. (2024) มาออกแบบ JSON schema ตายตัวสำหรับใบเสร็จ/ฉลากสินค้า (คีย์คงที่ เช่น "item": , "price": , "date":) ให้ตัวถอดรหัสข้ามการคำนวณ logit ของคีย์เหล่านี้ไปเลย และให้แบบจำลองที่ผ่านการบีบอัดแล้วคำนวณเต็มรูปแบบเฉพาะกับค่า (value) ที่อ่านมาจากภาพเท่านั้น เพื่อให้ได้ผลลัพธ์ JSON ที่มีความถูกต้องสูงบนอุปกรณ์ทรัพยากรจำกัด

- นำสถาปัตยกรรม IoT gateway น้ำหนักเบาบนไมโครคอนโทรลเลอร์ ESP32 ที่รองรับโปรโตคอล MQTT ของ Serepas et al. (2025) มาปรับใช้เป็นชั้นเชื่อมต่อ Home Assistant โดยกำหนด MQTT topic แยกตามรายการสินค้า (เช่น home/inventory/<item_id>/quantity) และนำแบบจำลองพยากรณ์อนุกรมเวลาตามฤดูกาล Adaptive Holt-Winters ของ Sawalha and Al-Naymat (2025) มาปรับใช้กับข้อมูลปริมาณคงเหลือรายวันต่อรายการสินค้า เพื่อพยากรณ์อัตราการสิ้นเปลืองสินค้า (burn rate) ของแต่ละครัวเรือน

- ใช้ช่องว่างทางความรู้ที่ระบุไว้เป็นจุดยืนของงานวิจัย (research positioning) ในการเขียนบทนำและวัตถุประสงค์ของวิทยานิพนธ์ฉบับเต็มต่อไป

3.3 สถาปัตยกรรมเชิงแนวคิด (Conceptual Architecture)

จากผลการสังเคราะห์วรรณกรรมในบทที่ 2 โครงงานนี้กำหนดสถาปัตยกรรมเชิงแนวคิด (Conceptual Architecture) ดังแสดงในภาพที่ 1 (หัวข้อ 1.1) เป็นไปป์ไลน์ (Pipeline) ที่แบ่งความรับผิดชอบออกเป็น 3 ชั้นหลัก โดยแต่ละชั้นอ้างอิงเทคนิคเฉพาะจากงานวิจัยที่ทบทวนมาในหัวข้อ 2.1 และ 2.3 ดังนี้

- ชั้นตรวจจับและสกัดข้อมูล (Sensing/Capture Layer): กล้อง IP Camera จับภาพเอกสาร (ใบเสร็จ/ฉลากสินค้า) แบบเรียลไทม์ แล้วส่งต่อให้แบบจำลอง YOLO ทำหน้าที่ตรวจจับตำแหน่งเอกสารและตัดกรอบภาพ (Document Detection) ก่อนส่งเข้าสู่โมดูล OCR เพื่อสกัดข้อความดิบออกจากภาพ

- ชั้นประมวลผลด้วย NPU-centric Local LLM (Inference Layer): ข้อความดิบจาก OCR ถูกส่งเข้าสู่ Quantized Local LLM ที่รันบนหน่วยประมวลผลเฉพาะทาง (NPU) เป็นหลัก ตามแนวคิด NPU-centric Architecture ของ Yin et al. (2026) โดยเลือกระดับการบีบอัดแบบจำลองตามผลการวัด Trade-off ของ Giedra et al. (2026) และควบคุมผลลัพธ์ด้วยเทคนิค Grammar-Constrained Decoding ตามแนวทางของ Zheng et al. (2024) เพื่อบังคับให้ผลลัพธ์เป็นโครงสร้าง JSON ที่ถูกต้อง

- ชั้นประยุกต์ใช้งานปลายน้ำ (Application Layer): ข้อมูล JSON ที่ได้ถูกส่งผ่านโปรโตคอล MQTT เข้าสู่ระบบบ้านอัจฉริยะ Home Assistant ตามแนวทาง IoT Gateway ของ Serepas et al. (2025) จากนั้นนำข้อมูลไปประมวลผลด้วยแบบจำลองพยากรณ์ Adaptive Holt-Winters ตามแนวทางของ Sawalha and Al-Naymat (2025) เพื่อพยากรณ์อัตราการสิ้นเปลืองสินค้าในครัวเรือน (burn rate) และแสดงผลผ่านแดชบอร์ด

จุดที่แตกต่างจากงานวิจัยที่ทบทวนมาคือการออกแบบให้ทั้งสามชั้นทำงานประสานกันภายใต้เงื่อนไขฮาร์ดแวร์ SBC/Edge Server เดียวกันแบบ Single-host ในบริบทที่พักอาศัย โดยไม่มีการเชื่อมต่อคลาวด์ภายนอกในขั้นตอนประมวลผลหลัก เพื่อรักษาความเป็นส่วนตัวของข้อมูลครัวเรือนตลอดทั้ง Pipeline

3.4 แผนการดำเนินงาน (Implementation Roadmap)

ในระยะปัจจุบัน โครงงานยังอยู่ในขั้นตอนของ Conceptual View กล่าวคือยังไม่มีการพัฒนาส่วนต้นแบบ (Toy Model) หรือโค้ดจริงแต่อย่างใด โดยแผนการดำเนินงานทั้งหมดถูกวางเป็นระยะดังตารางที่ 6

ระยะ	กิจกรรม	สถานะ
ระยะที่ 1	ทบทวนวรรณกรรมและสังเคราะห์กรอบ Performance Trade-off 3 มิติ กำหนดสถาปัตยกรรมเชิงแนวคิด (Conceptual Architecture) ของ Pipeline 3 ชั้น	เสร็จสิ้น (เอกสารฉบับนี้ — Conceptual View)
ระยะที่ 2	จัดเตรียมฮาร์ดแวร์ SBC/Edge Server และคัดเลือกระดับการบีบอัด Quantized Local LLM เบื้องต้นตามผลการวัด trade-off ระหว่างความแม่นยำและพลังงานของ Giedra et al. (2026) บนโมเดลขนาด sub-1B ถึง 8B พารามิเตอร์ พัฒนาต้นแบบ (Toy Model) ของชั้นตรวจจับเอกสารด้วย YOLO และ OCR	ยังไม่เริ่ม
ระยะที่ 3	พัฒนาโมดูลประมวลผลด้วย NPU-centric Quantized Local LLM ตามหลักการแบ่งงานตามความอ่อนไหวต่อการควอนไทซ์ของ Yin et al. (2026) ร่วมกับ Grammar-Constrained Decoding แบบ jump-forward ของ Zheng et al. (2024) เพื่อแปลงข้อความจาก OCR เป็นโครงสร้าง JSON	ยังไม่เริ่ม
ระยะที่ 4	เชื่อมต่อระบบเข้ากับ Home Assistant ผ่าน MQTT ตามสถาปัตยกรรม IoT gateway บน ESP32 ของ Serepas et al. (2025) และพัฒนาแบบจำลองพยากรณ์ burn rate ด้วยแนวทาง Adaptive Holt-Winters ของ Sawalha and Al-Naymat (2025) พร้อมแดชบอร์ดแสดงผล	ยังไม่เริ่ม
ระยะที่ 5	เก็บข้อมูลนำร่อง (Pilot 1-2): ใบเสร็จและฉลากสินค้าจริง เพื่อประเมินความแม่นยำของ OCR และการสกัดข้อมูลด้วย LLM แบบ Factorial Design ตามแนวทางการประเมินแบบจำลองหลายรุ่นของ Husom et al. (2025)	ยังไม่เริ่ม
ระยะที่ 6	ยื่นขอรับรองจริยธรรมการวิจัยในมนุษย์ (IRB) ผ่าน eckku.kku.ac.th สำหรับ Pilot 3 และเก็บข้อมูลอัตราการแก้ไขของผู้ใช้แบบ End-to-end	ยังไม่เริ่ม
ระยะที่ 7	ประเมินผล Trade-off ระหว่างความละเอียดของข้อมูล ความแม่นยำของการสกัดข้อมูล และภาระการประมวลผล (CPU/Memory/Latency Overhead) ตามระเบียบวิธีวัดผลแบบคู่ (dual power measurement) ของ Giedra et al. (2026) เปรียบเทียบกับแนวทางในงานวิจัยที่ทบทวนมา	ยังไม่เริ่ม

ตารางที่ 6: Implementation Roadmap

เอกสารอ้างอิง

Cai, F., Yuan, D., Yang, Z., & Cui, L. (2024). Edge-LLM: A collaborative framework for large language model serving in edge computing. In 2024 IEEE International Conference on Web Services (ICWS) (pp. 799–809). https://doi.org/10.1109/ICWS62655.2024.00099

Giedra, H., Matuzevičius, D., Sledevič, T., Shubitidze, G., & Serackis, A. (2026). Benchmarking large language model inference on limited-resource edge systems. Electronics, 15(11), Article 2451. https://doi.org/10.3390/electronics15112451

Hu, A., Xu, H., Zhang, L., Ye, J., Yan, M., Zhang, J., Jin, Q., Huang, F., & Zhou, J. (2025). mPLUG-DocOwl2: High-resolution compressing for OCR-free multi-page document understanding. In Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers) (pp. 5817-5834). https://doi.org/10.18653/v1/2025.acl-long.291

Husom, E. J., Goknil, A., Astekin, M., Shar, L. K., Kåsen, A., Sen, S., Mithassel, B. A., & Soylu, A. (2025). Sustainable LLM inference for edge AI: Evaluating quantized LLMs for energy efficiency, output accuracy, and inference latency. ACM Transactions on Internet of Things, 6(4), Article 28. https://doi.org/10.1145/3767742

Moon, S., Cha, J., Park, H., & Kim, J.-Y. (2025). Hybe: GPU-NPU hybrid system for efficient LLM inference with million-token context window. In Proceedings of the 52nd Annual International Symposium on Computer Architecture (ISCA 2025) (pp. 808–820). https://doi.org/10.1145/3695053.3731051

Oloko-Oba, M., Esenogho, E., & Aruleba, K. (2026). From biosignals to bedside: A review of real-time edge machine learning for wearable health monitoring. Bioengineering, 13(5), 559. https://doi.org/10.3390/bioengineering13050559

Rivkin, D., Hogan, F., Feriani, A., Konar, A., Sigal, A., Liu, X., & Dudek, G. (2025). AIoT smart home via autonomous LLM agents. IEEE Internet of Things Journal, 12(3), 2458-2472. https://doi.org/10.1109/JIOT.2024.3471904

Sawalha, S., & Al-Naymat, G. (2025). An adaptive Holt-Winters model for seasonal forecasting of Internet of Things (IoT) data streams. IoT, 6(3), Article 39. https://doi.org/10.3390/iot6030039

Serepas, F., Papias, I., Christakis, K., Dimitropoulos, N., & Marinakis, V. (2025). Lightweight embedded IoT gateway for smart homes based on an ESP32 microcontroller. Computers, 14(9), Article 391. https://doi.org/10.3390/computers14090391

Yin, W., Xu, D., Xu, M., Huang, G., Liu, X., Mascolo, C., & Kawsar, F. (2026). ShadowNPU: System and algorithm co-design for NPU-centric on-device LLM inference. In Proceedings of the 24th Annual International Conference on Mobile Systems, Applications and Services (MobiSys 2026) (pp. 294–308). https://doi.org/10.1145/3745756.3809205

Zheng, L., Yin, L., Xie, Z., Sun, C. L., Huang, J., Yu, C. H., Cao, S., Kozyrakis, C., Stoica, I., Gonzalez, J. E., Barrett, C., & Sheng, Y. (2024). SGLang: Efficient execution of structured

language model programs. Advances in Neural Information Processing Systems, 37, 62557-62583. https://doi.org/10.52202/079017-2000

Zheng, Y., Chen, Y., Qian, B., Shi, X., Shu, Y., & Chen, J. (2025). A review on edge large language models: Design, execution, and applications. ACM Computing Surveys, 57(8), Article 209. https://doi.org/10.1145/3719664